

OPTIMIZACIÓN MULTIOBJETIVO (FALTA CREAR TITULO)

Montserrat Mora, Adriana Coronel, Diego Pinto-Roa, José Luis Vázquez Noguera

Facultad Politécnica - Universidad Nacional de Asunción

ABSTRACT

La mejora de contraste en imágenes en escala de gris es una técnica que busca resaltar la información útil de la imagen. Las técnicas, por lo general están relacionadas con las métricas que se utilizan para medir la cantidad de información y la calidad de la imagen. Escoger las métricas adecuadas de forma a lograr maximizar la información disponible minimizando la cantidad de ruido introducido supone un paso fundamental para lograr resultados en el proceso. En este trabajo se propone un enfoque de comparación basado en la Correlación de Pearson para medir la proporción de cambio inversa entre métricas. Los resultados muestran que una dupla de métricas obtiene el coeficiente más bajo de correlación, lo que indica que los objetivos muestran mayor correlación inversa y por lo tanto son las mejores métricas para utilizar dentro del algoritmo de mejora de contraste. Se realizaron comparaciones de a pares entre Entropía, Entropía Local, Índice de Similitud Estructural y la métrica Local Tuned Global.

Index Terms— SMP SO, CLAHE, Entropía, Entropía Local, SSIM, LTG, Mejora del Contraste, Optimización.

1. INTRODUCCIÓN

Las imágenes digitales están expuestas a sufrir una variedad de distorsiones durante su procesamiento, compresión, almacenamiento, transmisión y reproducción, y cualquiera de ellas puede resultar en la degradación de la calidad visual.

El principal objetivo de las técnicas de mejora es procesar una imagen de forma que resulte más adecuada que la original para una aplicación específica. Existen muchas técnicas de Mejoras de Contraste en el procesamiento de imágenes usadas para mejorar la apariencia de una imagen y hacerla más apta para la percepción visual humana. Una estrategia fundamental para la mayoría de las técnicas de Mejora de Contraste es la transformación del histograma. La técnica más usadas debido a su simplicidad y eficiencia es la Ecualización del Histograma (HE).

Es de gran importancia realizar la Mejora del Contraste de imágenes de carácter médico, debido a que de esta manera es posible acentuar y mantener las características presentes en ellas. Las radiografías presentan características particulares de contraste, como en el caso de radiografías del tórax y mamografías, donde pueden existir diferencias de contraste

notorias debido a las características de atenuación de los Rayos X [?].

Los enfoques de mejora local demuestran ser sumamente útiles al momento de realzar detalles en imágenes médicas, y existen diversas propuestas que se centran en mejorar el contraste en radiografías [?, ?, ?]. Debido a ello en esta propuesta se estudia la comparación de la correlación de entre dos métricas, la entropía local vs. SSIM y la entropía local vs LTG.

utilizará una metaheurística de optimización de objetivos, de manera a sintonizar los parámetros de entrada del algoritmo de mejora del contraste descrito en la sección 2, de manera a obtener un grupo de imágenes contrastadas, las cuales serán evaluadas en cuanto a la ganancia de información proveída y distorsión introducida por la ecualización (sección 3).

2. CONTRAST LIMITED ADAPTIVE HISTOGRAM EQUALIZATION (CLAHE)

Este enfoque de mejora de contraste presentado en [?] es una extensión del algoritmo original Adaptive Histogram Equalization (AHE) [?]; en ambos métodos se implementa un enfoque de Ecualización del Histograma local basada en *Regiones Contextuales*, que representan porciones de la imagen, cuyas dimensiones están delimitadas por $(\mathcal{R}_x, \mathcal{R}_y)$, para realizar la ecualización por sectores de la imagen. Las inconsistencias entre fronteras de las secciones la imagen se corrigen aplicando un esquema de interpolación bilineal.

El algoritmo AHE original presenta problemas de amplificación del ruido, por tanto en CLAHE se implementa una limitación de la cantidad de píxeles que pueden alcanzar cierto nivel de gris dentro del histograma local; aquí se define el coeficiente *Clip Limit* \mathcal{C} , como un factor que está fuertemente relacionado con los contenidos del histograma. El mismo permite realizar cortes en picos del histograma local, que se traducen en ruido dentro de la imagen.

3. MÉTRICAS DE EVALUACIÓN

Se adoptan tres métricas consideradas importantes para las comparaciones de los resultados obtenidos por el CLAHE que nos permitan determinar cuantitativamente la calidad de las mismas; éstas son la Entropía local como medida de mejora

del contraste, el Índice de Similitud Estructural y el modelo Local Tuned Global como medidas de distorsión de la imagen.

3.1. Entropía

La *Entropía de la Información* es una medida de la aleatoriedad presente en la imagen [?]. Se puede definir la Entropía de la imagen como:

$$\mathcal{H} = - \sum_{i=0}^{L-1} \mathcal{P}_i \log_2(\mathcal{P}_i) [\text{bits}] \quad \mathcal{H} \in 0, \dots, \log_2(L) \quad (1)$$

Donde \mathcal{P}_i es la probabilidad de ocurrencias del nivel de gris i en el histograma y L es el máximo nivel de gris que se puede utilizar para representar la imagen. Esta métrica es interesante debido a que está fuertemente asociada al brillo medio de la imagen [?]; este coeficiente nos ayuda a ver cuánto aumenta el contraste como consecuencia de la transformación de la imagen.

3.2. Índice de similitud estructural (SSIM)

El Índice de Similitud Estructural (SSIM) [?] es un coeficiente que mide el grado de distorsión producida en una imagen resultante T a consecuencia de aplicar una Mejora del Contraste a una imagen original I . SSIM se calcula por bloques, por lo que si definimos dos ventanas I_x e T_y para las imágenes original y resultante, respectivamente, se define el SSIM como se muestra abajo:

$$SSIM(I, T) = \frac{(2\mu_{I_x}\mu_{T_y} + C_1)(2\sigma_{I_x T_y} + C_2)}{(\mu_{I_x}^2 + \mu_{T_y}^2 + C_1)(\sigma_{I_x}^2 + \sigma_{T_y}^2 + C_2)} \quad SSIM \in [0, 1] \quad (2)$$

Donde μ_{I_x} es el promedio de intensidades de I_x ; μ_{T_y} es el promedio de intensidades de T_y ; $\sigma_{I_x}^2$ y $\sigma_{T_y}^2$ son las varianzas de intensidades de I_x e T_y , respectivamente; $\sigma_{I_x T_y}$ es la covarianza entre I_x e T_y ; $C_1 = (K_1 L^2)$, L es el rango dinámico de intensidades de los píxeles (256 para una imagen en escala de grises de 8 bits) y $K_1 \ll 1$ es una constante pequeña; $C_2 = (K_2 L)^2$, y $K_2 \ll 1$; tanto C_1 y C_2 son constantes que se usan para estabilizar la división en caso de que el denominador tienda a cero.

3.3. Local Tuned Global Model (LTG)

El modelo Local Tuned Global (LTG) está inspirado en las métricas IQA (Image Quality Assessment), fue introducido bajo la hipótesis de que la percepción visual humana en la calidad de la imagen depende de la distorsión local resaltante y la degradación global de la calidad. El modelo extrae información sobre la luminancia (brillo percibido por el ojo humano) y la crominancia (información del color) de la imagen de entrada y la imagen distorsionada, luego mide la distorsión local

resaltante y la degradación global de la calidad en la información obtenida sobre la luminancia y compara las diferencias en la información obtenida sobre la crominancia, derivando así el valor global de la calidad de la imagen.

$$LTG(x, y) = \frac{\Phi(G_s^{\theta_1})}{\Phi(G_m^{\theta_2})} \Phi(I_m^{\theta_3} \cdot Q_m^{\theta_3}) \quad (3)$$

Donde:

- G_m = es el gradiente medio de la imagen original y distorsionada.
- G_s = indica los píxeles con valores S% más altos en G_m .
- I_m y Q_m = contienen la información de crominancia de las imágenes.

4. FORMULACIÓN DEL PROBLEMA PLANTEADO

Dadas la imagen de entrada I , y un vector $\vec{x} = (\mathcal{R}_x, \mathcal{R}_y, \mathcal{C})$, donde \mathcal{R}_x y \mathcal{R}_y conforman la región contextual y \mathcal{C} es el *ClipLimit*, se desea calcular el conjunto de soluciones \mathcal{X} que maximice de manera simultánea los objetivos f_1 y f_2 , como se muestra abajo:

$$f(I, \vec{x}) = \{f_1(I, \vec{x}), f_2(I, \vec{x})\} \quad f_1, f_2 \in [0, 1] \quad (4)$$

donde:

- $f_1(I, \vec{x}) = \frac{\mathcal{H}(T)}{\log_2 L}$ es la Entropía local normalizada de la imagen T .
- $f_2(I, \vec{x}) = SSIM(I, T)$ es el Índice de Similitud Estructural o el modelo Local Tuned Global entre I y T .

Siendo T la imagen mejorada por *CLAHE*(\vec{x}, I) con los parámetros dados por \vec{x} aplicados a I .

sujeto a:

- $\mathcal{R}_x \in [2, \dots, M]$ en los números \mathbb{N} .
- $\mathcal{R}_y \in [2, \dots, N]$ en los números \mathbb{N} .
- $\mathcal{C} \in (0, 1]$ en los números \mathbb{R} .

Esto significa que los valores de \mathcal{R} solamente pueden tomar valores enteros positivos entre $(2, 2)$ y (M, N) y que \mathcal{C} puede tomar un valor mayor a cero y menor o igual a 1.

Algoritmo 1 Algoritmo *PSO* – *CLAHE* Multiobjetivo.

Entrada: imagen de entrada I , número de partículas Ω , número de iteraciones t_{max}

- 1: Inicializar los parámetros $\omega, C_1, C_2, t = 0, lower_limit_1, lower_limit_2, lower_limit_3, upper_limit_1, upper_limit_2, upper_limit_3, \mathcal{X}$
- 2: **mientras** $t < t_{max}$ **hacer**
- 3: **para** cada i -ésima partícula del enjambre **hacer**
- 4: Calcular la nueva velocidad de la partícula \vec{v}_i^t utilizando la ecuación (6), sujeto a las restricciones impuestas por (8)
- 5: Calcular la nueva posición de la partícula \vec{x}_i^t con la expresión de posición (5)
- 6: $T = \text{CLAHE}(\vec{x}_i^t, I)$
- 7: $f_i^t = f(I, \vec{x}_i^t)$
- 8: **si** $f_i^t < f_{\vec{x}_{p_i}}^t$ **then**
- 9: reemplazar \vec{x}_{p_i} por el nuevo valor de \vec{x}_i^t
- 10: **fin si**
- 11: **si** $\vec{x}_i^t \succ \vec{x}_{g_i}^t$ **then**
- 12: actualizar \mathcal{X}
- 13: **fin si**
- 14: $t = t + 1$
- 15: **fin para**
- 16: **fin mientras**

Salida: \mathcal{X}

5. PROPUESTA

Se utiliza el algoritmo *SMPSO* [?], donde las soluciones potenciales $\vec{x} = (\mathcal{R}_x, \mathcal{R}_y, \mathcal{C})$ se denominan *partículas* y el conjunto de partículas Ω se denomina *enjambre*. Cada partícula \vec{x}_i se actualiza en cada generación t de acuerdo a la siguiente ecuación:

$$\vec{x}_i^t = \vec{x}_i^{(t-1)} + \vec{v}_i^t \quad (5)$$

donde el factor \vec{v}_i^t se conoce como la velocidad y está dado por:

$$\vec{v}_i^t = \omega \cdot \vec{v}_i^{(t-1)} + C_1 \cdot r_1 \cdot (\vec{x}_{p_i} - \vec{x}_i) + C_2 \cdot r_2 \cdot (\vec{x}_{g_i} - \vec{x}_i) \quad (6)$$

Aquí, \vec{x}_{p_i} es la mejor solución que encontró \vec{x}_i , \vec{x}_{g_i} es la mejor partícula (también conocida como *líder*) que se encuentra en todo el enjambre, ω es el peso de la inercia de la partícula, r_1 y r_2 son dos números aleatorios, y C_1 y C_2 son parámetros que controlan el efecto de las partículas locales y globales. Si una partícula es mejor que otra, se dice que la *domina*, y la dominancia está definida de la siguiente manera: $\vec{x}_{g_i} \succ \vec{x}_i$ si y sólo si

$$\begin{cases} f_i(I, \vec{x}_g) \geq f_i(I, \vec{x}) \forall i \in \{1, 2\} \\ f_i(I, \vec{x}_g) > f_i(I, \vec{x}) \exists i \in \{1, 2\} \end{cases} \quad (7)$$

El *Conjunto Pareto* es el grupo de soluciones \mathcal{X} , y la imagen en el espacio objetivo es el *Frente Pareto*.

En adición, en *SMPSO* se realiza una restricción en \vec{v} , para cada componente j de \vec{x} , de acuerdo a la siguiente ecuación:

$$v_{i,j}^t = \begin{cases} \text{delta}_j & \text{if } v_{i,j}^t > \text{delta}_j \\ -\text{delta}_j & \text{if } -\text{delta}_j \\ v_{i,j}^t & \text{otherwise} \end{cases} \quad (8)$$

donde:

$$\text{delta}_j = \frac{\text{upper_limit}_j - \text{lower_limit}_j}{2} \quad (9)$$

El **Algoritmo 1** muestra cómo se implementa la propuesta. Las imágenes resultantes se evalúan de acuerdo a las métricas (1) y (2) o (3), y los mejores resultados que se obtienen en base a éstas métricas conforman un conjunto pareto de soluciones. El conjunto representa una serie de imágenes con distintos niveles de contraste, de manera a resaltar características particulares de la misma.

La interacción entre CLAHE y las partículas de SMPSO se muestran en la **Fig. 1**. CLAHE recibe como parámetros de entrada los valores almacenados por una partícula $(\mathcal{R}_x, \mathcal{R}_y, \mathcal{C})$ y la imagen original I , y a la imagen procesada se le calculan las métricas \mathcal{H} y *SSIM* o *LTG* de manera a obtener las funciones objetivo. Las soluciones no dominadas se almacenan en el conjunto pareto. Éste proceso se repite hasta alcanzar un criterio de parada definido.