

**Universidad Nacional De Asunción
Facultad Politécnica
Ingeniería en Informática**



**Aplicación de optimización de enjambre de partículas para la sintonización
de los parámetros del CLAHE, en base a la Entropía y el Índice de
Similitud Estructural**

Luis Guillermo Moré Rodríguez
Marcos Andrés Brizuela Núñez

Asesores:

M.Sc. Ing. José Luis Vázquez Noguera
D.Sc. Ing. Diego P. Pinto-Roa
D.Sc. Ing. Horacio Legal Ayala

Proyecto de grado presentado en conformidad a los requisitos para obtener el
grado de Ingeniero en Informática

Campus Universitario. San Lorenzo - Paraguay
Diciembre - 2014

He de agradecer con el corazón sincero: a mis padres terrenales, Don Luis y Doña Victoria, a quienes venero con sagrado respeto. A mis abuelos, Don Hilario y Doña Eleuteria, dos personas particularmente importantes para mi; a ella entregaré en vida este logro. A mi adorada esposa Ma. Irene, y a mi tesoro Ma. Luján; ellas son las personas con las que verdaderamente aprendí a amar... ellas son el motivo por el que despierto cada mañana...

... Gracias, Padre Divino; Gracias, Madre Divina, ustedes en secreto me observan... y me cuidan...

Luis Guillermo Moré Rodríguez

Este triunfo va dedicado a las personas más importantes de mi vida.

A mi madre, Alba Núñez, que me ha apoyado y ayudado en todo momento durante este largo tiempo a poder culminar la carrera y poder terminar este trabajo. Gracias a su esfuerzo, a su apoyo y a su paciencia, que fueron elementos fundamentales para llevarme a conseguir este triunfo y no rendirme jamás.

A mi hermano Bruno Brizuela, que siempre ha estado apoyándome y también dándome fuerzas para continuar hacia adelante y poder terminar esta carrera, ayudándome en lo laboral para así poder seguir dedicándome a mis estudios y poder conseguir este triunfo.

Y por ultimo a una persona muy especial para mí, Cristina Escobar, que siempre a estado a mi lado dándome fuerzas para seguir hacia adelante y terminar la carrera, ayudándome a no rendirme en los momentos difíciles, y dándome su apoyo incondicional en todo momento, en este largo tiempo.

Gracias a Dios por todo y gracias a todos por su gran apoyo y por estar ahí siempre conmigo, gracias Mamá, gracias Bruno, gracias Maki, los quiero mucho.

Marcos Andrés Brizuela Núñez

Agradecimientos

Al Profesor M.Sc. Ing. José Luis Vázquez Noguera, por su paciencia y apoyo durante todo el desarrollo de este largo trabajo; por ayudarnos, guiarnos y orientarnos a empezar y concluir este proyecto final de grado; por los consejos brindados en este tiempo; por su predisposición a ayudarnos; y por ultimo, algo no menos importante, por el largo tiempo dedicado a nosotros y nuestro trabajo.

Al Profesor D.Sc. Ing. Diego Pedro Pinto Roa, por su apoyo incansable desde el inicio de este trabajo; por sus consejos; por su asesoramiento en la culminación de este proyecto final de grado; por su asesoramiento en la redacción y corrección de este libro; y por el valioso tiempo que nos ha dedicado para lograr este cometido.

Al Profesor D.Sc. Ing. Horacio Legal Ayala por el apoyo y asesoramiento de este proyecto final de grado desde el inicio del trabajo hasta la culminación del mismo.

A los tres, por el valioso tiempo que nos han dedicado, por el esfuerzo que pusieron para asesorarnos, por la paciencia que tuvieron para guiarnos y por sobre todo, la confianza puesta en nosotros para llevar a cabo este trabajo y poder terminarlo.

Abstract

Contrast Enhancement is a research field in Image Processing area, which addresses the problem of lack of contrast in digital images. Is one of the most important processes in the area because there are images which need contrast enhancement in order to be correctly visualized, and be able to analize its information contents. It is also important as a previous processing step for higher level applications, such as image segmentation and feature detection.

In several grayscale images, such as mammographies, fingerprints, and so on, information carried by them can be of crucial importance, and because of lack of contrast it is not possible to analize information contained in those images. In this context, contrast enhancement algorithms are necessary.

Contrast Limited Adaptive Histogram Equalization (CLAHE) is a local contrast enhancement algorithm, because is based in dividing the images in blocks. It needs to input parameters which are: the dimensions of the block, which is the size of every block in which the image is divided; and contrast limit, which is a factor that limits the amount of pixels that can reach the available gray levels of the image.

It is challenging to choose the appropriate input values for *CLAHE* in order to obtain a contrast enhancement of the image, without distorting it; this is because there is a huge number of possible values that are eligible to take as input parameter, so there is an enormous search space for solutions of this problem.

In order to decide which parameters are adequate to choose it is needed to fulfill the main objective of this research work, which consist in obtaining contrast enhancement of an image, maximizing the contained information and minimizing distortion produced by *CLAHE*. Given that maximizing and minimizing objectives implies searching for the best values, we can state that the searching of the adequate parameters for *CLAHE* is an optimization problem.

In order to find those optimal values, in this work we propose using a metaheuristic algorithm called Particle Swarm Optimization (*PSO*), which is an optimization algorithm, which is capable to explore a wide search space and find an optimal solution, or at least the closest solution to the optimal. *PSO* is a good choice for this optimization problem because it is easy to implement and needs low computational requirements.

In order to determine the best solution for the problem, which is finding the optimal input parameters for *CLAHE*, it is proposed an evaluation function, which is derived from two state-of-the-art metrics which are: Information Entropy, and Structural Similarity Index. The main objective from this evaluation is to measure that the resultant image from the *CLAHE* process given the chosen parameters gives the maximum of information possible and the least degradation of the original structure of the image.

This proposal was validated, comparing it with the implementation proposed by Byong [MLKL13], which is the closest method found in the state-of-the-art literature. The work proposed by Byong is a deterministic method, which consist in finding the adequate parameters for *CLAHE*, considering two adjusted curves, created by Entropy as a function of the contrast limit coefficient, and Entropy with respect to the window size. We achieved results in which Entropy coefficient is close to the results of Byong, nevertheless the values of *SSIM* obtained by the proposal of this work, *PSO – CLAHE*, were remarkably higher, therefore the evaluation function of the objectives was higher for *PSO – CLAHE*, for every test case showed.

Keywords: Contrast Limited Adaptive Histogram Equalization, Structural Similarity Index, Entropy, Local contrast enhancement, Particle Swarm Optimization, Histogram Equalization.

Resumen

La mejora de contraste es un campo del área de procesamiento de imágenes digitales que afronta el problema de la falta del contraste en una imagen. Es uno de los procesos más importantes del área debido a que algunas imágenes necesitan de una mejora de contraste con el fin de poder visualizarlas correctamente y analizar la información contenida en ella. También es importante como un preprocesamiento para aplicaciones más complejas como segmentación de imágenes o detección de características.

En muchas imágenes en escala de grises, como por ejemplo mamografías, radiografías, huellas dactilares, entre otras, la información contenida en ellas puede ser de vital importancia y que a causa de la falta de contraste no se puede analizar correctamente la información contenida en ellas. En este contexto, los algoritmos de mejora de contraste son fundamentales.

Contrast Limited Adaptive Histogram Equalization (CLAHE) es un algoritmo de mejora de contraste local basado en la división de una imagen en bloques. CLAHE posee dos parámetros de entrada, los cuales son: el tamaño de bloque, que es el tamaño que tendrán cada uno de los bloques en el que se divide la imagen; y el límite de contraste, que es un factor que limita la cantidad de píxeles que pueden llegar a tener los distintos niveles de gris disponibles.

Escoger los valores adecuados de estos dos parámetros de forma a conseguir mejorar el contraste de la imagen sin distorsionarla es un problema. Esto se debe a que existe un gran número de combinaciones posibles que pueden tomar dichos parámetros, lo que genera un enorme conjunto de soluciones posibles.

Para decidir cuales son los valores adecuados se debe cumplir con el objetivo principal trazado en este trabajo de investigación que consiste en mejorar el contraste de una imagen maximizando la información contenida en ella y minimizando la distorsión producida por *CLAHE*. Dado que la maximización y la minimización de objetivos implica buscar los mejores valores, el problema de la búsqueda de los parámetros adecuados es un problema de optimización.

Para encontrar los valores óptimos, en este trabajo de investigación se propone la utilización del algoritmo metaheurístico *Particle Swarm Optimization* (PSO), que es un algoritmo de optimización capaz de explorar un amplio

espacio de búsqueda y encontrar la solución óptima del problema o la más cercana a la óptima. *PSO* es una gran opción para el trabajo de optimización debido a que es de fácil implementación y bajo costo computacional.

Para poder determinar la mejor solución al problema, es decir, los valores óptimos de los parámetros del *CLAHE*, se propone el cálculo de una función de evaluación, el cual utiliza dos métricas del estado del arte que son: La Entropía de la información y el Índice de Similitud Estructural (SSIM por sus siglas en inglés Structural Similarity Index). El objetivo principal de esta evaluación es medir que la imagen resultante del proceso del *CLAHE* con los parámetros selectos posea la máxima cantidad de información posible y la menor degradación o distorsión posible en su estructura original.

Se validó la propuesta, comparando la misma con la implementación hecha por Byong [MLKL13], la cual es la más próxima al método encontrada en la literatura del estado del arte. El método de Byong es un método determinista consistente en encontrar los parámetros adecuados para *CLAHE* considerando dos curvas ajustadas, formadas por la Entropía como función del límite de contraste, y la Entropía con respecto al tamaño de ventana. Se lograron resultados cuya Entropía resulta cercana a los resultados logrados por Byong, aunque los valores de *SSIM* obtenidos por la propuesta de este trabajo *PSO-CLAHE* fueron notablemente superiores, por lo que la función de evaluación de los objetivos resultó mayor para todos los casos de prueba presentados.

Palabras claves: Contrast Limited Adaptive Histogram Equalization, Structural Similarity Index, Entropía, Mejora de contraste local, Optimización de enjambre de partículas, Ecualización del histograma.

Contenido

Contenido	VII
Lista de Figuras	IX
Lista de Símbolos	XI
Lista de Acrónimos	XIV
Lista de Tablas	xv
1. Introducción	1
1.1. Antecedentes	1
1.2. Objetivo General	3
1.3. Objetivos Específicos	3
1.4. Organización del Trabajo	4
2. Mejora de Imagen	5
2.1. Imagen digital	5
2.2. Mejora de imagen	8
2.3. Contraste	8
2.4. Mejora de contraste	12
2.4.1. Mejora de contraste global	12
2.4.2. Mejora de contraste local	13
2.5. Histograma de niveles de gris	14
2.5.1. Ecuación clásica del histograma	16
2.5.2. Ecuación local del histograma	20
2.6. Contrast Limited Adaptive Histogram Equalization (CLAHE)	21
2.6.1. Adaptive Histogram Equalization (AHE)	21
2.6.2. Limitaciones del algoritmo <i>AHE</i>	23
2.6.3. La idea introducida en <i>CLAHE</i>	24
2.6.4. Comparación entre <i>AHE</i> y <i>CLAHE</i>	28

CONTENIDO

3. Optimización de Enjambre de Partículas	32
3.1. Conceptos Básicos	32
3.2. Definición y Funcionamiento	33
3.3. Exploración y Explotación	38
3.4. Óptimos Locales y Óptimos Globales. Convergencia	38
3.5. Modificaciones y Desempeño del <i>PSO</i>	39
4. Métricas de evaluación	41
4.1. Entropía	42
4.2. Índice de Similitud Estructural	45
5. Propuesta	50
5.1. Contexto del Problema	50
5.2. Formulación del Problema	51
5.3. Algoritmo <i>PSO – CLAHE</i>	52
5.4. Relación <i>CLAHE-Partícula</i>	55
6. Resultados y Discusión	56
6.1. Ambiente de Ejecución e Implementación	56
6.2. Implementación del estado del arte	56
6.3. Resultados Obtenidos. Comparación con el estado del arte	58
7. Conclusiones y Trabajos Futuros	64
7.1. Consideraciones finales	64
7.2. Trabajos Futuros	66
Apéndice A	67
Apéndice B	79
Referencias	87

Listado de Figuras

2.1.	Píxeles de una imagen digital en escala de grises.	5
2.2.	Matrices numéricas y matrices pintadas con el nivel de gris correspondiente.	6
2.3.	Escalas de grises.	7
2.4.	Ejemplo de contraste.	9
2.5.	Ejemplo de contraste casi nulo.	9
2.6.	Iluminación insuficiente. Detalles ocultos por la oscuridad.	10
2.7.	Bajo Contraste. Tonos de colores muy semejantes.	11
2.8.	Imagen Médica. Radiografía. A mayor kV, menor contraste.	11
2.9.	División en bloques de 8x8 píxeles.	13
2.10.	Histograma de niveles de gris.	15
2.11.	Histograma uniforme.	15
2.12.	Redistribución de píxeles a lo largo del Histograma.	16
2.13.	Amplificación de ruido en una mamografía.	19
2.14.	Sobre mejora de imagen.	20
2.15.	Pérdida de detalles y distorsión.	20
2.16.	Diagrama de una región contextual del <i>AHE</i>	22
2.17.	Diferencias visibles de la ecualización por bloques.	23
2.18.	Redistribución de píxeles a lo largo del histograma de la región contextual.	24
2.19.	(a) Imagen original. (b) División en regiones como se indica en la línea 1 del pseudocódigo 2.	25
2.20.	Histograma sin ecualizar.	25
2.21.	Histograma ecualizado.	26
2.22.	Histograma ecualizado, con píxeles recortados y redistribuidos.	26
2.23.	Diagrama de interpolación bilineal de un punto m de la imagen.	27
2.24.	(a) Imagen sin interpolar. (b) Imagen interpolada. Resultado final del <i>CLAHE</i>	28
2.25.	(a)Imagen original. (b) Mejorada con <i>AHE</i> . (c) Mejorada con <i>CLAHE</i>	29
2.26.	Histograma de la Figura 2.25a.	29
2.27.	Histograma de la Figura 2.25b.	29
2.28.	Histograma de la Figura 2.25c.	30
2.29.	(a) Imagen original. (b) Distorsión y amplificación de ruido producido por parámetros no adecuados del <i>CLAHE</i>	30

LISTA DE FIGURAS

3.1.	Movimiento inicial aleatorio de cada partícula.	35
3.2.	Convergencia de las partículas hacia la solución óptima.	36
3.3.	Influencia de los parámetros p_i , p_g y ω en la velocidad de una partícula.	37
3.4.	Ejemplo de óptimo global y óptimos locales.	39
4.1.	Diagrama esquemático de un sistema general de comunicación.	42
4.2.	Diagrama esquemático del cálculo del Índice de Similitud Estructural. .	46
4.3.	Diagrama de elementos componentes del Índice de Similitud Estructural.	48
5.1.	Relación CLAHE-Partícula.	55
6.1.	Ejemplo de curva ajustada de Entropía con respecto al Clip Limit, según la implementación de Byong. A partir de la misma se debe seleccionar el punto en donde se tiene la máxima curvatura, para tomar como el resultado de Clip Limit del algoritmo CLAHE.	57
6.2.	(a) Lenna Original. (b) $PSO - CLAHE$.(c) Byong.	61
6.3.	(a) Tórax Original. (b) $PSO - CLAHE$.(c) Byong.	61
6.4.	(a) Iris 1 Original. (b) $PSO - CLAHE$.(c) Byong.	62
1.	Imagen original y resultados para imagen Mamografía.	80
2.	Imagen original y resultados para imagen Retinopatía.	80
3.	Imagen original y resultados para imagen Células.	80
4.	Imagen original y resultados para imagen Rodilla.	81
5.	Imagen original y resultados para imagen Aorta.	81
6.	Imagen original y resultados para imagen Flores.	81
7.	Imagen original y resultados para imagen Jirafa.	82
8.	Imagen original y resultados para imagen Árbol.	82
9.	Imagen original y resultados para imagen Mujer.	82
10.	Imagen original y resultados para imagen Caramelos.	83
11.	Imagen original y resultados para imagen Caramelos 2.	83
12.	Imagen original y resultados para imagen Aérea.	83
13.	Imagen original y resultados para imagen Aérea 2.	84
14.	Imagen original y resultados para imagen Avión.	84
15.	Imagen original y resultados para imagen Pareja.	84
16.	Imagen original y resultados para imagen Puente.	85
17.	Imagen original y resultados para imagen Camión.	85
18.	Imagen original y resultados para imagen Elaine.	85
19.	Imagen original y resultados para imagen biométrica de Iris 2.	86
20.	Imagen original y resultados para imagen biométrica Dedo.	86

Listado de Símbolos

Variables

- c Cantidad de información de cada estado posible de un mensaje del esquema de Shannon.
- \mathcal{C} Clip Limit.
- C_1 Constante utilizada en la fórmula de la Luminancia.
- C_2 Constante utilizada en la fórmula de la Contraste.
- C_3 Constante utilizada en la fórmula de la Estructura.
- f Valor o función de Fitness.
- f_i^t Valor del Fitness de la partícula i en la iteración t .
- f_{p_i} Valor del Fitness de la mejor posición individual encontrada hasta el momento de una partícula i .
- f_g Valor del Fitness de la mejor posición global encontrada hasta el momento por todo el enjambre de partículas.
- F_i Fuerza que actúa sobre una partícula i .
- \mathcal{H} Histograma de una imagen.
- \mathcal{H} Entropía
- h_k Cantidad de píxeles que posee el k-ésimo nivel de gris del histograma.
- I Imagen digital.
- k Nivel de gris o k-ésimo nivel de gris.
- k' Nuevo nivel de gris mapeado por la ecualización del histograma.
- \mathcal{K} Estado posible de un mensaje del esquema de Shannon.
- K_1 Constante utilizada en la fórmula de la Luminancia.

Lista de Símbolos

K_2 Constante utilizada en la fórmula de la Contraste.

L Cantidad de niveles de gris.

m Cantidad de filas de un bloque o región contextual de una imagen digital.

M Cantidad de filas de una imagen digital.

n Cantidad de columnas de un bloque o región contextual de una imagen digital.

N Cantidad de columnas de una imagen digital.

$\mathcal{P} = \frac{1}{\mathcal{K}}$ Probabilidad de ocurrencia de un estado \mathcal{K} de un mensaje del esquema de Shannon.

$\mathcal{P}_i = \frac{h_i}{Z}$ Probabilidad de ocurrencia de un nivel de gris i .

P_i Vector donde cada partícula i almacena la mejor posición o solución individual que ha encontrado hasta el momento.

p_g Mejor global hasta el momento encontrado por el enjambre de partículas.

p_{gd} Mejor global hasta el momento encontrado por el enjambre de partículas en la dimensión d .

Q Un mensaje del esquema de Shannon.

q_i Una parte i de un mensaje Q del esquema de Shannon.

\mathcal{R} Región contextual.

R^D Espacio de búsqueda D -dimensional del problema.

t Número de iteración del algoritmo PSO .

T Imagen digital.

$U(0, \phi_1)$ Coeficiente cognitivo del PSO .

$U(0, \phi_2)$ Coeficiente social del PSO .

V_i Vector que almacena la velocidad actual de cada partícula i .

v_i^t Velocidad actual de una partícula i en la iteración t .

v_i^{t+1} Velocidad de una partícula i para la siguiente iteración $t + 1$.

X_i Vector que almacena la posición actual de cada partícula i .

x_i^t Posición actual de cada partícula i en la iteración t .

x_i^{t+1} Posición de una partícula i para la siguiente iteración $t + 1$.

Lista de Símbolos

\vec{x} Una partícula del enjambre.

Z Cantidad total de píxeles de una imagen digital.

$(\mathcal{R}_x, \mathcal{R}_y)$ Tamaño de región contextual.

α Variable para denotar la curva de ajuste en el método de mejora de contraste propuesto por Byong.

β Coeficiente a determinar para encontrar la curva de mejor ajuste según el método de Byong.

γ Función con respecto al tiempo de la abscisa utilizada para hallar el punto de máxima curvatura, según el método de Byong.

δ Función con respecto al tiempo de la ordenada utilizada para hallar el punto de máxima curvatura, según el método de Byong.

Δf Diferencia entre fitness $PSO - CLAHE$ y Byong.

λ Coeficiente a determinar para encontrar la curva de mejor ajuste según el método de Byong.

μ_I Media de intensidad de una imagen I .

μ_T Media de intensidad de una imagen T .

σ_I Desviación típica de una imagen I .

σ_T Desviación típica de una imagen T .

σ_{IT} Covarianza entre dos imágenes I y T .

ϕ_1 Máximo valor que puede alcanzar el coeficiente cognitivo del PSO .

ϕ_2 Máximo valor que puede alcanzar el coeficiente social del PSO .

ω Coeficiente de inercia del PSO .

Ω Cantidad total de partículas.

Lista de Acrónimos

AHE Adaptive Histogram Equalization.

BBHE Brightness preserving Bi Histogram Equalization.

CLAHE Contrast Limited Adaptive Histogram Equalization.

DSIHE Dualistic Sub Image Histogram Equalization.

EA Evolutionary Algorithms.

FDA Función de Distribución Acumulativa.

HE Histogram Equalization.

JSON JavaScript Object Notation.

kV kiloVoltio.

MRI Magnetic Resonance Imaging.

MSE Mean Squared Error.

PSNR Peak Signal-to-Noise Ratio.

PSO Particle Swarm Optimization.

REST Representational State Transfer.

SDK Software Development Kit.

SSIM Structural Similarity Index.

VHS Visual Human System.

Listas de Tablas

3.1. Componentes del algoritmo <i>PSO</i>	33
6.1. Tabla de resultados de la implementación de PSO-CLAHE, para el grupo de imágenes médicas (tomografías, radiografías, mamografías y otros)	59
6.2. Tabla de resultados de la implementación de PSO-CLAHE, para el grupo de imágenes generales.	59
6.3. Tabla de resultados de la implementación de PSO-CLAHE, para el grupo de imágenes biométricas (escaneo de retina, escaneo de venas de dedos)	59
6.4. Tabla de resultados de la implementación de Byong [MLKL13], para el grupo de imágenes médicas (tomografías, radiografías, mamografías y otros).	60
6.5. Tabla de resultados de la implementación de Byong [MLKL13], para el grupo de imágenes generales.	60
6.6. Tabla de resultados de la implementación de Byong [MLKL13], para el grupo de imágenes biométricas (escaneo de retina, escaneo de venas de dedos)	60
1. Resultados para imagen Tórax.	67
2. Resultados para imagen Mamografía.	68
3. Resultados para imagen Retinopatía.	68
4. Resultados para imagen Células.	69
5. Resultados para imagen Rodilla.	69
6. Resultados para imagen Aorta.	70
7. Resultados para imagen Lenna.	70
8. Resultados para imagen Flores.	71
9. Resultados para imagen Jirafa.	71
10. Resultados para la imagen Árbol.	72
11. Resultados para imagen Mujer.	72
12. Resultados para imagen Caramelos.	73
13. Resultados para imagen Caramelos 2.	73
14. Resultados de la imagen Aérea.	74
15. Resultados para imagen Aérea 2.	74
16. Resultados para imagen Aeroplano.	75

LISTA DE TABLAS

17.	Resultados de la imagen Pareja.	75
18.	Resultados de la imagen Puente.	76
19.	Resultados para imagen Camión.	76
20.	Resultados de la imagen Elaine.	77
21.	Resultados de la imagen Iris 1.	77
22.	Resultados de la imagen Iris 2.	78
23.	Resultados de la imagen Dedo 1.	78

Capítulo 1

Introducción

1.1. Antecedentes

Desde la invención y evolución de las cámaras fotográficas, se ha vuelto muy común capturar la vida real en una imagen para el recuerdo. Además, la evolución de la tecnología ha permitido desarrollar aparatos más especializados y complejos con el fin de obtener imágenes específicas como las imágenes médicas, que se obtienen con aparatos que utilizan fenómenos físicos para construir una imagen tales como los Mamógrafos (Rayos X), Ecógrafos (Ultrasonido), Radiógrafos (Rayos X, Rayos Gamma), Escáner de Resonancia Magnética MRI (Ondas Electromagnéticas), Tomógrafos (Rayos X, Rayos Gamma, Ultrasonido, Electrones, Positrones, Iones) [GF10; Rus10]; y las imágenes biométricas, que se obtienen con aparatos que utilizan sensores tales como los Escáneres de huellas dactilares, los Escáneres de venas, y los Escáneres de iris que usan pequeñas cámaras especiales de alta resolución [PCGSCFYD09; JRP04].

Lo más importante de esta reseña histórica es la inclusión de la computación en el campo de las imágenes. El avance de la computación ha permitido crear lo más importante en esta área: la imagen digital. Actualmente, digitalizar una imagen es un proceso incluido en muchos aparatos que capturan imágenes, siendo la cámara digital la más común de todas [Bax94; Rus10].

Los aparatos médicos también se pueden conectar a computadoras y digitalizar las imágenes que construyen [GF10; Rus10], mientras que los aparatos biométricos normalmente funcionan conectados a las computadoras [PCGSCFYD09; Rus10]. Sin embargo, la captura de una imagen a través de cualquiera de estos aparatos no está exenta de problemas. La captura de una imagen puede sufrir de problemas de adición de ruido, mucha oscuridad, borrosidad, bajo contraste, entre otras. Muchas imágenes con este tipo de problemas necesitan de un procesamiento previo para poder ser visualizadas correctamente, en especial las imágenes médicas y las biométricas, debido a la información importante contenida en ellas [VS11; LLK13; SBS11; SV11].

El *Procesamiento digital de imágenes* es un proceso fundamental en las ciencias de la computación gracias a los importantes avances de la tecnología en el campo de la visión por computador. Esta área se encarga de subsanar los problemas surgidos durante la

captura de una imagen de cualquier tipo y capturada con cualquier dispositivo. La utilización del procesamiento digital de imágenes, se puede encontrar en un gran número de aplicaciones [KWH⁺13] incluyendo: visión por computador [Par10], segmentación de imágenes [AMFM11], reconocimiento de patrones [CPW10], procesamiento de imágenes médicas para la detección de anomalías [SRAP11; MR13; LWHJ94; KWR⁺00], monitoreo de personas con cámaras de vigilancia y biometría informática para la identificación de personas [NG11; ASN13; Han11; OHBL10].

Este trabajo está enfocado exclusivamente a la pobreza del contraste, específicamente en imágenes en escala de grises. Para mejorar el contraste de una imagen, se ha escogido el algoritmo Contrast Limited Adaptive Histogram Equalization (*CLAHE*), que es un algoritmo de mejora de contraste local basado en la división de la imagen en bloques y la ecualización del histograma de cada bloque de forma independiente, propuesto en [Zui94]. *CLAHE* ha demostrado tener buenos resultados principalmente en el procesamiento de imágenes con bajo contraste [SMG11] e imágenes médicas [SV11; MR13], debido a que en este tipo de imagen se priorizan los detalles locales de una imagen.

Una característica del *CLAHE* es que posee dos parámetros que controlan la calidad del resultado. Para obtener un buen resultado se debe escoger los valores óptimos. Sin embargo, el rango de posibilidades de ambos parámetros es muy grande, por lo que se necesita de algún mecanismo que encuentre los valores que brinde el resultado más óptimo en un tiempo razonable.

En el estado del arte, el algoritmo *CLAHE* es frecuentemente utilizado gracias a que puede producir una ecualización satisfactoria y limitar la mejora de contraste [SMG11]. En el trabajo de Byong [MLKL13], se plantea un método matemático para encontrar parámetros adecuados para el algoritmo *CLAHE*. Este trabajo se diferencia de nuestra propuesta en varios puntos. Primero, en dicho trabajo no se propone la búsqueda de los parámetros óptimos debido a que el método no utiliza un algoritmo de optimización. Byong propone una formulación sencilla para encontrar parámetros adecuados sin recorrer todo el espacio de búsqueda en base a la maximización de la entropía de la información. Y segundo, en el trabajo se hacen ciertas presunciones; por ejemplo se define un tamaño de ventana inicial con el objetivo de encontrar el Clip Limit que con dicho tamaño de ventana maximice la Entropía. Con dicho Clip Limit, ignora el tamaño de ventana inicial y busca un nuevo tamaño de ventana que nuevamente maximice la Entropía, finalizando así en que el par de valores encontrados son los parámetros adecuados del *CLAHE*.

El trabajo de Sheldha [MR13] está centrado en la mejora de imágenes de un solo tipo, las imágenes mamográficas. Dicha propuesta se combina con otra técnica de búsqueda de parámetros del *CLAHE* y otras métricas de evaluación de la solución. Se utiliza una formulación matemática que utiliza la media y la desviación estándar para calificar una solución en conjunto con la entropía y el número de aristas detectado por un filtro de Sober. La diferencia principal con nuestra propuesta es que nuestra propuesta no está centrada en un solo tipo de imágenes y la función de evaluación es diferente debido a la diferencia de métricas.

En el trabajo presentado por Saikat [SV11], se propone un método para la detección de Retinopatía diabética utilizando el algoritmo *CLAHE*. Sin embargo, se eligen los parámetros a utilizar de forma predeterminada y no se buscan los valores óptimos. Luego de la aplicación del algoritmo *CLAHE* se aplica un filtro de mediana para suavizar la amplificación de ruido producida por *CLAHE*.

De esta manera surgen varias preguntas respecto a la selección de parámetros. Debido a que en [MLKL13] se definió un tamaño de ventana inicial para buscar el Clip Limit y posteriormente volver a buscar un tamaño de ventana más adecuado para dicho coeficiente. Entonces, ¿Es el tamaño de ventana inicial el adecuado para hallar el Clip Limit final?, ¿El Clip Limit encontrado es el adecuado para cualquier otro tamaño de ventana?; en dicho trabajo utilizaron tamaños de ventana cuadrados y valores de Clip Limit acotados, ¿es esto adecuado para todos los casos?. En [SV11] se han predeterminado los dos parámetros de forma aún más simple debido a que dicho trabajo no se centra en la búsqueda de sus valores sino que utiliza el algoritmo *CLAHE* como un paso previo para otras operaciones. Entonces, ¿Han seleccionado parámetros que les genere buenos resultados?, ¿Si los parámetros fueran los adecuados, obtendrían mejor resultado las operaciones posteriores?. Por ultimo, la propuesta de [MR13] se han centrado en mamografías. Entonces, ¿Los parámetros encontrados por la propuesta de Shelda, son los más adecuados para otros tipos de imágenes como las biométricas, otras imágenes médicas o incluso cualquier tipo de imagen?

En estas propuestas no se han buscado los parámetros más óptimos que a su vez generen los mejores resultados del *CLAHE*. Además, en estos trabajos no se ha tenido en cuenta la distorsión producida por los algoritmos de mejora de contraste, solamente se han centrado en la maximización de la información, y se utilizaron métricas que miden el ruido introducido. Todos estos antecedentes sirven como motivación para el presente trabajo, por lo que a continuación delineamos un objetivo general para el mismo.

1.2. Objetivo General

El objetivo general de este trabajo de investigación es el de proponer una herramienta informática para encontrar los parámetros óptimos del algoritmo *CLAHE* de manera a mejorar el contraste de la imagen satisfactoriamente evitando la distorsión de la misma.

1.3. Objetivos Específicos

Los objetivos específicos que se han trazado en este trabajo para lograr el objetivo general son:

- Proponer una formulación matemática que maximice la cantidad de información y minimice la distorsión.

- Aplicar una metaheurística para sintonizar los parámetros del algoritmo *CLAHE*, en base a la formulación matemática propuesta.
- Comparar los resultados obtenidos con el estado del arte de modo a garantizar la validez de nuestros resultados.

1.4. Organización del Trabajo

El resto del trabajo está organizado de la siguiente manera:

- En el capítulo 2 se presentan los conceptos básicos que describen a la mejora de imagen y la mejora de contraste como también el algoritmo *CLAHE*.
- En el capítulo 3 se presenta la metaheurística de optimización de enjambre de partículas escogida en el trabajo para encontrar los parámetros óptimos del algoritmo *CLAHE*.
- En el capítulo 4 se presentan las métricas de evaluación de soluciones.
- El método propuesto en este trabajo se explica detalladamente en el capítulo 5. Cómo se utiliza la optimización de enjambre de partículas para explorar el espacio de búsqueda de soluciones para los parámetros del *CLAHE* y evaluar la mejor solución a través de las métricas propuestas.
- Los resultados de la propuesta se visualizan y discuten en el capítulo 6.
- En el capítulo 7, se finaliza el trabajo de investigación presentando las conclusiones generales.

Capítulo 2

Mejora de Imagen

2.1. Imagen digital

Una *Imagen* es una representación visual de una escena o un objeto real o imaginario que describe su apreciación visual en un momento dado. Puede ser un dibujo, una fotografía o una imagen digital [Rus10].

Una *Imagen digital* es una representación bidimensional de una imagen a partir de una matriz numérica donde cada lugar de la matriz representa un píxel. Un píxel es la menor unidad homogénea de color que forma una imagen digital. En la Figura 2.1 se ven claramente un grupo de píxeles de una imagen digital en escala de grises. Las imágenes digitales se pueden obtener por medio de dispositivos de conversión analógico-digital como los escáneres, equipos médicos digitales y las cámaras digitales, o a través de software para la creación y edición de imágenes como Photoshop, GIMP, Fireworks y otros [Bax94].

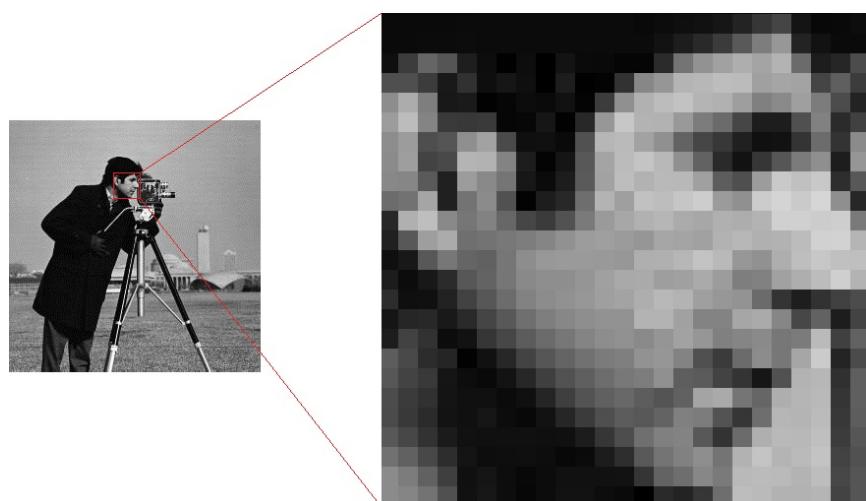


Figura 2.1: Píxeles de una imagen digital en escala de grises.

2. Mejora de Imagen

En la Figura 2.2, se ve la representación numérica de dos matrices bidimensionales cuyos valores representan la graduación de los niveles de gris de cada píxel de las imágenes digitales que aparecen a la derecha.

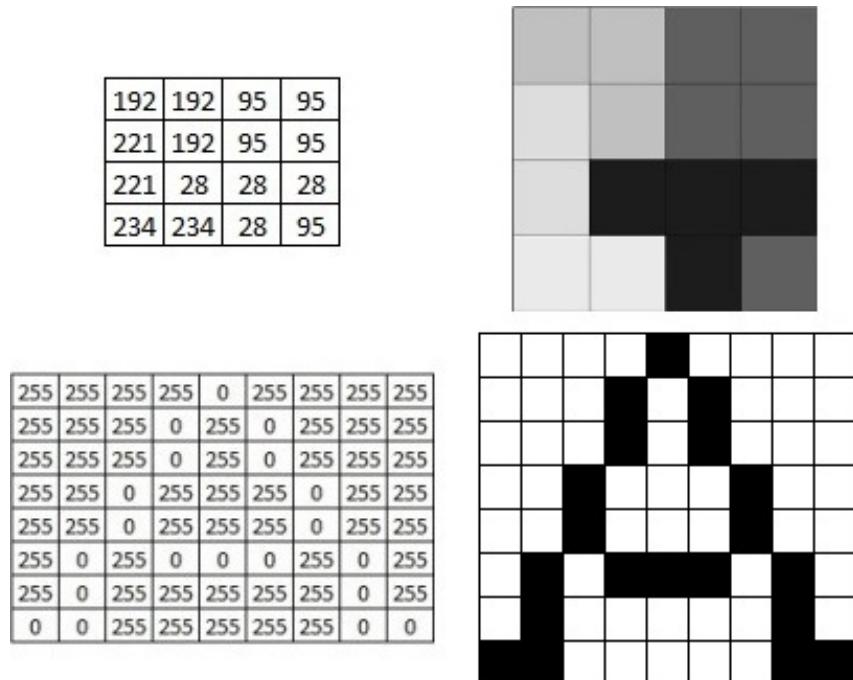


Figura 2.2: Matrices numéricas y matrices pintadas con el nivel de gris correspondiente.

Nuestro trabajo se enfoca a imágenes en escala de grises. El gris es una denominación común a un conjunto de colores intermedios acromáticos comprendidos entre una luminosidad máxima (blanco) y una luminosidad nula (negro) [Rus10; dLRae14; Dic14]. La escala de grises es un rango de niveles de gris donde cada nivel equivale a una graduación de gris comprendido entre el negro y el blanco [Rus10]. La cantidad de niveles de gris de la escala depende de la cantidad de bits tomados para representar un nivel gris. Un bit es la unidad de medida mínima de información empleada en el campo de la computación y la información digital [Gis00].

En la Figura 2.3, se ven algunos ejemplos de escalas de grises en base a la cantidad de bits tomados para representar un nivel de gris. Con 1 bit, se puede representar 2 niveles, el 0 (negro) y el 1 (blanco), con lo que solo se pueden formar imágenes monocromáticas. Con 2, 3, 4, 5, 6 y 7 bits se pueden representar 4, 8, 16, 32, 64 y 128 niveles de gris respectivamente. La escala más utilizada y que se utiliza en este trabajo es la de 8 bits con lo que se puede representar 256 niveles de gris distintos que van del 0 (negro) al 255 (blanco). También se puede utilizar una escala más amplia como por ejemplo de 16 bits que contiene 65.536 niveles de gris para alcanzar un mayor grado de precisión en las imágenes.

2. Mejora de Imagen

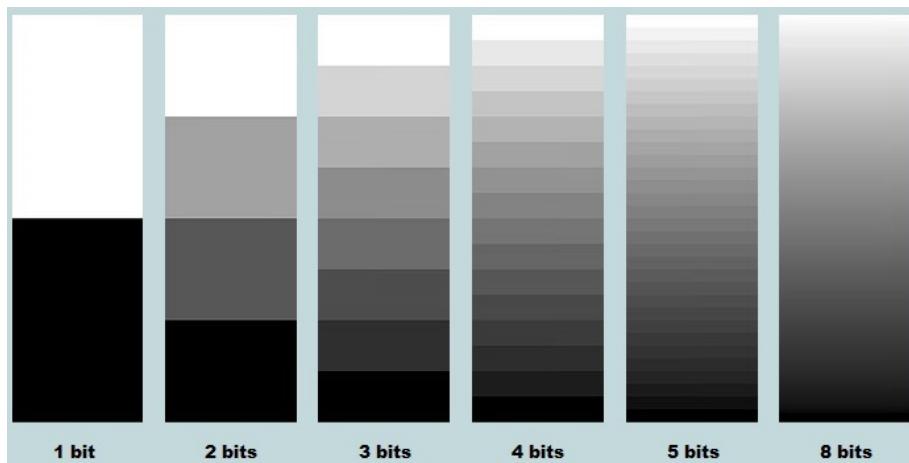


Figura 2.3: Escalas de grises.

Ahora bien, todo lo que podemos ver es básicamente información. Todo lo capturado en una imagen contiene información que puede ser muy importante para aplicaciones científicas o de la vida real. Una de éstas aplicaciones es la autenticación biométrica o biometría informática, que es el estudio de técnicas para la identificación de personas [JRP04]. Los lectores biométricos son aparatos que identifican personas a través de escáneres o cámaras con el objetivo de permitirles o negarles el acceso a determinados lugares. Las cámaras de vigilancia también están estrechamente relacionadas a la identificación de personas. Estas cámaras capturan imágenes y videos con el objetivo de poder identificar personas en caso de asaltos o disturbios a través del reconocimiento facial. De este modo, se puede identificar a una persona exitosamente, procesando imágenes digitales de patrones únicos tales como: huellas dactilares, iris ocular, rostro, venas de los dedos y venas de la palma de la mano [NG11; ASN13; Han11; SM15; OHBL10; FKB07; TMM13; DHLB14].

Otra aplicación muy importante es el procesamiento de imágenes médicas como las mamografías, tomografías y otras, como un soporte para la medicina [SRAP11; MR13; MM13]. Para dar un diagnóstico médico, el profesional analiza las imágenes médicas utilizando sus conocimientos profesionales. Pero en muchas ocasiones, las imágenes médicas no poseen una buena calidad de visualización debido a la adición excesiva de ruido durante la creación de la imagen, lo que dificulta al profesional a hacer un buen análisis de la situación. Por ello, el procesamiento digital de imágenes funciona como una herramienta de soporte ayudando al profesional en la detección de anomalías como un posible tumor, y ayudando a decidir el diagnóstico final.

El procesamiento digital de imágenes se ha convertido en un área fundamental de la computación y está en constante investigación y evolución con el fin de ofrecer técnicas de mejora de imágenes para éstas y muchas otras aplicaciones importantes.

2.2. Mejora de imagen

Una imagen puede estar asociada a problemas que afectan la calidad de visualización y comprometen la información sensible contenida en ella. Estos problemas pueden ser: aparición de ruido durante la captura, amplificación de ruido durante la conversión de una imagen a digital, imagen borrosa a causa del movimiento del objetivo o de la cámara durante la captura, imagen oscura por falta de iluminación o mala exposición a la luz, imagen borrosa a causa de utilizar un dispositivo no apropiado para el caso (para capturar una imagen a una distancia milimétrica, se necesitan cámaras profesionales), y en el caso de imágenes médicas, los fenómenos físicos utilizados para crear las imágenes sufren principalmente de la adición excesiva de ruido.

Debido a la importancia de la información contenida en una imagen, lo ideal sería que la captura de una imagen digital, una fotografía o la conversión analógica-digital de una fotografía sea lo más perfecta posible. Sin embargo, los factores que mencionamos anteriormente, influyen a que esto sea bastante difícil.

Por estas razones, muchas imágenes necesitan de una mejora previa para poder ser visualizadas correctamente. La *Mejora de Imagen* consiste en un conjunto de técnicas que sirven para modificar la estructura de una imagen con el objetivo de obtener una mejora en la calidad de visualización. Además, la imagen mejorada puede ser más útil que la imagen original como entrada para otras aplicaciones de más alto nivel tales como la detección de características, reconocimiento de patrones, segmentación de imágenes, registro de imágenes y otras [VS11; PTS⁺13]. En ocasiones se necesita de un preprocesamiento que elimine la mayor cantidad de imperfecciones de tal manera a facilitar el análisis y la extracción de información. Gracias a esto, el procesamiento digital de imágenes se ha convertido en un área fundamental de la computación y de la visión por computador. La mejora de imagen es uno de los procesos fundamentales del área.

La iluminación del ambiente durante la captura de una imagen es uno de los factores más importantes que determinan su calidad de visualización. La correcta o incorrecta exposición a la luz puede ser crítica durante la captura para que podamos visualizar correctamente todos los detalles de la escena. Una característica relacionada a la exposición de la luz es el contraste de una imagen y éste no está exento de problemas. Uno de estos problemas es la pobreza de contraste [SV11]. Nuestro trabajo se concentra en la mejora de contraste, por lo tanto, empezaremos a hablar del concepto de contraste, los problemas relacionados a él y qué implica la mejora del contraste.

2.3. Contraste

El *Contraste* es la diferencia relativa en la intensidad entre un objeto o un punto de su representación gráfica (imagen del objeto) y sus alrededores o fondo, que lo hacen distinguible a la vista [Rus10]. En la Figura 2.4 se ve un ejemplo de contraste. En dicha figura existen dos círculos dentro de un cuadro grande que actúa como fondo. Todos en distintos niveles de gris, de manera a apreciar correctamente el concepto de contraste.

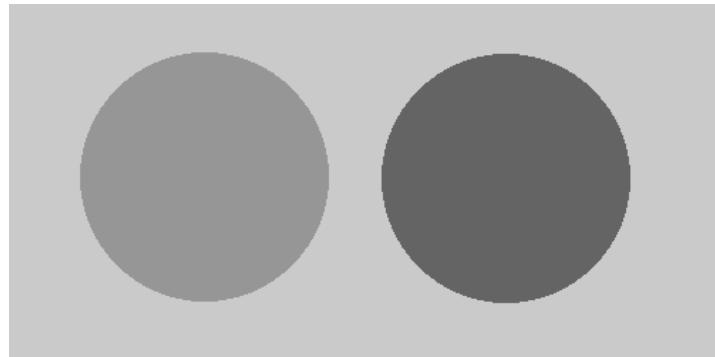


Figura 2.4: Ejemplo de contraste.

Se pueden visualizar los círculos gracias a que existe una diferencia en la intensidad entre ellos (objetos) y su alrededor (fondo). Ahora veamos lo que ocurre en la Figura 2.5, se ha modificado el círculo de la izquierda y se le ha puesto casi el mismo nivel de gris del fondo (dos niveles menos). Por lo tanto, casi no existe una diferencia de intensidad visible entre ellos, haciéndolo casi imperceptible a la vista. Esto quiere decir que no hay un buen contraste entre el fondo y dicho objeto. Sin embargo, el otro círculo permaneció intacto, por lo que podemos ver que existe la diferencia de intensidad entre él y su fondo. Esta diferencia perceptible es lo que se define como contraste.



Figura 2.5: Ejemplo de contraste casi nulo.

Volviendo a la Figura 2.4, la diferencia de intensidad entre el círculo más oscuro y el fondo es mayor y por lo tanto tiene más contraste que el otro y es más fácil verlo. A medida que se incrementa la diferencia de intensidad entre un objeto y el fondo, el objeto se tornará más perceptible con respecto a lo que le rodea y tendrá mayor contraste hasta alcanzar la máxima diferencia de intensidad posible o máximo contraste. A este umbral se le llama rango dinámico o proporción de contraste [Rus10].

El grado de iluminación durante una captura, es un factor determinante para que

2. Mejora de Imagen

en la imagen capturada se puedan distinguir correctamente todos los detalles. Una iluminación pobre resulta en zonas oscuras que ocultan detalles de la escena. Los tonos de colores de los objetos también juegan un papel fundamental. Si los objetos y el fondo tienen tonos muy similares o iguales, será más difícil distinguir correctamente los objetos del fondo, ya que la diferencia de intensidad será muy reducida o nula. Un ejemplo claro de esto vimos en la Figura 2.5 donde uno de los círculos tiene casi el mismo tono que el fondo y por ello no podemos apreciarlo. Esto influencia fuertemente al bajo contraste.

El bajo contraste también puede ser influenciado por factores externos como la niebla, el humo o el vapor presentes durante la captura de una imagen. Además, una iluminación suave en el ambiente puede evitar que se formen sombras de contraste, es decir, la cantidad de luz que hay en la sombra es igual o casi igual a la cantidad que hay en el lado iluminado, lo que hace que las sombras entre objetos sean muy suaves y no ayuden a distinguir correctamente los objetos.

Para el caso de las imágenes médicas, el contraste es un tema más complejo. En una imagen médica, el contraste se forma en base a las propiedades de los tejidos del cuerpo humano y a la técnica de imagen utilizada (fenómenos físicos utilizados). El espesor y la densidad de los tejidos y partes del cuerpo como músculos, huesos, cartílagos, tejidos grasos, son propiedades que afectan a la penetración de los rayos y la formación de la imagen [Bus10]. Por ejemplo, en una radiografía o una mamografía, la energía utilizada en kilovoltios (kV) determinará el contraste final. A mayor kV la penetración de los rayos X será mayor y la radiación será menor, lo que producirá una imagen con bajo contraste. A menor kV la penetración será menor pero la radiación a la que se somete el paciente será mayor, lo que producirá una imagen con mayor contraste. Los demás fenómenos físicos utilizados en la generación de imágenes médicas también se ven afectados por las propiedades de los tejidos del cuerpo. A esto se suman la adición de ruidos y artefactos durante la construcción de las imágenes.

En la Figura 2.6 se puede ver una imagen con iluminación insuficiente, en la Figura 2.7 se ve una imagen con bajo contraste y por último en la Figura 2.8 se ve la diferencia de contraste en una imagen médica dependiendo de la energía utilizada.



Figura 2.6: Iluminación insuficiente. Detalles ocultos por la oscuridad.

2. Mejora de Imagen

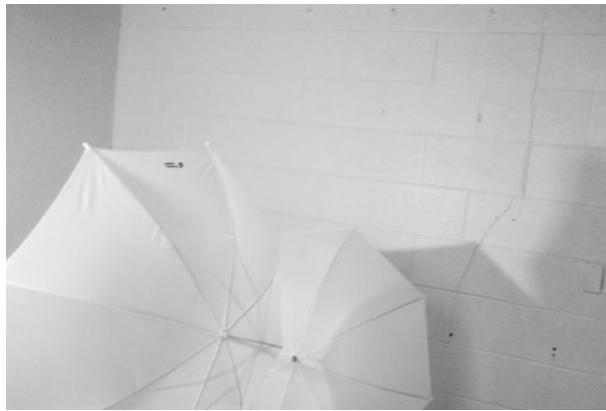


Figura 2.7: Bajo Contraste. Tonos de colores muy semejantes.

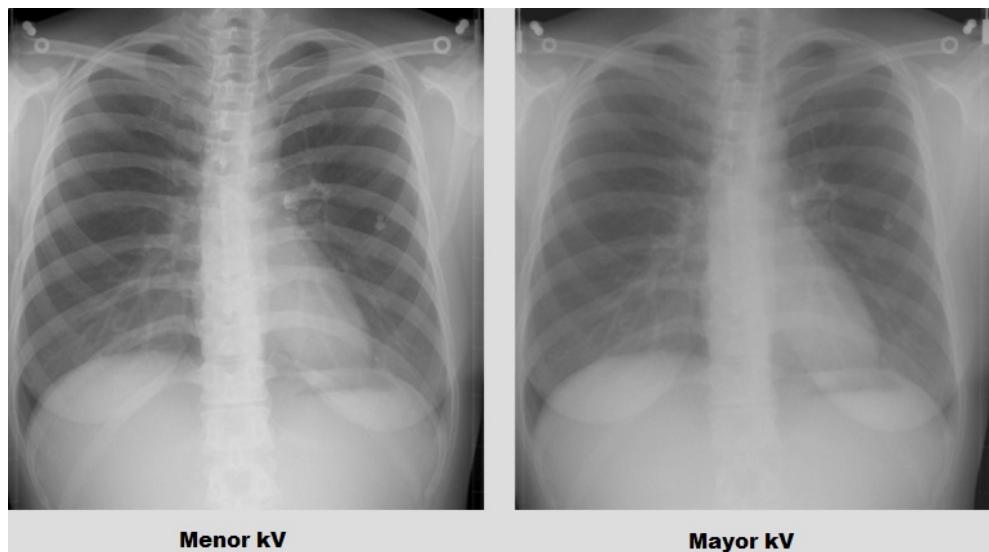


Figura 2.8: Imagen Médica. Radiografía. A mayor kV, menor contraste.

En estos casos, no se pueden apreciar correctamente todos los detalles de la imagen, por lo que necesitamos manipular el contraste de tal manera a poder resaltar mejor los detalles o incluso descubrir detalles ocultos detrás de zonas oscuras. Estas imágenes tienen muy bajo rango dinámico de intensidad debido a la iluminación insuficiente, por lo que necesitan ser procesadas antes de ser visualizadas correctamente [CJB13].

Ahora, ¿Cómo se mejora el contraste de una imagen? Para responder esta pregunta se debe establecer qué es la mejora de contraste y hablar de algunas técnicas para conseguirlo.

2.4. Mejora de contraste

Es un proceso que consiste en modificar los valores de los niveles de gris de los píxeles que componen la imagen de tal forma a obtener una mejor calidad de apreciación visual y descubrir las zonas ocultas detrás de las sombras y los factores que producen bajo contraste. La idea es modificar los niveles de gris oscuros por unos más claros y viceversa y así aumentar la diferencia de intensidad entre los píxeles. Como ya habíamos mencionado en el apartado de mejora de imágenes, una imagen con contraste mejorado se puede utilizar como entrada para procesos más complejos tales como el reconocimiento de patrones y la detección de características [KHLF06].

La modificación de contraste se puede hacer a través de dispositivos hardware [HC14] o programas software. La mayoría de las técnicas se basan en software, es decir, algoritmos que aplican una función de transformación sobre la imagen. La mayoría de estos nuevamente, se basan en aplicar la función de transformación directamente sobre el histograma de niveles de gris de la imagen [KHLF06]. Más adelante veremos qué es el histograma de una imagen.

Al modificar los valores de los píxeles estamos alterando la estructura de la imagen y esto puede causar problemas. Uno de los problemas es la distorsión o degradación de la imagen, que se atribuye a una mala reasignación de los niveles de gris, que hacen perder información y perder la visualización correcta de algunos detalles de la imagen. Además existen los problemas de amplificación de ruido y artefactos, que consisten en el aumento en la diferencia de intensidad en el brillo entre dos o más píxeles entre sí que se hace más visible a la vista y no es parte del objeto o escena capturada en la imagen, que puede ser causada por los dispositivos de captura de imágenes. Los artefactos son objetos extraños que no existen en la imagen original y que pueden surgir luego de una modificación inadecuada de la imagen o como una amplificación grave de ruido [KWH⁺13].

Para evitar estos problemas, los algoritmos de mejora de contraste se utilizan en conjunto con métricas de evaluación que determinan la calidad del resultado. Métricas que miden la degradación de la imagen, la pérdida de información y la adición de ruidos provocados por una mala modificación de los píxeles.

Una de las características más importantes de la mejora del contraste es que se puede clasificar en dos: el enfoque de mejora global y el enfoque de mejora local. Para saber que enfoque es mejor se debe estudiar que tipo de imágenes serán procesadas o que tipo de interés está motivando la mejora de contraste, por ejemplo, en las imágenes médicas, los detalles locales son más importantes que la imagen completa. De esta manera, empecemos a hablar de los enfoques de mejora de contraste.

2.4.1. Mejora de contraste global

El enfoque de mejora global es fácil de entender y de implementar. La idea radica en aplicar una función de transformación que modifica un píxel en función a todos los demás píxeles de la imagen. Dicho de otra manera, cuando la función toma un píxel para calcular su nuevo valor de intensidad, toma en cuenta todos los valores de intensidad

del resto de píxeles que componen la imagen [LLK13]. De este modo, todos los niveles de gris de la imagen influyen en el nuevo valor que tendrá el píxel procesado. La función de transformación no toma niveles de gris ausentes en la imagen, pero el resultado que arroja sí puede tomar un nivel de gris que en la imagen original no aparece. Este enfoque puede ser implementado con simplicidad y puede ser rápido en ejecución, pero debido a las características de la estructura de la imagen, puede no dar el mejor resultado.

En muchas imágenes se necesita mejorar el contraste en su totalidad. Pero en ocasiones, solo algunas zonas de la imagen necesitan de una mejora de contraste significativa. Este escenario es bastante común y una función global podría no ser muy útil debido a que al aplicar la función global podemos alterar demás el contraste en zonas de la imagen donde no se necesitaba una mejora significativa. Esto puede causar una distorsión de la imagen y dificultar la calidad de visualización en esas zonas. Esto normalmente se conoce como sobre mejora. También puede haber pérdida de información en detalles pequeños y amplificación de ruido innecesario [KWH⁺13].

Con esta problemática es difícil obtener una función de transformación adecuada para la imagen y para cualquier tipo de imagen a la que se aplique. Entonces, es hora de hablar de la mejora de contraste local o por zonas, es decir, donde la imagen se divide en zonas y la función de transformación se localiza y procesa en cada una de las zonas independientemente unas de otras.

2.4.2. Mejora de contraste local

La idea principal de la mejora de contraste a nivel local es dividir la imagen en porciones y aplicar la función de transformación a cada porción independientemente. Esto implica que al aplicar la función sobre un píxel de la porción o sobre la porción completa, solo se tomarán en cuenta los píxeles de dicha porción y por lo tanto solo los valores de los niveles de gris que se encuentran allí. De esta forma, cada porción es como si fuera una imagen aparte y se mejora el contraste en cada una de ellas independientemente. Luego se unen las partes mejoradas a través de alguna técnica de unión. En la Figura 2.9 se muestra un ejemplo de división de una imagen en bloques.



Figura 2.9: División en bloques de 8x8 píxeles.

Mediante estas divisiones se consigue una reasignación de los niveles de gris más homogénea y más acorde al contenido de la porción y se trata de evitar los problemas mencionados del enfoque global [MLKL13].

Existen varias formas de dividir la imagen en partes. Una forma simple y clásica es dividir la imagen en subimágenes más pequeñas normalmente llamadas bloques o ventanas, de forma rectangular y de tamaño fijo $m \times n$ donde normalmente m y n son iguales como vimos en la Figura 2.9.

Otra forma muy utilizada es construir el histograma de niveles de gris de la imagen y luego dividir el histograma en partes. Luego se aplica una técnica llamada ecualización del histograma a cada parte. Esta técnica la explicaremos más adelante. También se puede construir el histograma de cada porción y ecualizar cada histograma para al final unir los resultados.

La forma más sencilla del enfoque local es procesar la imagen píxel por píxel secuencialmente tomando en cuenta solo al vecindario directo de píxeles para formar un pequeño bloque que se desliza a través de todos los píxeles de la imagen, donde se procesa solo el píxel del centro [MLKL13; BSA07; HKNM09].

Si bien el enfoque de mejora de contraste local puede subsanar los inconvenientes que se dan en el enfoque de mejora global, la mejora local tiene dos desventajas muy importantes: primero, demanda un mayor costo computacional (recursos de hardware y tiempo de ejecución) debido a que en lugar de ejecutar la función de transformación una sola vez a la imagen completa, se ejecuta por la cantidad de bloques en que se dividió la imagen, y en el caso del bloque deslizante, se ejecuta por la cantidad de píxeles de la imagen. Y segundo, posee una mayor complejidad, ya que se necesita añadir una proceso más, para unir los bloques procesados y formar la imagen mejorada final.

La mejora de contraste global es más simple y es muy utilizada debido a sus ventajas en mayor velocidad de ejecución y menor complejidad [LLK13]. Dicho esto, hablaremos a partir de ahora del histograma de niveles de gris y la ecualización del histograma, que es la técnica más utilizada tanto para la mejora global como la local debido a su simplicidad y rapidez y es la base de nuestro trabajo.

2.5. Histograma de niveles de gris

El *Histograma* de niveles de gris de una imagen se define como la representación gráfica de la distribución de frecuencias de niveles de gris de la imagen, es decir, la cantidad de píxeles que posee cada nivel de gris del rango [SMG11]. En la Figura 2.10 vemos un ejemplo de histograma, donde podemos ver que el eje de abscisas representa cada uno de los niveles de gris disponibles (256 niveles) y el eje de ordenadas representa la cantidad de píxeles para cada nivel de gris. La suma de las cantidades de cada nivel de gris es igual a la cantidad total de píxeles de la imagen.

El histograma se puede expresar como sigue [KWH⁺13]:

$$\mathcal{H} = \{h_k\} \quad \text{siendo} \quad \sum_{k=1}^L h_k = Z \quad (2.1)$$

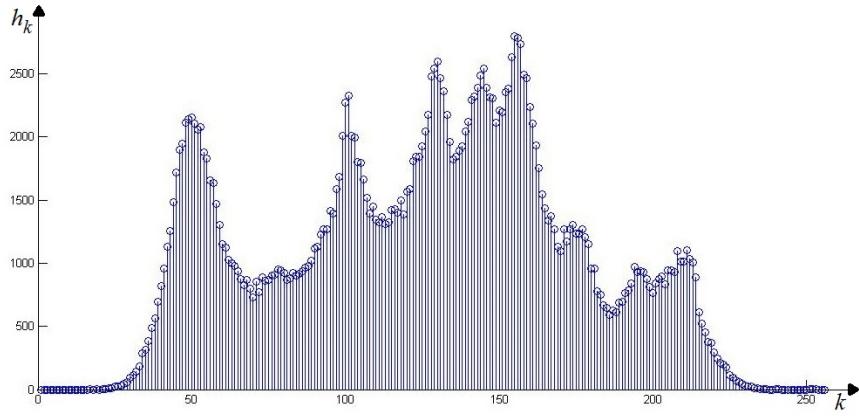


Figura 2.10: Histograma de niveles de gris.

donde:

- \mathcal{H} es el histograma;
- h_k es la cantidad de píxeles que posee el k -ésimo nivel de gris del histograma;
- L es la cantidad total de niveles de gris disponibles, 256 niveles disponibles;
- Z es la cantidad total de píxeles de la imagen;

Una imagen ideal debería poseer la misma cantidad de píxeles en cada nivel de gris del rango [SMG11], es decir, tiene un histograma uniforme como se ve en la Figura 2.11.

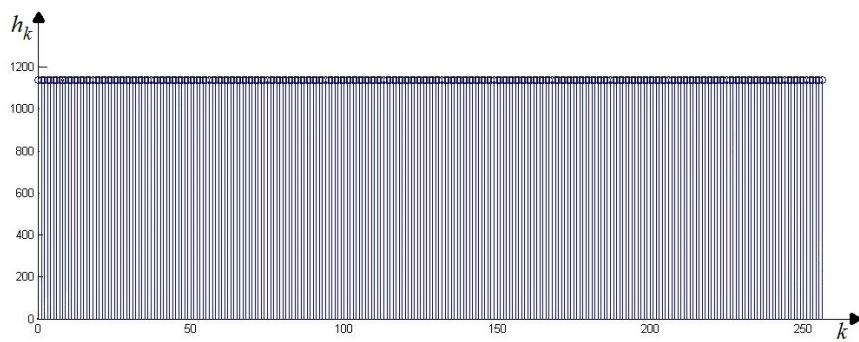


Figura 2.11: Histograma uniforme.

Difícilmente una imagen tendrá un histograma uniforme. El histograma dependerá de los tonos de intensidad existentes en la escena capturada. Es más, en las imágenes

médicas como las mamografías y radiografías, una gran parte de los píxeles se encuentran en los niveles de gris de los extremos del rango, los más oscuros y los más claros, y una menor parte se reparte en el resto de los niveles del rango. En estas imágenes con histogramas muy concentrados no se están utilizando de la mejor manera los niveles de gris disponibles.

Mejorar el contraste de una imagen implica utilizar de la mejor manera el rango de niveles de gris y con ello conseguir una mejor calidad de visualización [KWH⁺13]. Esto significa que debemos modificar el histograma redistribuyendo los píxeles a lo largo de él con el fin de obtener el histograma uniforme. Modificar el histograma tiene la ventaja de ofrecer una implementación sencilla y efectiva. Además, el histograma es simple de calcular en software y también son económicos en hardware, lo que lo hace una herramienta muy popular para el procesamiento de imágenes en tiempo real [VS11].

Se pueden aplicar varias funciones de transformación al histograma de una imagen, pero existe un proceso en especial llamado ecualización del histograma, que es el proceso más utilizado y extendido en el campo de la mejora de contraste gracias a su simplicidad, velocidad de ejecución y efectividad [LLK13]. A continuación hablaremos de esta técnica.

2.5.1. Ecualización clásica del histograma

Muchas imágenes tienen histogramas muy dispersos y concentrados. Por ello, transformarlos en el histograma uniforme causa una distorsión o una sobre mejora de contraste que afectan considerablemente a la correcta visualización de la misma [PTS⁺13].

La *Ecualización del histograma* (*HE* por sus siglas en inglés Histogram Equalization), consiste en una función de transformación que redistribuye los píxeles equitativamente a través de todo el histograma como se muestra en la Figura 2.12.e

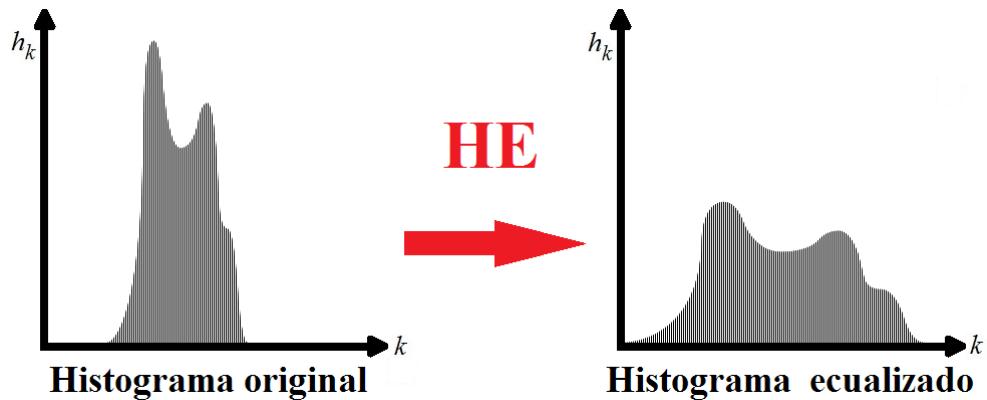


Figura 2.12: Redistribución de píxeles a lo largo del Histograma.

La idea radica en reducir la cantidad de píxeles de los niveles de gris con picos altos y reasignar estos píxeles de forma equitativa al resto del histograma de forma a que

el histograma resultante se aproxime a una distribución uniforme [MLKL13]. Al hacer esto estamos tratando de utilizar de una mejor manera los niveles de gris disponibles sin distorsionar la imagen de forma crítica.

En la Ecualización del histograma, para calcular los nuevos valores de cada píxel primero se define la Función de Distribución Acumulativa (*FDA*) de una imagen en escala de grises como se muestra en la expresión (2.2).

$$FDA_I(k) = \sum_{k=1}^L \frac{h_k}{Z} \quad (2.2)$$

donde:

- I es la imagen de entrada.
- k representa el k -ésimo nivel de gris del histograma.
- L es la cantidad de grises disponibles.
- Z es la cantidad total de píxeles de la imagen I .
- $\frac{h_k}{Z}$ es la cantidad de píxeles normalizada del k -ésimo nivel de gris.
- $FDA_I(k)$ es la distribución acumulativa de la imagen I para el k -ésimo nivel de gris.

Definida la expresión 2.2 para hallar la distribución acumulativa de la imagen de entrada I , definimos ahora la fórmula de la Ecualización clásica del Histograma como se ve en la expresión (2.3).

$$FDA_T(k') = redondear \left(\frac{FDA_I(k) - FDA_{I_{min}}}{Z - FDA_{I_{min}}} \times (L - 1) \right) \quad (2.3)$$

donde:

- I es la imagen de entrada.
- T es la imagen mejorada.
- L es la cantidad de grises disponibles.
- Z es la cantidad total de píxeles de la imagen I y por lo tanto de la imagen T .
- k' es el nuevo nivel de gris para la imagen T al que corresponde el nivel de gris k de la imagen de entrada I , como resultado de la ecualización.
- $FDA_{I_{min}}$ es el mínimo valor de la distribución acumulativa de la imagen I distinto de 0.

Para poder fijar este concepto, a continuación se presenta un ejemplo sencillo de ecualización del histograma: Dada una imagen I de 4×4 píxeles, como se muestra en la siguiente matriz:

52	55	71	71
63	59	55	90
62	59	68	113
63	58	71	122

Definamos:

- Total de píxeles en la imagen: $Z = M \times N = 16$.
- Niveles de gris: $L = 256$.
- El histograma de la imagen I en forma tabular como sigue:

k	52	55	58	59	62	63	68	71	90	113	122
h_k	1	2	1	2	1	2	1	3	1	1	1

- La distribución acumulativa de la imagen I en forma tabular como sigue:

k	52	55	58	59	62	63	68	71	90	113	122
$FDA_I(k)$	1	3	4	6	7	9	10	13	14	15	16

Podemos ver que la distribución acumulativa de la imagen I , termina en 16 píxeles para el nivel de gris 122, por lo que coincide con el número total de píxeles $Z = 16$. El resto de los niveles de gris que no aparecen en la tabla tienen valor 0 por lo que no se incluyen en la tabla para hacer el ejemplo más sencillo de visualizar.

De esta manera, para hallar el nivel de gris k' de la imagen T , que corresponde al nivel de gris $k = 71$ de la imagen I , se reemplazan los valores en la formula 2.3 como se muestra a continuación:

$$FDA_T(71) = redondear \left(\frac{13 - 1}{16 - 1} \times (255) \right) = redondear \left(\frac{12}{15} \times (255) \right) = 204 \quad (2.4)$$

Así, se tiene que en la imagen original I , se deben tomar todos los píxeles cuyo valor de nivel de gris sea 71, y asignarles el nuevo valor de gris resultante de la formula de ecualización del histograma en la imagen resultante T que será el nivel de gris de valor 204. De esta manera, se reasignan todos los píxeles de la imagen I en la imagen mejorada T .

Ahora bien, HE no está libre de inconvenientes. El estiramiento de contraste está limitado a los niveles de gris con mayor frecuencia. Esto causa una pérdida significante

de contraste para los niveles con menor frecuencia [HKNM09]. En esta situación, la ecualización del histograma reasigna los niveles de gris restringiendo el estiramiento de contraste hacia los niveles dominantes, causando una pérdida considerable al resto de los niveles de gris [SBS11].

HE no se centra en los detalles locales de una imagen. Cuando en un nivel de gris o un rango particular se tiene muy poca cantidad de píxeles, las diferencias menores de contraste podrían desaparecer por completo luego de la ecualización, por lo que se pierden detalles de la imagen [SV11; MLKL13].

HE es un proceso del enfoque de mejora global. El histograma se construye en base a todos los píxeles de la imagen y se procesa completamente. Esta técnica, tratando de mejorar la imagen, puede causar efectos no deseables y reducir la calidad de visualización. Sufre de amplificación de ruido como se ve en la Figura 2.13, sobre mejora de imagen como se ve en la Figura 2.14, pérdida de detalles como se ve en la Figura 2.15 y distorsión como se ven en las tres Figuras, causados por una mala redistribución de los píxeles a lo largo del histograma [LLK13; MLKL13; PTS⁺13].

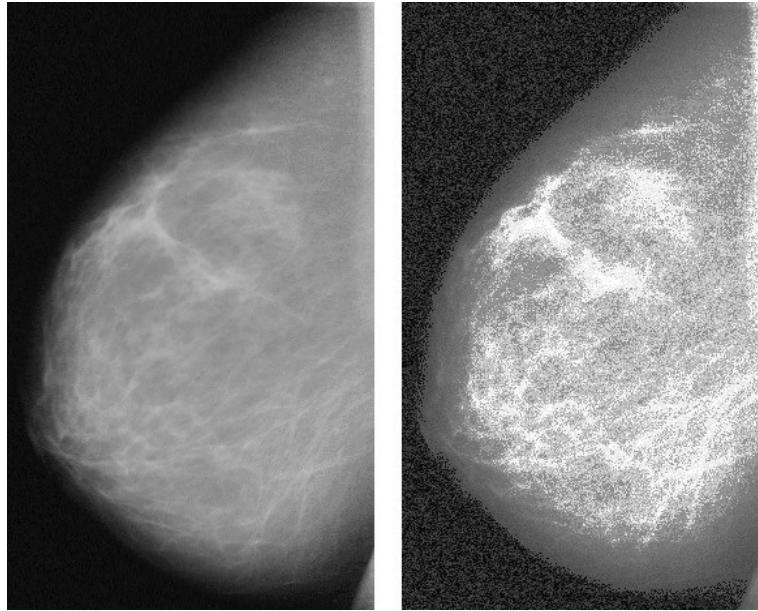


Figura 2.13: Amplificación de ruido en una mamografía.

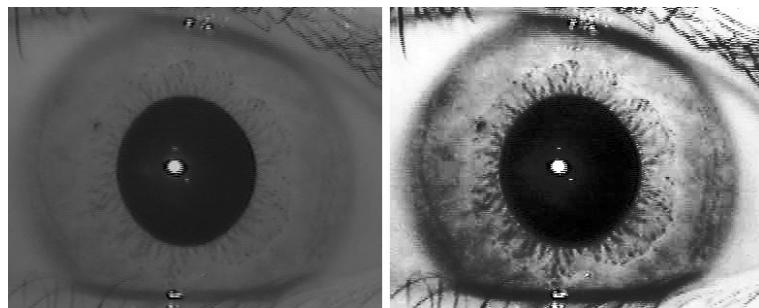


Figura 2.14: Sobre mejora de imagen.



Figura 2.15: Pérdida de detalles y distorsión.

Debido a estos problemas, se han desarrollado técnicas de división del histograma o de la imagen, con lo que surge el concepto de ecualización local del histograma, basado en el enfoque de mejora local. A continuación hablaremos de este concepto.

2.5.2. Ecualización local del histograma

La ecualización local del histograma divide la imagen en bloques y los mejora independientemente. Hay dos formas generales de realizar esto: [LLK13]

- La primera es dividir el histograma global de la imagen en dos o más partes, ecualizar cada parte independientemente y luego redistribuir los píxeles en la matriz de la imagen.
- La segunda es dividir la imagen en dos o más bloques, normalmente muchos bloques, construir el histograma de cada bloque y ecualizarlas como si fueran imágenes independientes y por ultimo unir los bloques ecualizadas con alguna técnica de unión. Estas divisiones se realizan con el fin de preservar el brillo

global de la imagen, reduciendo el cambio brusco de brillo producido por *HE*, y tratar de minimizar los problemas asociados al mismo.

Uno de los métodos de división del histograma más simple se llama Brightness preserving Bi Histogram Equalization (*BBHE*) y fue propuesto en [Kim97]. En este método, el histograma de la imagen de entrada se separa en dos partes tomando como punto de división a la media de niveles de gris y cada parte es ecualizada por separado. De esta manera se consigue una mejora preservación de brillo.

En [WCZ99], se propone un método muy similar al *BBHE* llamado Dualistic Sub-Image Histogram Equalization (*DSIHE*), donde también se divide el histograma en dos partes, pero en esta ocasión el punto de división es diferente, es la mediana de niveles de gris. Con esta variante se consigue nuevamente una mejora en la preservación del brillo.

Un método más complejo se ha propuesto en [KKH01], y se llama Block-overlapped Histogram Equalization. En este método, un bloque de tamaño $m \times n$ se desliza secuencialmente a través de todos los píxeles de la imagen procesando un solo píxel, que es tomado como centro del bloque. Entonces, se ecualiza el histograma del bloque y solo se reasigna el nivel de gris del píxel del centro del bloque. El proceso es costoso debido a que se ejecuta por cada píxel de la imagen. Una ventaja de este método es que se puede elegir el tamaño del bloque, para hacer que la mejora sea más fina a nivel de detalles muy pequeños. Cuanto más fino se desee más costoso será en tiempo de ejecución. En este trabajo se utiliza una técnica de mejora de contraste local llamada *CLAHE* [Zui94], basada en la división y ecualización de la imagen en bloques. A continuación hablaremos de ella.

2.6. Contrast Limited Adaptive Histogram Equalization (CLAHE)

Es una técnica de mejora de contraste basada en la división de la imagen en bloques y la ecualización del histograma de cada bloque de la imagen de forma independiente. Fue diseñado pensando en imágenes médicas y ha demostrado ser satisfactorio para mejorar imágenes de bajo contraste [SMG11; MR13]. *CLAHE* es una mejora del Adaptive Histogram Equalization (*AHE*) [KLW76; PAA⁺87; ZCF⁺89; KJ91], que agrega una manera de limitar la mejora de contraste para evitar la sobre mejora y la amplificación de ruido producida por *AHE*. Para entender el *CLAHE*, primero se debe entender como funciona el algoritmo *AHE*. A continuación, se explica el *AHE*, y luego las diferencias introducidas por *CLAHE*.

2.6.1. Adaptive Histogram Equalization (AHE)

El comportamiento natural del ojo humano es el de juzgar la información contenida en una imagen basándose en los componentes locales de la misma. Entonces, es relevante realizar una mejora de contraste enfocado a regiones locales [LLK13]. El desarrollo de

AHE se remonta a [KLW76], donde se aplicaron sus primeras nociones, para mejorar detalles que se muestran en radares y cabinas de dispositivos militares. En *AHE*, se optimiza el contraste dentro de regiones rectangulares de la imagen, llamadas *regiones contextuales* [Zui94], con dimensiones de región definidas como $(\mathcal{R}_x, \mathcal{R}_y)$. Luego, la ecualización del histograma se realiza en cada región contextual de forma independiente. En la Figura 2.16 se muestra una región contextual de tamaño $m \times m$.

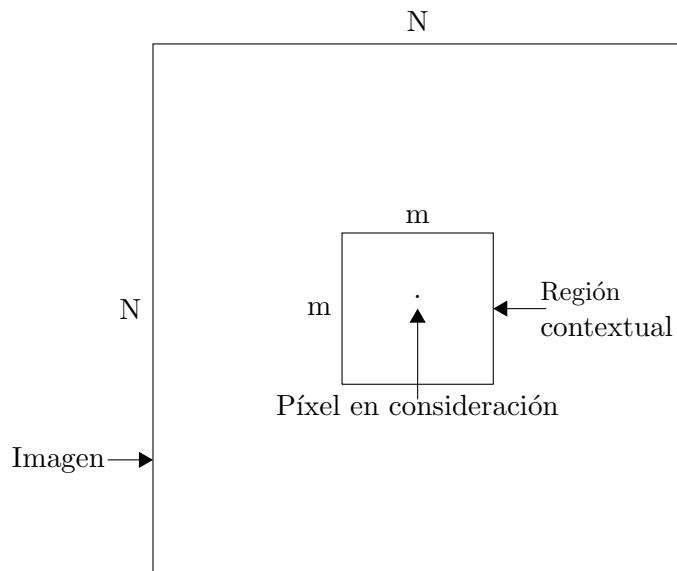


Figura 2.16: Diagrama de una región contextual del *AHE*.

En la implementación básica del algoritmo, se compara y se realiza un mapeo del nivel de intensidad de cada píxel respecto a los valores de intensidad de los píxeles que conforman la región contextual. Luego se asigna un nuevo valor de intensidad al píxel de acuerdo a la función de mapeo [KJ91]. Ésta versión adolece de ciertas limitaciones, las cuales se detallan en la sección siguiente. En [PAA⁺87] se proponen mejoras al algoritmo básico para aumentar la velocidad de procesamiento realizando los mapeos de intensidad de niveles de gris solamente para un grupo de muestra de píxeles, los cuales se utilizan luego para realizar una interpolación de los píxeles no mapeados de la imagen utilizando los píxeles mapeados que lo rodean, logrando así la mejora de velocidad de procesamiento deseada. Para ver más detalles acerca del método de interpolación ver [ZCF⁺89]. En [Zui94], la función de mapeo utilizada para la transformación se basa en la ecualización del histograma de cada región contextual, la cual se aplica posteriormente en *CLAHE*; y luego se procede a corregir posibles inconsistencias visuales en las fronteras de cada región contextual, utilizando un esquema de interpolación bilineal (véase la Figura 2.17). En los bordes de la imagen se utilizan interpolaciones lineales, y en las esquinas se utilizan funciones de transformación basadas en un solo punto de referencia [Zui94]. El pseudocódigo del algoritmo se muestra en el Algoritmo 1.

Algoritmo 1 Pseudocódigo del algoritmo de *AHE*.

Entrada: *ImagenOriginal*, Región contextual ($\mathcal{R}_x, \mathcal{R}_y$)

- 1: Dividir *ImagenOriginal* en regiones contextuales de tamaño ($\mathcal{R}_x, \mathcal{R}_y$)
- 2: **para** Cada Región Contextual **hacer**
- 3: Realizar la Ecualización del Histograma utilizando los píxeles contenidos en la Región Contextual
- 4: **fin para**
- 5: **para** Cada Región Contextual **hacer**
- 6: Realizar interpolación en los píxeles de los bordes para evitar inconsistencias.
- 7: **fin para**

Salida: *ImagenResultado*

2.6.2. Limitaciones del algoritmo *AHE*

El *AHE* sufre de las siguientes limitaciones: tiempo computacional elevado, regiones contextuales irregulares en los puntos cercanos a los bordes de la imagen, computación excesiva, sobre mejora y amplificación de ruido [Zui94; KJ91].

Si se considera una región contextual de tamaño $m \times m$ y una imagen de tamaño $N \times N$, entonces se necesitan $m^2 \times N^2$ comparaciones para obtener el resultado de la ecualización.

Se ha reportado que el algoritmo *AHE* puede amplificar el ruido presente en la imagen, haciendo que el resultado de la ecualización resulte insatisfactorio [Zui94].

Un problema de los algoritmos de enfoque local como el *AHE* y el *CLAHE*, es que luego de procesar cada bloque de la imagen, queda una diferencia visible entre ellos, causados por la ecualización separada como se muestra en la Figura 2.17. Para subsanar este problema, una función de interpolación bilineal se ejecuta en las regiones contextuales para corregir las inconsistencias, como se mencionó en la sección anterior.



Figura 2.17: Diferencias visibles de la ecualización por bloques.

2.6.3. La idea introducida en *CLAHE*

AHE está asociado a problemas de amplificación de ruido, los cuales son particularmente visibles en áreas donde hay niveles de gris relativamente homogéneos [VS11; MR13]. Éstas regiones tienen como característica principal que generan picos en el histograma de niveles de gris, debido a que muchos píxeles con niveles de gris similares aparecen en dichas regiones. Éste problema se puede resolver limitando la mejora del contraste en dichas áreas [Zui94].

La idea propuesta por el algoritmo *CLAHE* para subsanar este problema es el de limitar la cantidad de píxeles que puede alcanzar determinado nivel de gris, lo que corrige los picos elevados asociados a las regiones de la imagen donde hay niveles de gris homogéneos, además de limitar la pendiente producida por los mismos en la Función de Distribución Acumulativa del Histograma (*FDA*), y por tanto se reducen los picos asociados a la amplificación de ruido en la imagen [Zui94; MLKL13]. Los píxeles se redistribuyen de manera a recortar picos, y dicha distribución se hace de forma equitativa a través del histograma de niveles de gris de la región contextual como se muestra en la Figura 2.18.

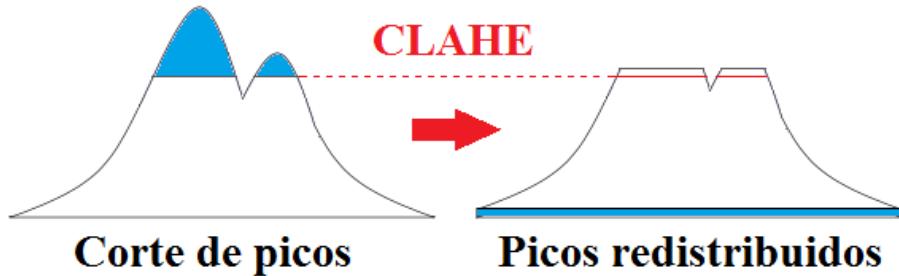


Figura 2.18: Redistribución de píxeles a lo largo del histograma de la región contextual.

Este límite a los picos se consigue con un parámetro del *CLAHE* llamado Clip Limit. Se puede definir el Clip Limit \mathcal{C} como un factor asociado al promedio del contenido del histograma y a la región contextual definida. Si se define un \mathcal{C} bajo, la pendiente en los histogramas locales generados será también baja, que resultará en poca mejora de contraste. Si se define un \mathcal{C} alto, estaríamos evitando la redistribución de los píxeles que aparecen en los picos del Histograma, lo que resulta ser equivalente a la mejora del *AHE*.

El pseudocódigo del *CLAHE* se presenta en el Algoritmo 2, el cual podemos describir de acuerdo al siguiente ejemplo práctico: la Figura 2.19a muestra una imagen de ejemplo de 512×512 píxeles, las cuales a efectos prácticos se divide en 4 regiones contextuales de acuerdo a la línea 1 del pseudocódigo, como se muestra en la figura 2.19b; nótese que el tamaño de cada región contextual $(\mathcal{R}_x, \mathcal{R}_y)$ será de 256×256 píxeles. Ahora, podemos definir de forma arbitraria el Clip Limit \mathcal{C} con un valor de 10 (siguiendo con el ejemplo) y efectuar las líneas 3 y 4 del pseudocódigo. El Histograma original de la sección 1 de la imagen de ejemplo (la porción de arriba a la izquierda)

se muestra en la Figura 2.20, el Histograma ecualizado de dicha sección realizado en la línea 3 del pseudocódigo se muestra en la Figura 2.21 y el Histograma ecualizado, recortado y redistribuido realizado en la línea 4 del pseudocódigo para la misma sección se muestra en la Figura 2.22. Éste paso se repite para cada una de las regiones contextuales definidas.

Algoritmo 2 Pseudocódigo del *CLAHE*.

Entrada: *ImagenOriginal*, Región contextual $(\mathcal{R}_x, \mathcal{R}_y)$, Clip Limit \mathcal{C}

- 1: Dividir *ImagenOriginal* en regiones contextuales de tamaño $(\mathcal{R}_x, \mathcal{R}_y)$
- 2: **para** Cada Región Contextual **hacer**
- 3: Realizar la Ecualización del Histograma utilizando los píxeles contenidos en la Región Contextual
- 4: Realizar el Recorte del Histograma de acuerdo al límite establecido (Clip Limit \mathcal{C})
- 5: **fin para**
- 6: **para** Cada Región Contextual **hacer**
- 7: Realizar interpolación en los píxeles de los bordes para evitar inconsistencias
- 8: **fin para**

Salida: *ImagenResultado*



Figura 2.19: (a) Imagen original. (b) División en regiones como se indica en la línea 1 del pseudocódigo 2.

En la Figura 2.20 se muestra el histograma original de la sección 1 de la Figura 2.19a, que se construye según la expresión (2.1).

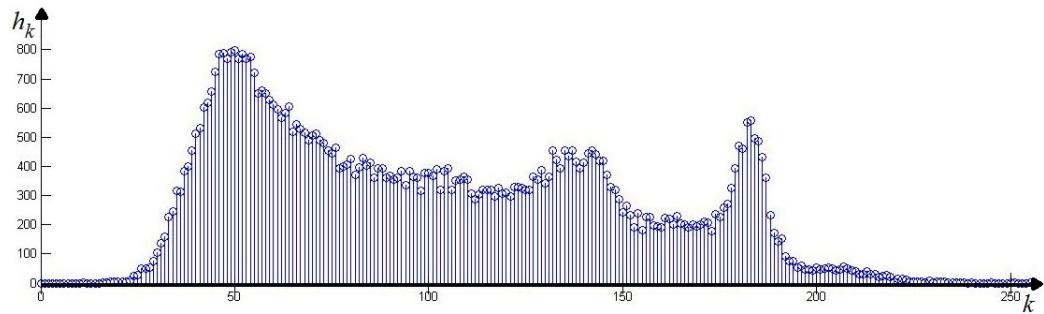


Figura 2.20: Histograma sin ecualizar.

En la Figura 2.21 se muestra el histograma ya ecualizado correspondiente al histograma de la Figura 2.20, que se construye según la fórmula de ecualización clásica del histograma (2.3) [Rus10].

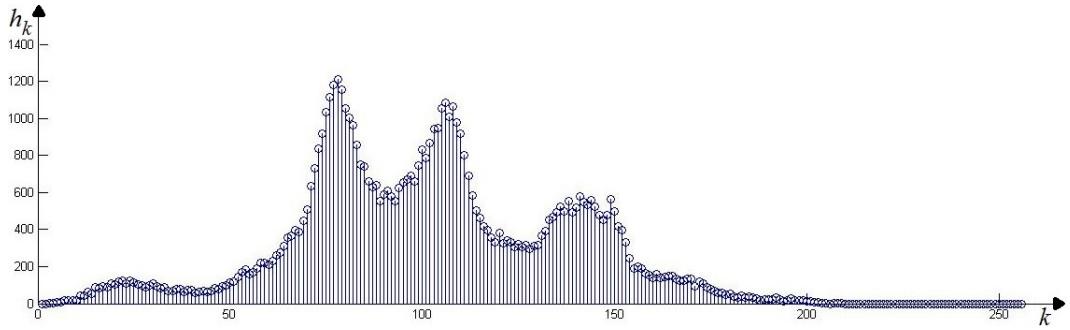


Figura 2.21: Histograma ecualizado.

En la Figura 2.22 se muestra el histograma ya cortado correspondiente al histograma de la Figura 2.20, posterior a la ecualización, según (2.5)

$$h_k = \begin{cases} h_k + 1; & exceso - 1; \quad k = k + 1 \quad \text{si} \quad exceso_0 > L - 1 \\ h_k + 1; & exceso - 1; \quad k = k + \frac{L-1}{exceso_0} \quad \text{si} \quad exceso_0 < L - 1 \end{cases} \quad (2.5)$$

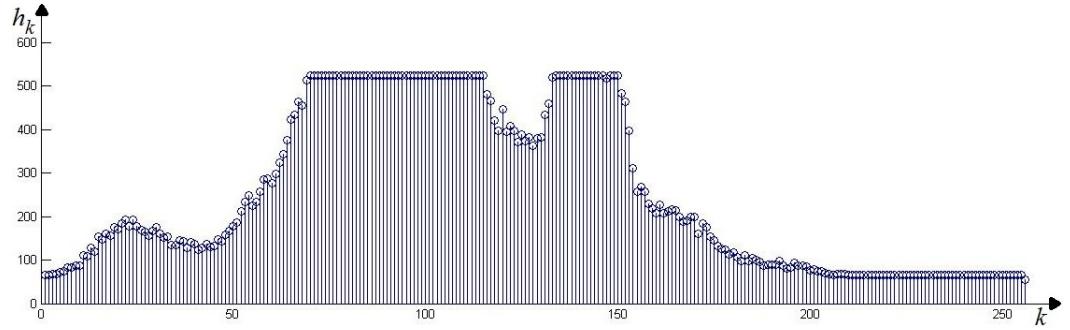


Figura 2.22: Histograma ecualizado, con píxeles recortados y redistribuidos.

En la expresión 2.5, se incrementa h_k , se disminuye la cantidad $exceso$ (píxeles recortados del histograma ecualizado), y se avanza un nivel k dependiendo de si $exceso_0$ (la cantidad inicial de píxeles recortados) es mayor al rango dinámico de niveles de gris ($L - 1$); en caso de que $exceso_0$ sea menor a ($L - 1$), se avanzan $\frac{L-1}{exceso_0}$ posiciones en el histograma. Si aún quedan píxeles por redistribuir, entonces $exceso_0 = exceso$. Éste proceso se repite hasta que $exceso_0$ sea cero.

Luego se utiliza el histograma recortado de manera a construir una función de distribución acumulativa (*FDA*) como se define en la función (2.2) [Rus10]. Entonces, el nuevo nivel de gris k' para un píxel en la coordenada (i, j) de la Figura 2.24a que representa a la imagen mejorada T , se obtiene a partir de la distribución acumulativa del histograma recortado y a partir del nivel de gris original k del píxel en la imagen I de la Figura 2.19a, de acuerdo a la ecualización clásica del histograma (2.3) [Rus10], es decir, $T(i, j) = k'$, donde k' es obtenido a partir del mapeo de $FDA(I)$ para el nivel de gris k correspondiente al pixel $I(i, j)$.

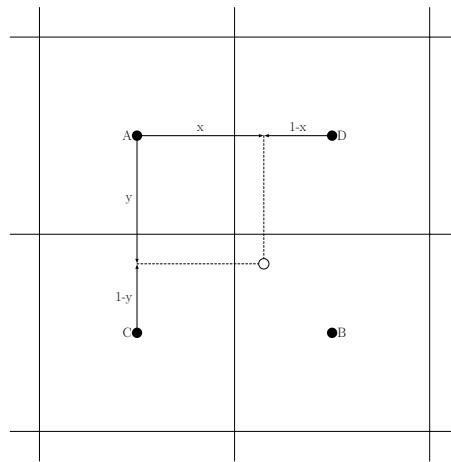


Figura 2.23: Diagrama de interpolación bilineal de un punto m de la imagen.

Como paso siguiente, se necesita realizar una interpolación bilineal en la imagen de manera a corregir las inconsistencias de fronteras que se muestra en la Figura 2.24a. Esto se realiza de la siguiente manera: Se toman los centros de las regiones contextuales generadas y se realiza el paso de la línea 7, para los píxeles que se encuentran dentro el recuadro cuyos vértices son los centros de 4 regiones contextuales como se muestra en la Figura 2.23. En los bordes de la imagen se realiza una interpolación lineal utilizando solamente 2 píxeles centro de las regiones contextuales, y en las esquinas solamente se utiliza un punto [PAA⁺87]. En la Figura 2.23, tomamos 4 centros y los denominamos A , B , C y D , y además definimos que sus niveles de gris luego de la ecualización son $g(A)$, $g(B)$, $g(C)$ y $g(D)$ respectivamente, podemos decir que el nivel de gris del punto a interpolar $g(m)$ se calcula de acuerdo a la función de interpolación de la siguiente manera:

$$g(m) = (1 - y)((1 - x)g(A) + xg(B)) + y((1 - x)g(C) + xg(D)) \quad (2.6)$$

donde x e y son las proyecciones normalizadas de las distancias entre el punto a interpolar y los centros que lo rodean. Nótese que esta función realiza una ponderación entre los centros de las regiones contextuales de acuerdo a la distancia que existe entre los mismos y el punto a interpolar. Finalmente, luego de este proceso se tiene la imagen resultante ecualizada como se muestra en la Figura 2.24b

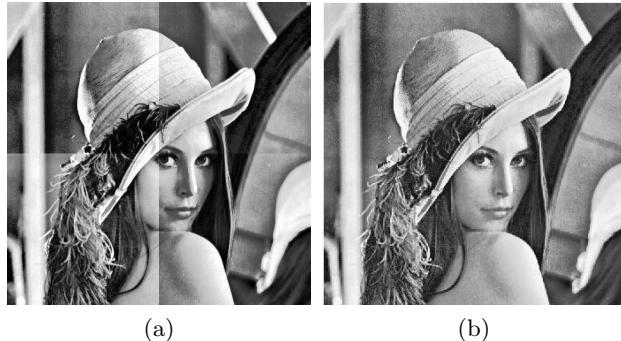


Figura 2.24: (a) Imagen sin interpolar. (b) Imagen interpolada. Resultado final del *CLAHE*.

Ahora que se tiene una noción con detalle suficiente del funcionamiento de *CLAHE*, es importante establecer las diferencias más importantes entre los algoritmos *AHE* y *CLAHE* de modo a entender por qué el algoritmo *CLAHE* es una mejor opción. En la siguiente sección se presentan las diferencias.

2.6.4. Comparación entre *AHE* y *CLAHE*

La principal diferencia entre estos algoritmos es la modificación realizada en *CLAHE* para limitar los picos de histograma que se pueden presentar durante la ecualización. Se podrá notar la consecuencia directa de agregar éste coeficiente al algoritmo de *AHE* al ver las figuras que se muestran en esta sección, además de que se podrá visualizar el motivo por el que se elige el algoritmo *CLAHE* para este trabajo en lugar de *AHE*.

Se presenta una comparación empírica entre los algoritmos *AHE* y *CLAHE* de forma a tener una referencia de las características de ambos algoritmos. La idea de ésta comparación es poder visualizar la diferencia en los resultados que arrojan ambos sobre una misma imagen de modo a visualizar y entender la mejora realizada en *CLAHE*, la cual es que recorta los picos de histograma gracias al coeficiente de Clip Limit \mathcal{C} . Para ello, se utiliza una imagen conocida del estado del arte que se muestra en la Figura 2.25a (Lenna [Len14]). En la Figura 2.25b se muestra el resultado de aplicar *AHE* con un tamaño de región contextual de $(\mathcal{R}_x, \mathcal{R}_y) = (10, 10)$, y en la Figura 2.25c se muestra el resultado de aplicar *CLAHE* utilizando el mismo tamaño de región contextual y $\mathcal{C} = 3$.

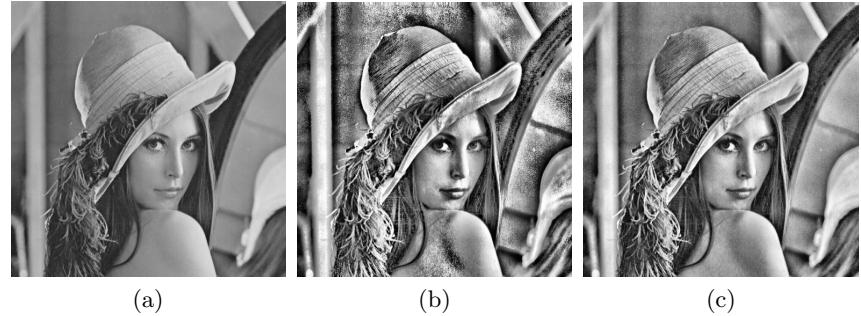


Figura 2.25: (a)Imagen original. (b) Mejorada con *AHE*. (c) Mejorada con *CLAHE*.

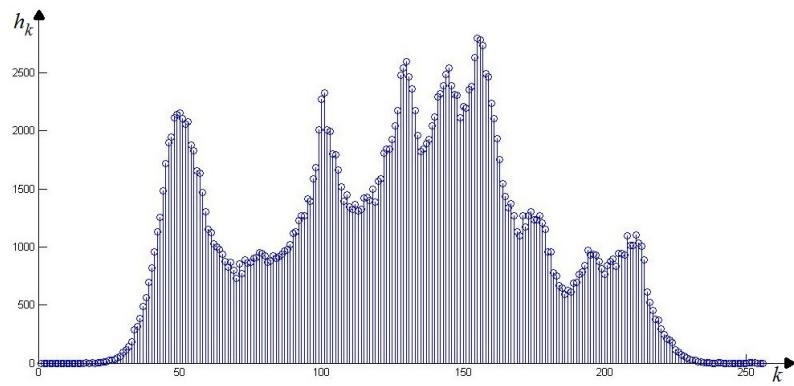


Figura 2.26: Histograma de la Figura 2.25a.

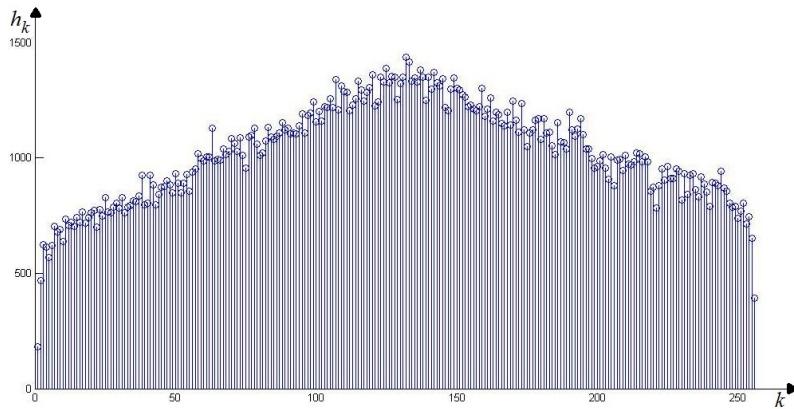


Figura 2.27: Histograma de la Figura 2.25b.

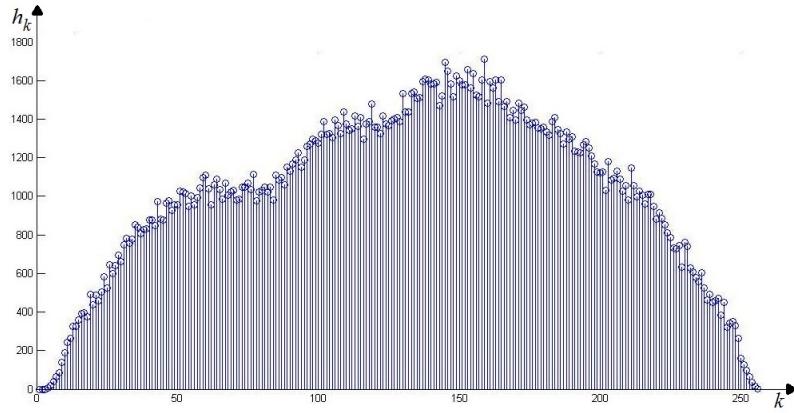


Figura 2.28: Histograma de la Figura 2.25c.

En la Figura 2.25b, se ve el resultado de la aplicación del algoritmo *AHE*. Se hacen visualmente notorios los cambios en el contraste y en la Figura 2.27 se ve que se logró una buena ecualización del histograma respecto al histograma original de la Figura 2.26. Sin embargo, se hace muy evidente la presencia de ruido en la imagen mejorada, particularmente en las regiones con niveles de gris relativamente homogéneos. Esto es una consecuencia de la naturaleza del algoritmo de *AHE*. En la Figura 2.25c, se ve el resultado de la aplicación del algoritmo *CLAHE*. Se puede ver en esta ocasión una mejora de contraste más suave y limitada gracias al factor limitante \mathcal{C} , evitando así la amplificación excesiva de ruido, como pasó con *AHE*. En la Figura 2.28 se puede ver que también se logró una buena ecualización del histograma.



Figura 2.29: (a) Imagen original. (b) Distorsión y amplificación de ruido producido por parámetros no adecuados del *CLAHE*.

Las ventajas principales del algoritmo *CLAHE* son:

- Sus requisitos computacionales son relativamente modestos [Zui94].

- Es de fácil aplicación, debido a que solamente se deben emplear como parámetros: la región contextual ($\mathcal{R}_x, \mathcal{R}_y$), y el coeficiente Clip Limit (\mathcal{C}) [Zui94].
- Provee resultados satisfactorios en imágenes médicas y de bajo contraste [SMG11].

Sin embargo, *CLAHE* requiere de una minuciosa selección de los valores del tamaño de región contextual \mathcal{R} y el Clip Limit \mathcal{C} . Una mala selección de valores podría resultar en amplificación del ruido en la imagen, lo que degrada la calidad de visualización de la misma [PZH⁺98] como se ve en la Figura 2.29b. Esto deriva en una mayor dificultad para realizar un análisis de la información contenida en la imagen mejorada. Además, una mala selección del Clip Limit puede hacer que no exista corte de picos, lo que puede dar como resultado una mejora equivalente a la del *AHE*. De esta manera, el *AHE* se puede ver como un caso particular del *CLAHE*.

Para que el resultado de *CLAHE* sea satisfactorio, los valores de sus parámetros deben ser los óptimos, pero el espacio de búsqueda de los valores para los parámetros es muy grande. Por ello, para encontrar los valores óptimos se necesita un mecanismo que explore el espacio de búsqueda hasta encontrar la solución. En el siguiente capítulo, se explicará el algoritmo que se utiliza en este trabajo para encontrar estos valores.

Capítulo 3

Optimización de Enjambre de Partículas

3.1. Conceptos Básicos

La *Optimización de Enjambre de Partículas* (*PSO* por sus siglas en inglés Particle Swarm Optimization), es una metaheurística que se aplica satisfactoriamente en muchos problemas de optimización y en un amplio rango de campos de investigación científica [Pol08]. La esencia de la metaheurística *PSO* está basada en la inteligencia de enjambre, es decir, el trabajo en conjunto de un grupo de organismos en búsqueda de un objetivo común, haciendo que tenga un comportamiento colectivo [PKB07].

La metaheurística *PSO* sienta sus raíces en una analogía a los grupos de seres vivientes que se ven en la naturaleza, los cuales se organizan para la búsqueda de sus alimentos (parvadas de pájaros, bancos de peces, entre otros). Por tanto, en esta metaheurística se utilizan enfoques de interacción social para la resolución de problemas en lugar de explotar habilidades cognitivas individuales [PKB07]. La idea principal de esta metaheurística se centra en utilizar un grupo de partículas individuales, las cuales exploran a través del amplio espacio de búsqueda del problema que se aborda buscando la solución óptima (en este trabajo, se buscan los valores óptimos para los parámetros del algoritmo *CLAHE*). Las partículas interactúan en base a la mejor solución que va encontrando el enjambre a través del recorrido en el espacio de búsqueda y otros condicionantes como perturbaciones aleatorias, que inciden en el movimiento de las partículas dentro del espacio de búsqueda. Eventualmente el conjunto convergerá hacia la mejor solución que se pueda encontrar según las condiciones de evaluación de mejor solución para el problema específico.

El enfoque del *PSO*, es similar al enfoque de la familia de los Algoritmos Evolutivos (*EA* por sus siglas en inglés Evolutionary Algorithms) [CVVL02] y presenta un enfoque estocástico, por lo que no necesita informaciones previas específicas.

Algunas características atractivas de la metaheurística *PSO* son su facilidad de implementación en cualquier lenguaje de programación y su aplicabilidad a todo tipo de problemas aunque estos sean irregulares, no continuos y no lineales gracias a su

3. Optimización de Enjambre de Partículas

comportamiento estocástico y a que no necesitan de ninguna condición o diferenciación. Otros métodos de optimización clásicos como el algoritmo de optimización *Gradient Descent*, necesita contar con información de gradiente [VDB06; BSA07]. Gracias a esto, se han implementado de forma exitosa numerosas aplicaciones con esta metaheurística.

3.2. Definición y Funcionamiento

Para describir el funcionamiento del *PSO*, se definen los componentes básicos del algoritmo y sus nomenclaturas como se muestra en la Tabla 3.1.

Tabla 3.1: Componentes del algoritmo *PSO*.

Nomenclatura	Descripción
R^D	Espacio de búsqueda del problema donde D representa a la cantidad de variables que posee una partícula y $R^D = R_1 \times R_2 \times \dots \times R_D$
t	Máxima cantidad de iteraciones o ciclos de búsqueda
Ω	Número total de partículas
$X_i^t = (x_{i1}^t, \dots, x_{iD}^t)$	Vector donde se almacenan las posiciones actuales x_i^t de cada i -ésima partícula en cada dimensión D en la iteración t
$V_i^t = (v_{i1}^t, \dots, v_{iD}^t)$	Vector donde se almacenan las velocidades actuales v_i^t de cada i -ésima partícula en cada dimensión D en la iteración t
$P_i = (p_{i1}, \dots, p_{iD})$	Vector donde se almacenan las mejores posiciones individuales encontradas hasta el momento de cada i -ésima partícula en cada dimensión D
p_{gd}	Mejor posición encontrada hasta el momento por el enjambre completo en cada dimensión D
f_i^t	Valor de la función de aptitud (Fitness) de la i -ésima partícula en la iteración t
f_{pi}	Valor de la función de aptitud para la mejor solución individual que ha encontrado la i -ésima partícula hasta el momento
f_g	Valor de la función de aptitud para la mejor solución encontrada en conjunto por el enjambre hasta el momento
ω	Coeficiente de inercia
$U(0, \phi_1)$	Parámetro cognitivo que influye a la partícula a moverse hacia la mejor solución individual. Toma un valor aleatoriamente entre un valor mínimo de 0 y un valor máximo de ϕ_1
$U(0, \phi_2)$	Parámetro social que influye a la partícula a moverse hacia la mejor solución global. Toma un valor aleatoriamente entre un valor mínimo de 0 y un valor máximo de ϕ_2

3. Optimización de Enjambre de Partículas

Cada i -ésima partícula se compone de una posición x_i^t , que es la posición actual en la que se encuentra la partícula en la iteración t durante su movimiento en el espacio de búsqueda R^D , y está almacenada en el vector de posiciones X_i de la partícula.

Cada posición que puede tener una partícula dentro del espacio R^D es una posible solución del problema. De esta manera, la idea principal del algoritmo es que en cada iteración t las partículas cambien su posición de un punto a otro y evalúen el grado de satisfacción de la nueva posición.

Cada partícula se mueve a través del espacio R^D con una velocidad v_i^t distinta para cada una, que se almacena en el vector V_i de la partícula. Esta velocidad v_i^t no es constante y varía en cada iteración t . La velocidad marca el ritmo con el que una partícula se desplaza y se acerca a una solución.

Para que una partícula explore el espacio R^D , solo necesita calcular su velocidad y posición. Para ello, se utilizan dos ecuaciones: la de velocidad y la de posición, dadas seguidamente.

$$v_i^{t+1} = \omega v_i^t + U(0, \phi_1) \times (p_i - x_i^t) + U(0, \phi_2) \times (p_g - x_i^t) \quad (3.1)$$

$$x_i^{t+1} = v_i^{t+1} + x_i^t \quad (3.2)$$

La nueva posición x_i^{t+1} de la partícula está definida por la suma de la posición anterior x_i^t y la nueva velocidad v_i^{t+1} . La nueva velocidad está definida por una suma un poco más compleja donde intervienen la velocidad anterior v_i^t , el factor de inercia ω , las distancias entre la posición actual x_i^t respecto a la mejor posición individual encontrada hasta el momento p_i y la mejor posición global encontrada hasta el momento p_g , y por último los coeficientes de aceleración cognitivo $U(0, \phi_1)$ y social $U(0, \phi_2)$.

De esta manera, los pasos básicos del *PSO* se describen como sigue:

- Se inicializan la cantidad de partículas del enjambre, la cantidad de iteraciones t y los parámetros ω, ϕ_1, ϕ_2 .
- Se determinan posiciones iniciales y velocidad inicial para cada partícula del enjambre. Una vez determinado todo esto, se comienza con la exploración, es decir, las partículas comienzan a moverse a través del espacio de búsqueda R^D .
- Una vez que empieza el ciclo de exploración y hasta que se cumpla algún criterio de parada, se evaluarán las posiciones de cada partícula con la función de aptitud o *Fitness* y luego se desplazarán las partículas hacia una nueva posición (Véase Figura 3.1).
- En este punto, el *PSO* utiliza la función de aptitud para evaluar la calidad de la nueva posición de una partícula en la iteración t que almacena en f_i^t . Esta evaluación determinará la calidad de la solución en relación a la mejor solución individual encontrada hasta el momento almacenada en p_i y en relación a la mejor solución encontrada por todo el enjambre hasta el momento almacenada en p_g . Al comparar el Fitness de la iteración actual f_i^t con el Fitness f_{p_i} , la

3. Optimización de Enjambre de Partículas

partícula actualizará el valor de p_i si el Fitness de la nueva posición es mejor que la ultima encontrada. En caso contrario, la ultima posición almacenada seguirá siendo la mejor solución encontrada por la partícula de forma individual. De manera similar, la partícula compara su Fitness con el Fitness de la mejor solución global f_g , y si nuevamente es mejor, reemplazará al mejor global p_g con su posición actual p_i pasando ésta a ser la nueva mejor solución del enjambre en conjunto. Nuevamente, en caso contrario, no se reemplazará el mejor global. Este par de comparaciones de Fitness tanto local como global se lleva a cabo por todas las partículas y en todas las iteraciones hasta encontrar la solución óptima o terminar el algoritmo con algún criterio de parada como la cantidad máxima de iteraciones.

- Una vez completada la evaluación, se calculan la nueva velocidad y la nueva posición de la partícula para la próxima evaluación. La velocidad de cada partícula va variando en cada iteración y oscila entre una velocidad máxima y una velocidad mínima. Además, los parámetros cognitivos, sociales y de inercia influyen en la nueva velocidad y por tanto a la convergencia del *PSO* (Véase Figura 3.2).
- Una vez alcanzado el criterio de fin del ciclo iterativo, el *PSO* presenta el resultado del problema almacenado en p_g . Esta es la mejor solución encontrada hasta el fin del ciclo.

Durante este proceso de exploración del espacio R^D , se van realizando ajustes a la velocidad V_i , de manera a que las partículas oscilen de forma estocástica entre las mejores soluciones individuales p_i y la mejor solución global p_g hasta converger hacia un punto común que es un candidato firme a una solución óptima. Se dice que es un candidato porque *PSO* no garantiza encontrar la solución óptima y puede quedar estancado en una solución no óptima.

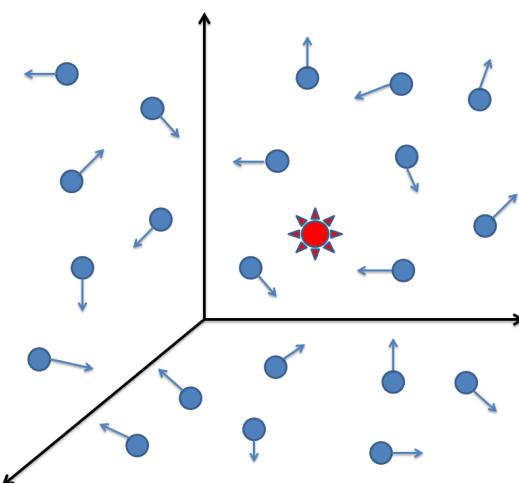


Figura 3.1: Movimiento inicial aleatorio de cada partícula.

3. Optimización de Enjambre de Partículas

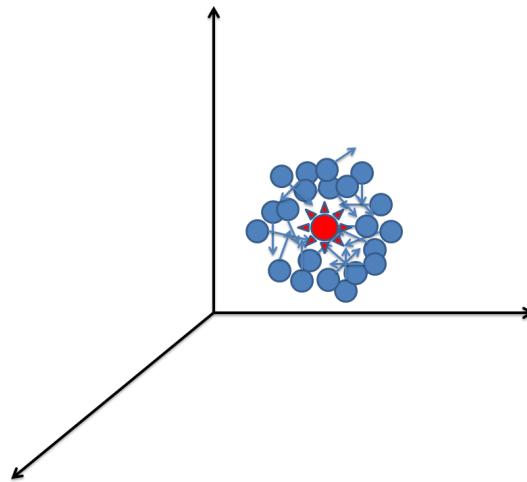


Figura 3.2: Convergencia de las partículas hacia la solución óptima.

Una partícula por sí sola es incapaz de resolver un problema cuyo espacio de búsqueda puede ser muy grande. Por ello, se necesita que interactúen entre ellas a través de las variables descritas que almacenan los mejores individuales y globales. Así, podemos ver que la resolución del problema abordado es un fenómeno de interacción social entre todos los individuos del enjambre.

Los pasos y funcionamientos del *PSO* descritos anteriormente se pueden ver a continuación en el Algoritmo 3:

Algoritmo 3 Algoritmo básico del *PSO*.

Entrada: número de partículas Ω , número de iteraciones t

```

1: Inicializar la posición y velocidad de cada partícula aleatoriamente en cada dimensión  $D$ 
2: Inicializar los mejores individuales  $p_i$  de cada partícula
3: Inicializar el mejor global  $p_g$ 
4: Inicializar el parámetro  $\omega$ 
5: mientras no se cumpla criterio de parada o no se llegue al máximo de iteraciones  $t$  hacer
6:   para cada  $i$ -ésima partícula del enjambre hacer
7:     Evaluar la función de aptitud (Fitness) de la partícula  $i$  en la iteración  $t$ 
8:     si el Fitness de la partícula es mejor que el Fitness del mejor individual  $p_i$  then
9:       reemplazar  $p_i$  por el nuevo valor de  $x_i^t$ 
10:    fin si
11:    si el Fitness de la partícula es mejor que el Fitness del mejor global  $p_g$  then
12:      reemplazar  $p_g$  por el valor de  $x_i^t$ 
13:    fin si
14:    Calcular la nueva velocidad de la partícula  $v_i^{t+1}$ , de acuerdo a la Ecuación 3.1
15:    Calcular la nueva posición de la partícula  $x_i^{t+1}$ , de acuerdo a la Ecuación 3.2
16:  fin para
17: fin mientras

```

Salida: mejor global p_g

En el Algoritmo 3, se necesitan ajustar algunos parámetros. A continuación se detallan los ajustes:

- Primero, el tamaño de la población de partículas, que por lo general se determina

3. Optimización de Enjambre de Partículas

de forma empírica y es frecuente utilizar cantidades entre 20 y 50 partículas y puede ser mayor dependiendo del problema en cuestión [PKB07].

- Segundo, ϕ_1 y ϕ_2 que son los valores máximos que pueden tomar los factores de aceleración $U(0, \phi_1)$ y $U(0, \phi_2)$, que determinan la ponderación de las fuerzas que mueven a la partícula hacia el camino de la mejor solución individual p_i o la mejor solución global p_g , como se ve en la Figura 3.3.
- Por ultimo, el peso de la inercia ω , que es una agregación al *PSO* original, propuesto en [SE98a].

En cuanto a ω , se puede ver que $v_i + U(0, \phi_1) \times (p_i - x_i) + U(0, \phi_2) \times (p_g - x_i)$ representa a una fuerza externa F_i que actúa sobre la partícula. Entonces, se observa que existe un cambio en la velocidad de la partícula, denotado como $\Delta x_i = F_i - (1 - \omega)v_i$. Esto significa que la constante $1 - \omega$ resulta en un coeficiente de fricción, y finalmente se puede interpretar a ω como la fluidez del medio en que la partícula se desplaza. Así, un valor relativamente alto de ω (como 0.9), corresponde a un sistema donde el medio en que se mueven las partículas presenta baja viscosidad y pueden efectuar una exploración extensiva. Al reducir ω de forma gradual hasta un valor relativamente bajo (como 0.4), entonces el sistema se vuelve más explotativo y tendiente a converger hacia algún óptimo local, es decir, una solución que pareciera ser la mejor pero no lo es, y erróneamente el enjambre puede moverse hacia ella y no encontrar la solución óptima global.

En cuanto a los factores $U(0, \phi_1)$ y $U(0, \phi_2)$, ambos se escogen de manera aleatoria en cada iteración y oscilan en cada uno de los rangos establecidos para cada factor.

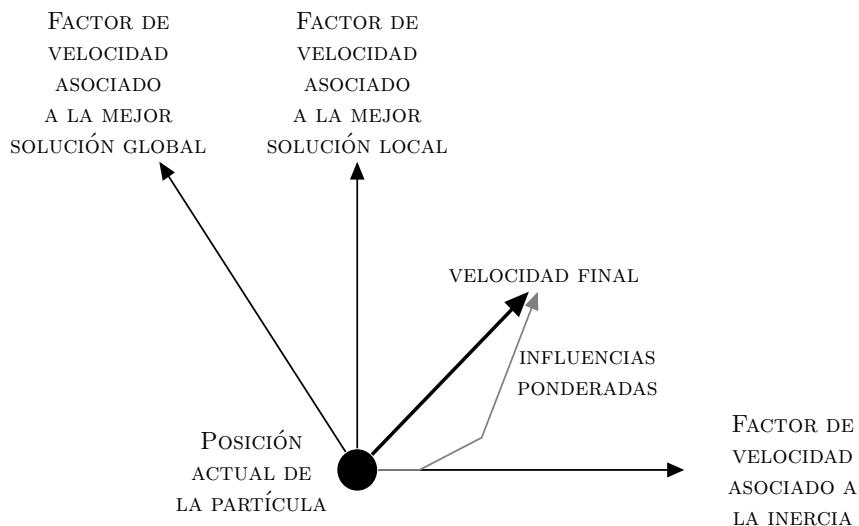


Figura 3.3: Influencia de los parámetros p_i , p_g y ω en la velocidad de una partícula.

3.3. Exploración y Explotación

El comportamiento del enjambre durante su movimiento en el espacio de búsqueda varía entre un comportamiento exploratorio, el cual hace que el enjambre realice la búsqueda a través del espacio de búsqueda lo más ampliamente posible abarcándolo por completo; y el comportamiento de explotación, que al encontrar una posible solución, orienta la búsqueda hacia un ella, y ésta a su vez podría ser solo un óptimo local y no la mejor solución posible. Este concepto está presente desde los inicios del *PSO* [Ken97; SE98b; CK02]. Para poder lograr un equilibrio entre los comportamientos de exploración y explotación y evitar la convergencia prematura hacia óptimos locales, se necesita realizar una selección bien cuidadosa de los parámetros del *PSO*.

3.4. Óptimos Locales y Óptimos Globales. Convergencia

Cuando las partículas van moviéndose en el espacio de búsqueda, van actualizando sus vectores de mejores locales (individual) y el vector de mejor global (en conjunto). Entonces, en algún momento comienzan a ir hacia un mismo lugar, es decir, una posible solución. A esto se le llama convergencia. Ahora bien, hay un detalle muy importante a la hora de converger hacia un punto del espacio de búsqueda, y es que el enjambre no sabe aún si está convergiendo hacia la mejor solución posible u óptima o hacia una solución no óptima. Existen dos maneras de convergencia en este tipo de metaheurística y son:

- **Converger hacia el óptimo global:** Las partículas se van moviendo hacia la mejor posición global del enjambre almacenada en p_g y ésta es a su vez la mejor solución del problema. Independientemente del comportamiento del enjambre, mientras no existan óptimos locales o el enjambre no se dirija hacia uno de ellos, todas las partículas convergerán hacia el óptimo global.
- **Converger hacia un óptimo local:** Aquí ocurre un colapso en el enjambre. Todas las partículas se mueven hacia un punto en el espacio de búsqueda almacenado en el vector de mejor global p_g , pero el enjambre no sabe que ésta no es la mejor solución del espacio de búsqueda. Aquí el enjambre podría atascarse, sin encontrar la solución óptima al problema. Para subsanar este inconveniente, se deben escoger de la mejor manera los parámetros del *PSO* y aplicar turbulencias aleatorias al enjambre de manera a que pueda volver a abrir un camino de exploración alternativo al camino al que el enjambre está convergiendo erróneamente.

En la Figura 3.4, se ve un ejemplo muy simple de una solución óptima global y dos soluciones óptimas locales, en una simple curva. Aquí, la mejor solución es el pico más alto de la curva, y los otros dos picos altos son soluciones no óptimas. El *PSO*, podría eventualmente converger hacia alguno de los puntos no óptimos y eso no daría el resultado correcto. Con una buena selección de parámetros y turbulencias aleatorias que sacudan al enjambre aleatoriamente se puede mover a las partículas hacia el punto correcto de la curva.

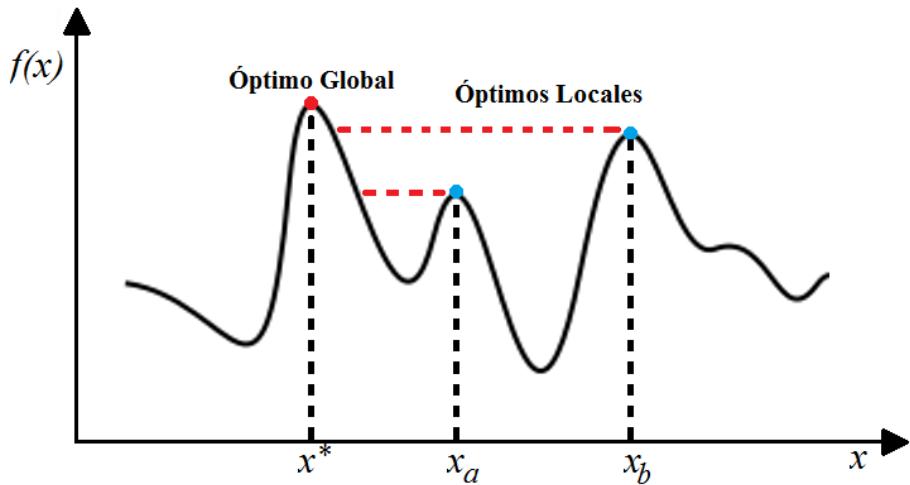


Figura 3.4: Ejemplo de óptimo global y óptimos locales.

Actualmente, la convergencia de las partículas solo puede ser determinada a través de pruebas empíricas. Los valores adecuados para los parámetros del *PSO* se determinan de la misma manera a través de pruebas. Por lo tanto, al utilizar el algoritmo *PSO*, se trata con mayor énfasis de mejorar el desempeño promedio del algoritmo, lograr una convergencia más rápida, mejorar la calidad de las soluciones y conseguir mayor robustez del algoritmo [ZZLS11].

3.5. Modificaciones y Desempeño del *PSO*

Las inicializaciones de las variables y la forma de evaluar las soluciones pueden afectar al desempeño del *PSO*. Por ello, existen variaciones entre las implementaciones propuestas que consideran algunas diferencias con el algoritmo básico. Hay formas de inicializar la velocidad de las partículas, iniciar con velocidad $v_i = 0$ o valores aleatorios, evaluar y actualizar el mejor global p_g encontrado por el enjambre una vez que el enjambre completo haya actualizado sus valores locales p_i , o que cada partícula actualice y evalúe ambos a la vez, entre otros. Algunas de estas opciones y como afectan al desempeño del *PSO* se pueden ver en [CD01].

Existen modificaciones del *PSO* básico que buscan mejorar el desempeño del algoritmo. Una práctica muy extendida es la de combinar *PSO* con otros métodos de optimización creando un enfoque de optimización híbrida [KL02; NA10; ZZLS11]. Otras modificaciones están centradas solamente en el intento de reducir la convergencia prematura y estancamiento en un óptimo local, introduciendo diferentes tipos de perturbaciones aleatorias en el movimiento de las partículas del *PSO* [LK02; Xin10].

Una forma de enfrentar a la convergencia prematura del algoritmo, es con el uso de varios enjambres de partículas explorando en el mismo espacio de búsqueda y buscando todos la solución óptima del problema [CDS13]. De esta manera, si un enjambre

3. Optimización de Enjambre de Partículas

se estanca en una solución no óptima, otro puede alcanzar la solución óptima. La utilización de varios enjambres se puede extender a una idea más compleja como la de los problemas con varios objetivos. Cuando el problema tienen más de un objetivo, estamos frente a un problema de optimización multi-objetivo. Aquí, se pueden utilizar varios enjambres de manera a que cada enjambre se enfoque a un objetivo específico [NBC⁺12].

Si bien el algoritmo *PSO* puede encontrar la solución óptima de un problema determinado, ¿Cómo determina cuál es esa solución óptima?, ¿Cómo el *PSO* puede determinar cuáles son los mejores parámetros del *CLAHE*? Para poder determinar cuáles son los parámetros óptimos para el *CLAHE* es necesario definir que criterios se tomarán en cuenta para evaluar la calidad de las soluciones que van encontrando las partículas durante su exploración.

Estas evaluaciones se llevan a cabo a través de las métricas de evaluación de la calidad de la solución. En el siguiente capítulo se presentan las métricas propuestas en este trabajo.

Capítulo 4

Métricas de evaluación

En este capítulo nos concentraremos en describir brevemente los criterios más utilizados para optimizar el proceso de Mejora del Contraste.

En general, podemos realizar una clasificación de los objetivos según la disponibilidad de una imagen de referencia no distorsionada, para efectuar comparaciones. La mayoría de los enfoques existentes se basan en lo que se denomina *referencia completa*, lo que significa que se asume disponer de una imagen de referencia completa. Sin embargo, en varias aplicaciones prácticas la imagen de referencia no está disponible, y entonces se utiliza un esquema de evaluación de calidad *sin referencia* o *ciega*. Luego existe un tercer esquema, en donde la imagen de referencia se encuentra parcialmente disponible, el cual se denomina evaluación de calidad con *referencia reducida* [WBSS04]. En esta sección sólo analizaremos algunos enfoques de *referencia completa*.

Dos de las métricas más sencillas, y por tanto más ampliamente utilizadas son:

- El Error Cuadrático Medio (*MSE* por sus siglas en inglés Mean Squared Error), el cual promedia las diferencias de intensidad elevadas al cuadrado de la imagen original y la imagen resultante,
- La Relación Señal a Ruido Pico (*PSNR* por sus siglas en inglés Peak Signal-to-Noise Ratio), la cual es una función logarítmica del Error Cuadrático Medio [Ann07].

Éstas métricas son interesantes por ser muy sencillas de calcular, tienen significado físico evidente, y son convenientes desde el punto de vista matemático para la optimización. Ahora, no son muy adecuados para determinar la calidad visual de los resultados [Gir93; TH94; EF95; EB98; WB02; WBL02]. La mayoría de los modelos de evaluación de calidad de resultados se basa en modificaciones de *MSE* para penalizar el ruido cuando se hace muy visible.

En nuestro trabajo, para medir una mejora de contraste satisfactoria, se trazaron los objetivos de maximizar la cantidad de información disponible en la imagen para el análisis y minimizar la distorsión que resulta como consecuencia de la utilización del

CLAHE. Por ello, a continuación, se presentan los conceptos de las métricas adoptadas para la evaluación de resultados del *PSO*: la *Entropía* y el *Índice de Similitud Estructural*.

4.1. Entropía

La *Entropía de la Información* es un coeficiente que nos da una medida cuantitativa de la aleatoriedad o incertidumbre que se encuentra dentro de la señal que transporta una imagen [TLM08]. La Entropía de la Información es un concepto definido primariamente por Shannon [Sha48]. Aquí se utiliza una generalidad importante, que es la de la fuente de información. Éste concepto puede ser caracterizado si tomamos en cuenta el esquema general de un sistema de comunicación, como fue definido por Shannon y se muestra en la Figura 4.1. Este esquema general de comunicación está definido por los siguientes componentes:

- Una *Fuente de Información*, que produce un mensaje, o una serie de mensajes a la correspondiente terminal. Las fuentes de información pueden ser de distintos tipos (Una serie de letras, una función del tiempo $f(x)$ como ocurre en radio o televisión, etc.).
- Un *Transmisor*, que opera sobre el mensaje, de manera que la señal pueda ser transmitida por el canal.
- El *Canal*, que es simplemente el medio por donde se transmite la señal.
- El *Receptor*, que realiza el trabajo inverso al transmisor, al reconstruir el mensaje transmitido dentro de la señal.
- El *Destino* es la persona (o aplicación), para el que el mensaje resulta útil o necesario.

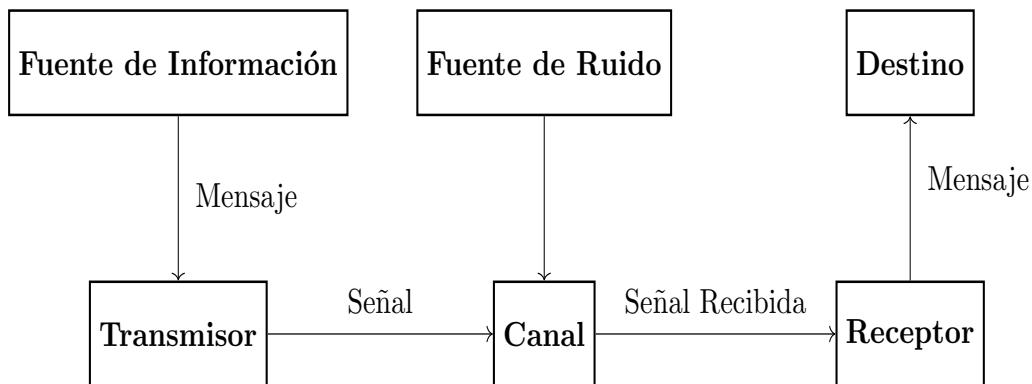


Figura 4.1: Diagrama esquemático de un sistema general de comunicación.

4. Métricas de evaluación

Análogamente, podemos ver que la imagen que se procesa es la fuente de información que necesitamos transmitir, y que el destino es la aplicación de alto nivel que utiliza la información proveída por la imagen a la que se aplica la mejora de contraste.

La Entropía de la Información de Shannon posee algunas características básicas:

- La medida de la información deberá ser proporcional (es decir, lineal continua). Esto significa, que si se tiene un cambio relativamente reducido, entonces se debe dar poca variación de la Entropía.
- Si todos los elementos de la señal tienen una misma probabilidad, entonces la Entropía es máxima.

Teniendo en cuenta el concepto presentado por Shannon, se puede dar una definición matemática de la Entropía de la información. De este modo, si se tiene una variable aleatoria cualquiera que contiene información (en nuestro caso una imagen digital) cuyo grado de indeterminación o incertidumbre inicial es \mathcal{K} (la variable puede tener \mathcal{K} estados posibles), y que cada estado tiene la misma probabilidad de aparición, entonces la probabilidad de ocurrencia de cada uno de los estados es $\mathcal{P} = \frac{1}{\mathcal{K}}$. Con la probabilidad de ocurrencia de cada estado posible, se puede expresar la cantidad de información c de un estado como se muestra en la fórmula (4.1)

$$c = \log_b(\mathcal{K}) = \log_b\left[\frac{1}{\frac{1}{\mathcal{K}}}\right] = \log_b\left(\frac{1}{\mathcal{P}}\right) = \underbrace{\log_b(1)}_{=0} - \log_b(\mathcal{P}) = -\log_b(\mathcal{P}) \quad (4.1)$$

Si cada estado posible i tiene una probabilidad de ocurrencia \mathcal{P}_i , entonces, la suma ponderada de la cantidad de información c_i de cada estado y su probabilidad de ocurrencia es la Entropía y se define como [CA86]:

$$\mathcal{H} = \mathcal{P}_1 c_1 + \dots + \mathcal{P}_{\mathcal{K}} c_{\mathcal{K}} = -\mathcal{P}_1 \log_b(\mathcal{P}_1) - \dots - \mathcal{P}_{\mathcal{K}} \log_b(\mathcal{P}_{\mathcal{K}}) = -\sum_{i=1}^{\mathcal{K}} \mathcal{P}_i \log_b(\mathcal{P}_i) \quad (4.2)$$

Entonces, la Entropía de un mensaje Q , denotada como $\mathcal{H}(Q)$, es la media ponderada de la cantidad de información que posee cada uno de los estados posibles del mensaje como se muestra en la función (4.3) de la Entropía General.

$$\mathcal{H}(Q) = -\sum_i \mathcal{P}(q_i) \log_b(\mathcal{P}(q_i)) \quad (4.3)$$

Ahora, en el contexto de la mejora de contraste, podemos afirmar que la información contenida en una imagen aumenta como consecuencia del aprovechamiento de los niveles de gris disponibles para la representación de la misma. Esto es consistente con el concepto general de la ecualización del histograma, es decir, cuanto mejor se usan los niveles de gris disponibles aproximando una distribución uniforme, más información se puede representar en la imagen [KHLF06].

4. Métricas de evaluación

Si luego de aplicar el algoritmo de mejora de contraste a una imagen, en nuestro caso el *CLAHE*, ocurre una disminución en el valor de la Entropía de la imagen mejorada con respecto a la original, quiere decir que se ha perdido información y no se está utilizando de la mejor manera los niveles de gris disponibles. Una mala redistribución hecha por el algoritmo *CLAHE* puede causar esta reducción en la Entropía de la imagen. De esta manera, si los parámetros utilizados por *CLAHE* causan esta disminución, quiere decir que no son los adecuados para un buen resultado, y en contrapartida, los parámetros que aumenten la Entropía son grandes candidatos a ser un buen resultado y ser los parámetros óptimos.

Por tanto, para definir la Entropía de la Información en el contexto de la mejora de contraste, primero se debe utilizar la definición del histograma de niveles de gris que se presentó en el capítulo 2 en la expresión (2.1) del Histograma.

De esta expresión, se necesitan la cantidad de ocurrencias del i -ésimo nivel de gris representado por h_i y la cantidad total de píxeles representado por Z . Con esto, se puede definir la distribución normal de niveles de gris como se muestra en la expresión (4.4). \mathcal{P}_i es la probabilidad de ocurrencia de un estado posible i de \mathcal{K} estados posibles, que a su vez es la probabilidad de ocurrencia de un nivel de gris de la escala de grises.

$$\mathcal{P}_i = \frac{h_i}{Z} \quad (4.4)$$

Finalmente, en el contexto de mejora de contraste, la Entropía de una imagen se define como se muestra en la función (4.5) de la Entropía de la Información.

$$\mathcal{H}(Q) = - \sum_i \mathcal{P}_i \log_2(\mathcal{P}_i) \quad (4.5)$$

La razón por la que se utiliza logaritmo en base 2 se debe a que la información que se intenta representar utiliza base binaria, es decir, se está intentando representar bits dado que una imagen digital como cualquier información digital, está compuesta de bits.

De esta manera, el valor máximo que puede tomar la Entropía está determinado por el número \mathcal{K} de estados posibles que puede tener el mensaje Q que es la imagen digital, y la base del logaritmo. Como la Entropía mide que tan bien se utilizan los niveles de gris disponibles, el número de estados posibles \mathcal{K} será el número de niveles de gris disponible, es decir, $\mathcal{K} = 256$.

Además, anteriormente dijimos que cada estado es equiprobable, es decir, cada nivel de gris tiene la misma probabilidad de ocurrencia, por lo tanto, la cantidad de información c de cada estado es $c = \log_2(\mathcal{K}) = \log_2(256) = 8$, la probabilidad de ocurrencia de cada nivel de gris es $\mathcal{P} = \frac{1}{\mathcal{K}} = \frac{1}{256}$, y dado que la Entropía es la suma ponderada entre la cantidad de información c y su probabilidad de ocurrencia, se puede calcular el valor máximo como:

$$\mathcal{H}(Q) = - \sum_i \mathcal{P}_i \log_2(\mathcal{P}_i) = - \sum_{i=1}^{256} \frac{1}{256} \log_2\left(\frac{1}{256}\right) = 8 \quad (4.6)$$

Por lo tanto, en el contexto de mejora de contraste, maximizar la entropía consiste en acercarse en lo posible a $\log_2(\mathcal{K})$, ya que este valor solo se puede obtener cuando la imagen posee un histograma uniforme donde cada nivel de gris posee la misma probabilidad de ocurrencia. Cuando el histograma se aproxima a la distribución uniforme, la Entropía se aproximará a $\log_2(\mathcal{K})$. La Entropía es siempre no negativa, es decir, es siempre mayor a 0 dado que es la suma de las probabilidades \mathcal{P}_i .

Es importante medir la Entropía de la imagen, debido a que está directamente relacionada con la homogeneidad del brillo de la misma [KBD91]. Ésto significa que al maximizar la Entropía de la imagen, también se aumenta el contraste que posee. Además, se maximiza la cantidad de información contenida dentro de la misma, lo que resulta útil para realizar análisis posteriores.

La Entropía por sí sola no es suficiente para determinar si la mejora de contraste realizada es satisfactoria, debido a que no cuantifica la amplificación del ruido ni la distorsión o degradación en la estructura de una imagen como consecuencia de aplicar *CLAHE*, como se vio en la Figura 2.29 del capítulo 2.

Esto conlleva a obtener imágenes con ruido muy amplificado o detalles distorsionados, debido a la elección no óptima de parámetros de ecualización de *CLAHE*. Por tanto es necesario definir otra métrica, que nos permita determinar la calidad de la imagen resultante, en términos de distorsión y amplificación del ruido. Es por esta razón que se introduce otra métrica de evaluación de mejora del contraste denominada Índice de Similitud Estructural, la cual se presenta en la siguiente sección.

4.2. Índice de Similitud Estructural

El Índice de Similitud Estructural (*SSIM* por sus siglas en inglés Structural Similarity Index) es un coeficiente que permite evaluar los cambios producidos en la información estructural de una imagen luego de haber sufrido alguna modificación. Esta métrica da como resultado una buena medida de la distorsión o degradación estructural de la imagen que puede ser producida por cualquier algoritmo de mejora de imágenes.

SSIM descansa en la idea de que existe una dependencia fuerte entre píxeles que son cercanos unos a otros [WBSS04], es decir, un vecindario de píxeles. Por lo tanto, existe mucha información sobre la estructura de los objetos que componen la escena de la imagen capturada.

Los métodos tradicionales que miden la degradación de una imagen, como la Relación Señal a Ruido de Pico (*PSNR* por sus siglas en inglés Peak Signal-to-Noise Ratio), y el Error Cuadrático Medio (*MSE* por sus siglas en inglés Mean Squared Error), son inconsistentes con la percepción visual de la imagen [WBSS04].

En las últimas décadas, se ha hecho un esfuerzo grande en desarrollar métricas que puedan aprovechar las características que se conocen acerca del Sistema Visual Humano (*VHS* por sus siglas en inglés Visual Human System). En la mayoría de los casos, las métricas desarrolladas se centran en modificar el *MSE* para penalizar los errores producidos por este, de acuerdo al grado de visibilidad que alcanzan.

4. Métricas de evaluación

De manera a calcular esta métrica, se necesita identificar tres partes fundamentales de la imagen que son: la Luminancia, el Contraste y la Estructura de la imagen, como se muestra en la Figura 4.2. En esta figura, se muestra un esquema sencillo del funcionamiento completo de la métrica de evaluación *SSIM*. Aquí, *Señal X* y *Señal Y* se pueden interpretar como dos imágenes arbitrarias que serán comparadas, donde *Señal X* representa a la imagen original y *Señal Y* representa a la imagen modificada con algún algoritmo de mejora de imagen.

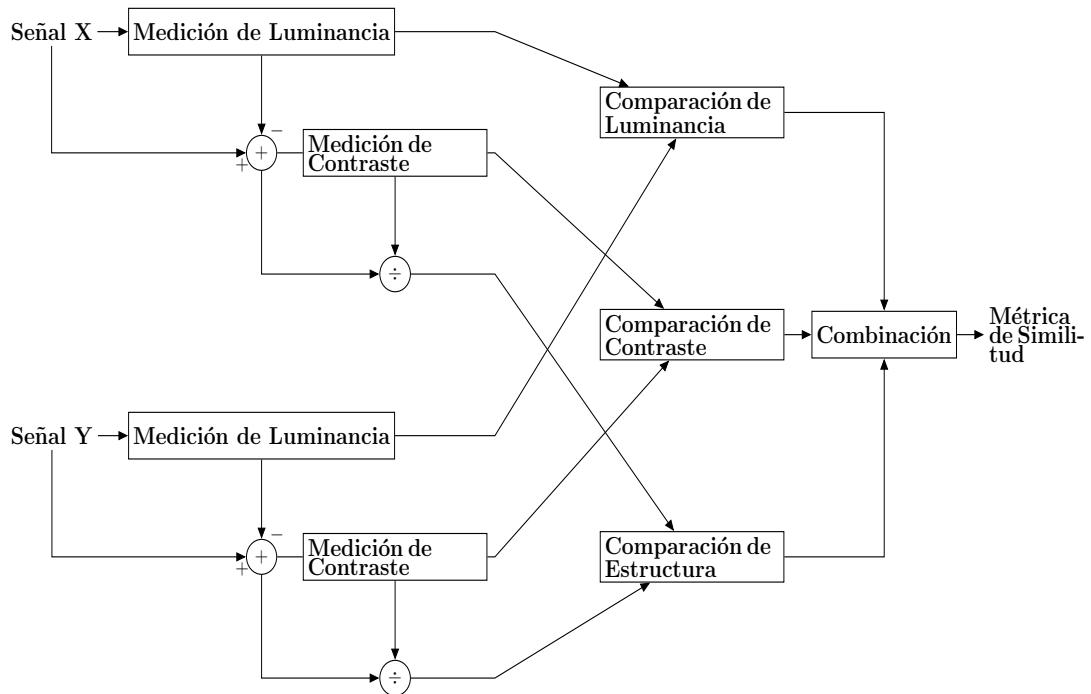


Figura 4.2: Diagrama esquemático del cálculo del Índice de Similitud Estructural.

Básicamente, se puede ver que se hacen mediciones para cada componente fundamental para cada imagen para posteriormente hacer una comparación de cada componente de la imagen original con respecto al componente par de la imagen modificada, es decir, luminancia con luminancia, estructura con estructura y contraste con contraste. Por ultimo se realiza una combinación cuyo resultado determina el grado de similitud entre ambas. A mayor *SSIM*, mayor similitud, que equivale a decir menor distorsión.

Para formular cada una de estas partes fundamentales, se deben definir dos imágenes digitales *I* y *T*, donde *I* es la imagen en su estado original y *T* es la imagen modificada por algún algoritmo cualquiera. Las imágenes *I* y *T* se pueden representar por una matriz de $M \times N$, donde *M* es la cantidad de filas de la matriz y *N* es la cantidad de columnas.

De esta manera, a continuación se describen las 3 partes como sigue:

4. Métricas de evaluación

- **Luminancia:** La Luminancia, con respecto a la superficie del objeto imagen, depende de la iluminación y la reflectancia. Es un estimativo de la media de intensidades de gris. La función de comparación de luminancia es función de los promedios μ_I y μ_T . Por lo tanto, para comparar este factor, se define la media de intensidades de gris de la imagen I como μ_I como se muestra en la expresión (4.7) y de la misma manera, la media de intensidades de gris de la imagen T como μ_T .

$$\mu_I = \frac{1}{M \times N} \sum_{i=1}^M \sum_{j=1}^N I(i, j) \quad (4.7)$$

En (4.7), (4.9) y (4.11) cada elemento $I(i, j)$ de la matriz representa a un píxel de la imagen con $i = \{1, 2, \dots, M\}$ y $j = \{1, 2, \dots, N\}$.

De esta manera se define la función de comparación de luminancia $l(I, T)$ como se ve en la función (4.8), considerando que la variable C_1 es una constante, que se añade de manera a evitar inestabilidades, que pueden surgir cuando la suma entre μ_I^2 y μ_T^2 es cercana a cero. Definamos a C_1 como sigue: $C_1 = (K_1 \times L)^2$, siendo L el rango dinámico de valores de píxel, y $K_1 \ll 1$.

$$l(I, T) = \frac{2\mu_I\mu_T + C_1}{\mu_I^2 + \mu_T^2 + C_1} \quad (4.8)$$

- **Contraste:** La variación de contraste entre imágenes depende de las desviaciones típicas de ambas, por tanto se debe calcular la desviación σ_I de la imagen I mediante la expresión (4.9) y de la misma manera σ_T para la imagen T . La función de comparación de contraste es entonces una comparación de σ_I y σ_T .

$$\sigma_I = \sqrt{\frac{1}{(M \times N) - 1} \sum_{i=1}^M \sum_{j=1}^N (I(i, j) - \mu_I)^2} \quad (4.9)$$

La función de comparación de contraste $c(I, T)$ se define como se muestra en la función (4.10), donde $C_2 = (K_2 L)^2$, el cual tiene los mismos parámetros que se definieron para C_1 .

$$c(I, T) = \frac{2\sigma_I\sigma_T + C_2}{\sigma_I^2 + \sigma_T^2 + C_2} \quad (4.10)$$

- **Estructura:** Para definir la información estructural de una imagen, se buscan las características que definen la representación de los objetos que componen la escena, de forma independiente de la luminancia y el contraste. La comparación de estructura está compuesta por la covarianza σ_{IT} y las desviaciones típicas σ_I

4. Métricas de evaluación

y σ_T . Por lo tanto, es necesario calcular la covarianza entre las imágenes I y T como se muestra en la expresión (4.11).

$$\sigma_{IT} = \frac{1}{(M \times N) - 1} \sum_{i=1}^M \sum_{j=1}^N (I_{(i,j)} - \mu_I)(T_{(i,j)} - \mu_T) \quad (4.11)$$

La covarianza indica que tanto se asemejan las estructuras de píxeles entre las dos imágenes, es decir, si es positiva hay semejanza entre las estructuras y si es negativa hay diferencia entre las estructuras. De esta manera, el término de información estructural $s(x, y)$ se define como se muestra en la función (4.12):

$$s(I, T) = \frac{\sigma_{IT} + C_3}{\sigma_I \sigma_T + C_3} \quad (4.12)$$

Finalmente, los tres componentes se combinan para dar la medida de similitud $SSIM$ dada en la expresión (4.13) y en la Figura 4.3:

$$SSIM(I, T) = F(l(I, T), c(I, T), s(I, T)) \quad (4.13)$$

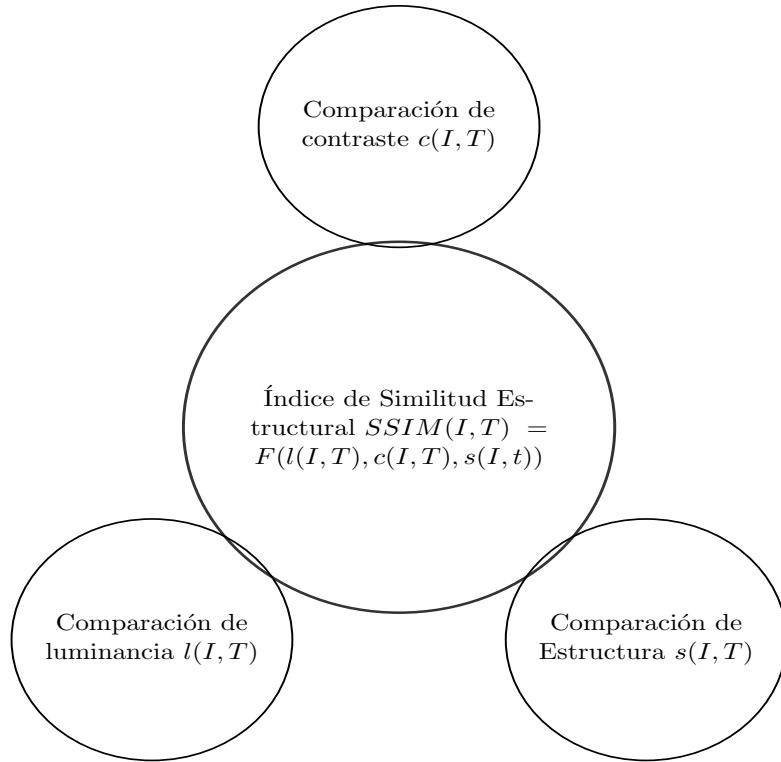


Figura 4.3: Diagrama de elementos componentes del Índice de Similitud Estructural.

4. Métricas de evaluación

Las funciones $l(I, T)$, $c(I, T)$ y $s(I, T)$ se han desarrollado de forma a que cumplan las tres condiciones siguientes [WBSS04]:

- Simetría: $SSIM(I, T) = SSIM(T, I)$
- Limitación: $SSIM(I, T) \leq 1$
- Normalización: $SSIM(I, T) = 1$ si y solo si $I = T$

Finalmente, al utilizar conjuntamente las tres ecuaciones anteriores, definimos de forma general el Índice de Similitud Estructural entre dos imágenes I y T según la Ecuación 4.14.

$$SSIM(I, T) = [l(I, T)]^\alpha + [c(I, T)]^\beta + [s(I, T)]^\gamma \quad (4.14)$$

Entonces, la forma particular de la función 4.14 toma como parámetros $\alpha = \beta = \gamma = 1$ y $C_3 = \frac{C_2}{2}$. α , β y γ definen el grado de prioridad de cada componente.

$$SSIM(I, T) = \frac{(2\mu_I\mu_T + C_1)(2\sigma_{IT} + C_2)}{(\mu_I^2 + \mu_T^2 + C_1)(\sigma_I^2 + \sigma_T^2 + C_2)} \quad (4.15)$$

Debido a que el algoritmo $SSIM$ se procesa por sectores de la imagen, como resultado se obtiene un conjunto de coeficientes $SSIM$, donde cada $SSIM$ corresponde a un sector procesado. Sin embargo, en la práctica se necesita de que el coeficiente $SSIM$ sea único y que permita evaluar la distorsión de una imagen original respecto a su modificación en su totalidad y no por sectores. Por ello, el resultado final de la métrica es la media de todos los coeficientes $SSIM$ resultantes calculados en cada sector de la imagen.

Capítulo 5

Propuesta

5.1. Contexto del Problema

Para dar una introducción al contexto del problema, se debe rememorar en forma general los conceptos más importantes del marco teórico que se presentó en los capítulos anteriores.

- Primero, *CLAHE* es un algoritmo de mejora de contraste local que posee dos parámetros de entrada que deben ser definidos de la mejor forma posible para obtener un resultado satisfactorio. Los parámetros del *CLAHE* son el tamaño de Región Contextual $\mathcal{R} = (\mathcal{R}_x, \mathcal{R}_y)$ y el Clip Limit \mathcal{C} .
- Segundo, la optimización de enjambre de partículas es un algoritmo metaheurístico de optimización que explora en un amplio espacio de búsqueda buscando la solución óptima del problema. Una solución óptima es aquella que satisface de la mejor manera posible la función de evaluación o aptitud del problema en base a los objetivos trazados. En el contexto del problema de mejora de contraste, y específicamente en este trabajo de investigación, una solución óptima es aquella que cumpla plenamente con los objetivos que se han priorizado, que son: maximizar la cantidad de información contenida en la imagen y minimizar la distorsión o degradación producida por el algoritmo *CLAHE*, que a su vez es un producto heredado del algoritmo básico *HE*.

Los dos parámetros del *CLAHE* se representan como tres dimensiones en el espacio de búsqueda de la solución:

- Primero, el espacio de búsqueda del tamaño de la Región Contextual \mathcal{R} . La Región Contextual está formada por un par de valores \mathcal{R}_x y \mathcal{R}_y que definen la cantidad de filas y columnas que tendrán todas las regiones \mathcal{R} en la que se divide la imagen. Estos valores pertenecen al conjunto de los números naturales \mathbb{N} y su dominio está acotado para \mathcal{R}_x en el rango de $[2, M]$ donde M es la cantidad de filas de la imagen original, y para \mathcal{R}_y en el rango de $[2, N]$ donde N es la cantidad de columnas de la imagen original.

- Segundo, el valor del Clip Limit \mathcal{C} que es el factor de corte de picos. Este valor pertenece al conjunto de los números reales \mathbb{R} y su dominio está acotado en el rango de $(0, 255]$

De esta manera, el problema radica en la selección correcta de los parámetros, de manera a obtener un resultado satisfactorio. La selección incorrecta de este par de parámetros en conjunto da una solución insatisfactoria o considerablemente distorsionada. Para que el resultado sea satisfactorio, ambos deben tener los valores óptimos. Encontrar el conjunto de valores óptimos es una tarea compleja debido a que cada posible tamaño de Región Contextual $(\mathcal{R}_x, \mathcal{R}_y)$ se empareja con cada uno de los valores posibles del Clip Limit en el rango de $(0, 255]$, lo que hace que exista un enorme número de combinaciones posibles en el espacio global de búsqueda y explorar este espacio de forma secuencial tiene un costo computacional muy elevado. El algoritmo metaheurístico de optimización *PSO*, es una buena opción para realizar la exploración en un amplio espacio de búsqueda y encontrar la solución óptima sin recorrer por todo el espacio gracias a su implementación sencilla en cualquier lenguaje, bajo consumo de recursos computacionales y su velocidad de convergencia [BSA07].

Pero para evaluar la calidad de una solución de forma a poder determinar si los valores de los parámetros son óptimos o no, se debe tener un criterio de evaluación. Este criterio es el que decidirá si la solución es mala o buena. Para ello se debe tener bien en claro lo que se quiere conseguir al mejorar la imagen. En el contexto del problema de mejora de contraste, se han priorizado dos objetivos: la maximización de la información contenida en una imagen y la minimización de la distorsión de la imagen producida por el algoritmo *CLAHE* que a su vez es un producto heredado del algoritmo *HE*. Teniendo definidos los criterios a evaluar, se describe a continuación el problema de mejora del contraste de manera formal, de la manera que se plantea en este trabajo.

5.2. Formulación del Problema

Debemos definir formalmente el problema que estamos buscando resolver, de forma a que la especificación del mismo sea clara. Para tal efecto, necesitamos definir algunos elementos que conforman el problema:

- I es la imagen de entrada en escala de grises de tamaño $M \times N$,
- T la imagen mejorada de tamaño $M \times N$,
- L la cantidad de niveles de gris disponibles,
- *CLAHE* el algoritmo utilizado para realizar la mejora del contraste, el cual toma como parámetros de entrada la imagen I , una región contextual $\mathcal{R} = (\mathcal{R}_x, \mathcal{R}_y)$ que representa el tamaño de los bloques en los que se divide la imagen y el Clip Limit \mathcal{C} que recorta los picos de histograma en la ecualización,
- \mathcal{H} es la Entropía de una imagen, tal y como se definió en la Sección 4.1, Ecuación 4.3,

- $SSIM$ como el Índice de Similitud Estructural, tal y como se definió en la Sección 4.2, Ecuación 4.14.

De esta manera, formalmente, dadas la imagen de entrada I y el algoritmo $CLAHE$, se desea calcular la mejor solución \vec{x} que maximice:

$$f(\vec{x}) = f_1(\vec{x}) \times f_2(\vec{x}) \quad (5.1)$$

donde:

- $\vec{x} = (\mathcal{R}_x, \mathcal{R}_y, \mathcal{C})$, donde \mathcal{R}_x y \mathcal{R}_y conforman la región contextual y \mathcal{C} es el Clip Limit.
- $f_1(\vec{x}) = \frac{\mathcal{H}(T)}{\log_2 L}$ es la Entropía normalizada de la imagen T , siendo T la imagen mejorada por $CLAHE$ con los parámetros dados por \vec{x} , y L la cantidad de grises disponibles.
- $f_2(\vec{x}) = SSIM(I, T)$ es el Índice de Similitud Estructural.

sujeto a:

- $\mathcal{R}_x \in [2, \dots, M]$ en los números \mathbb{N} .
- $\mathcal{R}_y \in [2, \dots, N]$ en los números \mathbb{N} .
- $\mathcal{C} \in (0, 1]$ en los números \mathbb{R} .

Ésto significa que los valores de \mathcal{R} solamente pueden tomar valores enteros positivos entre $(2, 2)$ y (M, N) y que \mathcal{C} puede tomar un valor mayor a cero y menor o igual a 1.

Ahora que definimos formalmente el problema que se plantea, podemos escribir el algoritmo de $PSO - CLAHE$, el cual se presenta en la sección siguiente.

5.3. Algoritmo $PSO - CLAHE$

El algoritmo PSO debe ser adaptado para que pueda procesar el algoritmo $CLAHE$ durante su ejecución. Para el problema en cuestión, se utiliza un algoritmo PSO básico en conjunto con una herramienta que implementa y ejecuta el algoritmo $CLAHE$ y el algoritmo $SSIM$. A continuación, se presenta el $PSO - CLAHE$ en el algoritmo 4.

Algoritmo 4 Algoritmo *PSO – CLAHE*.

Entrada: imagen de entrada *imagenOriginal*, número de partículas Ω , número de iteraciones t

```

1: Inicializar los parámetros  $\omega$ ,  $\phi_1$ ,  $\phi_2$ , iteracionActual=0
2: para cada  $i$ -ésima partícula del enjambre hacer
3:   Inicializar la posición  $x_i$  aleatoriamente
4:   Inicializar la velocidad  $v_i$  a 0
5:    $imagenMejorada = CLAHE(x_i, imagenOriginal)$ 
6:    $f_i = evaluarAptitud(imagenOriginal, imagenMejorada)$ 
7:   Establecer el mejor individual inicial  $p_i$  por el valor inicial  $x_i$ 
8:   si  $f_i < f_{p_g}$  then
9:     reemplazar  $p_g$  por el valor de  $x_i$ 
10:    fin si
11: fin para
12: mientras iteracionActual <  $t$  hacer
13:   para cada  $i$ -ésima partícula del enjambre hacer
14:     Calcular la nueva velocidad de la partícula  $v_i^t$  con la expresión (3.1) de velocidad
15:     Calcular la nueva posición de la partícula  $x_i^t$  con la expresión (3.2) de posición
16:      $imagenMejorada = CLAHE(x_i^t, imagenOriginal)$ 
17:      $f_i^t = evaluarAptitud(imagenOriginal, imagenMejorada)$ 
18:     si  $f_i^t < f_{p_i}$  then
19:       reemplazar  $p_i$  por el nuevo valor de  $x_i^t$ 
20:     fin si
21:     si  $f_i^t < f_{p_g}$  then
22:       reemplazar  $p_g$  por el valor de  $x_i^t$ 
23:     fin si
24:     iteracionActual = iteracionActual + 1
25:   fin para
26: fin mientras
Salida: mejor global  $p_g$ 

```

La descripción del funcionamiento del algoritmo 4 *PSO – CLAHE* se presenta a continuación:

- Se inicializa la imagen original en la variable *imagenOriginal* de modo a poder utilizarla para el cálculo de la Entropía y la obtención del *SSIM* comparándola con las imágenes mejoradas por cada partícula.
- Se inicializan el número de partículas del enjambre Ω , el número máximo de iteraciones t , iteracionActual=0, $\omega = 0.1$, $\phi_1 = 1.5$ y $\phi_2 = 2.5$.
- Por cada i -ésima partícula, se establece una posición x_i inicial, es decir, se establecen valores iniciales de forma aleatoria para la Región Contextual $\mathcal{R} = (\mathcal{R}_x, \mathcal{R}_y)$ y el Clip Limit \mathcal{C} , de manera a poder hacer una evaluación inicial. También se inicializa la velocidad de cada partícula con el valor 0.
- Por cada i -ésima partícula, se llama a la función CLAHE, que recibe como parámetros la posición inicial x_i y la imagen original. Esta función retorna la imagen procesada por el algoritmo CLAHE con los parámetros definidos en la partícula.
- Por cada partícula, se hace una evaluación inicial ejecutando la función de aptitud. Esta función recibe como parámetro la imagen original y la imagen procesada por el CLAHE. En la función de aptitud se calcula la Entropía de la imagen

mejorada y el *SSIM* entre las dos imágenes para retornar el valor del *Fitness* de la partícula.

- Se inicializan los mejores individuales hasta el momento p_i de cada partícula con su posición inicial x_i .
- Se inicializa el mejor global p_g con la partícula con mejor posición inicial x_i .
- Una vez que todas las partículas del enjambre tienen una posición inicial en el espacio de búsqueda, deben empezar a moverse en busca de la solución óptima hasta que se cumpla el criterio de parada que en este caso es una cantidad máxima de iteraciones t . A partir de ahora, para moverse, utilizarán las formulas de la Ecuación 3.1 de velocidad y la Ecuación 3.2 de posición. De esta manera, mientras no se cumpla el criterio de parada las partículas se moverán, se evaluarán, y se compararán con los mejores individuales y el mejor global.
- Se calcula la velocidad v_i^t de cada partícula según la Ecuación 3.1 de velocidad.
- Se calcula la posición x_i^t nueva de cada partícula según la Ecuación 3.2 de posición.
- Se ejecuta el algoritmo *CLAHE* con los valores nuevos de cada partícula.
- Se evalúa el *Fitness* f_i^t de cada partícula con los nuevos valores de las posiciones calculadas por las Ecuaciones.
- Se compara el *Fitness* f_i^t nuevo con el *Fitness* f_{p_i} del mejor individual encontrado hasta el momento. Si el nuevo *Fitness* es mejor, se debe actualizar el mejor individual por la partícula actual.
- Se compara el *Fitness* f_i^t nuevo con el *Fitness* f_g del mejor global encontrado hasta el momento. Si el nuevo *Fitness* f_i^t es mejor, se debe actualizar el mejor global por la partícula actual.
- Se suma una iteración más a la variable de criterio de parada de cantidad actual de iteraciones y el ciclo se repite hasta terminar.
- Cuando termine el ciclo iterativo, es decir, se llegue a la máxima cantidad de iteraciones posibles, la solución estará almacenada en la variable del mejor global p_g encontrado por el enjambre.

Cabe mencionar que a diferencia del algoritmo *PSO* básico, en el *PSO – CLAHE* se realiza una evaluación inicial a las partículas además de inicializar solo los valores. De esta manera, la velocidad y la posición son calculadas al principio de cada iteración antes de la evaluación del *Fitness* de la partícula.

5.4. Relación *CLAHE-Partícula*

En la Figura 5.1 se presenta un esquema del como está constituida la partícula y como interacciona esta partícula con el algoritmo *CLAHE*. Primeramente el *CLAHE* recibe la imagen original y los valores de la partícula que corresponden a sus dos parámetros de entrada que son el tamaño de región contextual (R_x, R_y) y el Clip Limit C .

El resultado de procesar *CLAHE* con los valores de la partícula es una imagen mejorada de la cual se calcula la entropía y se calcula el *SSIM* en relación a la original. La entropía y el *SSIM* luego son la entrada para la función de evaluación o fitness que determinará un valor f , que determinará a su vez la calidad de la solución, es decir, si los parámetros son buenos o no. Si esta solución es buena, se almacenará en la variable de mejor global del *PSO*. Esto se repetirá hasta que termine el algoritmo *PSO*.

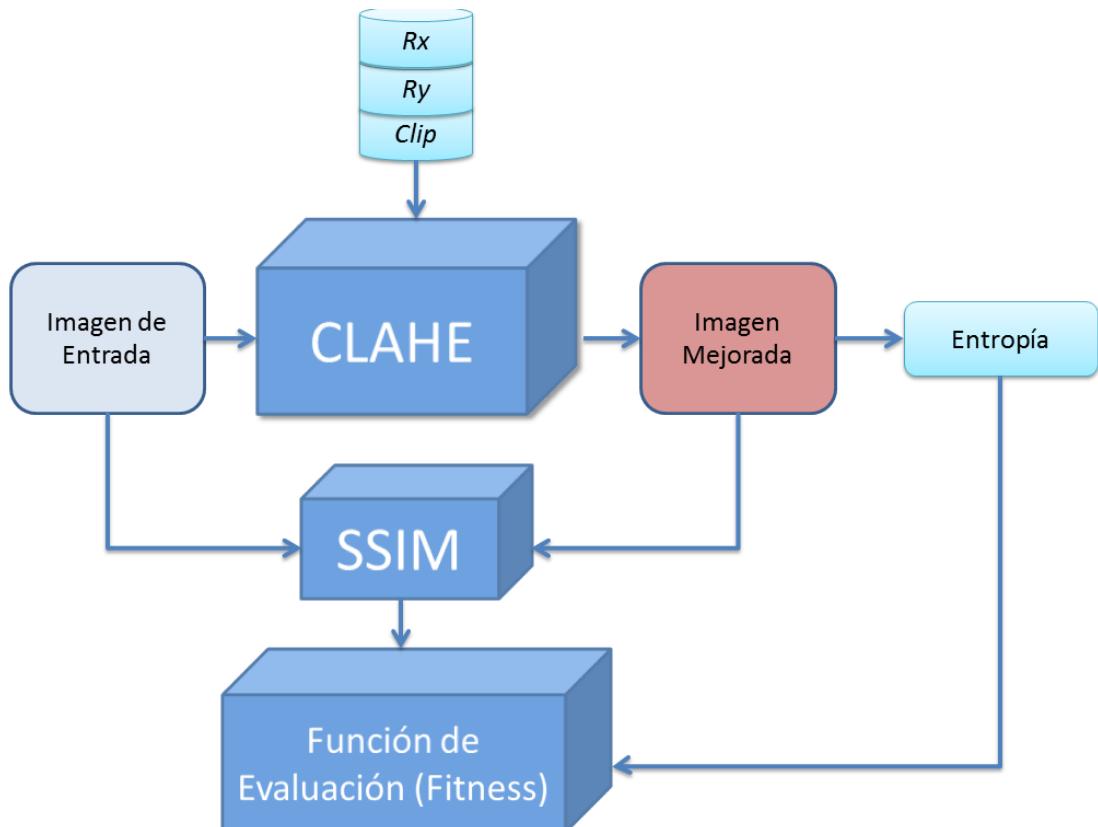


Figura 5.1: Relación *CLAHE-Partícula*.

Formulado el problema y definido el algoritmo *PSO - CLAHE*, pasamos en el siguiente capítulo donde se muestran los resultados obtenidos por nuestra propuesta.

Capítulo 6

Resultados y Discusión

6.1. Ambiente de Ejecución e Implementación

Para la ejecución de la implementación se utilizó como hardware una laptop con procesador Intel Core i5 de dos núcleos, arquitectura de 64 bits, con 6 GB de memoria RAM, con sistema operativo Windows 7 Home Edition.

Para la implementación del *PSO – CLAHE*, fue necesario la utilización de las implementaciones de una serie de librerías disponibles en la web para su utilización libre. La implementación del la metaheurística *PSO* es una adaptación de la implementación original planteada y disponible en las librerías *jMetal* [DN11]. El código fuente fue modificado para computar el cálculo del *fitness* basándose en la función 5.1 de Fitness. Se han utilizado los valores predeterminados provistos por *jMetal* para los parámetros de inercia ω , y para los valores que pueden tomar $U(0, \phi_1)$ y $U(0, \phi_2)$. Para la implementación del algoritmo *CLAHE* y de las métricas de Entropía y *SSIM*, se tomó como base las implementaciones de las librerías existentes en *OpenCV* [Bra00]. Debido a que las implementaciones del *PSO* y de *CLAHE* son heterogéneas, fue necesario implementar un esquema de intercambio de mensajes que logre la interoperabilidad entre ambas implementaciones. Con este propósito se utilizó una librería de interfaz REST [Fie00] para C++ denominado C++ REST SDK [web14a]. Gracias a ésto se hizo posible un intercambio de mensajes en formato JSON [web14b].

6.2. Implementación del estado del arte

Para validar los resultados obtenidos por *PSO – CLAHE*, se ha implementado una metodología más próxima reportada en la literatura del estado del arte. Para este propósito se implementó el enfoque propuesto por Byong Seok Min [MLKL13], el cual también trata el problema de Mejora de Contraste buscando los parámetros adecuados de *CLAHE* para la ecualización. Dicho enfoque solo utiliza la Entropía como métrica de evaluación de resultados. La diferencia más importante con respecto a *PSO – CLAHE* radica en el enfoque de búsqueda de los parámetros de ecualización de *CLAHE*. En el método propuesto por Byong se buscan los parámetros de ecualización de forma

6. Resultados y Discusión

analítica utilizando funciones de la Entropía con respecto a los parámetros de entrada de *CLAHE*. Primeramente se construye una curva de Entropía con respecto al Clip Limit teniendo en cuenta los parámetros $(\mathcal{R}_x, \mathcal{R}_y) = (8,8)$, y valores de \mathcal{C} comprendidos entre $[0,0.1]$ como se ve en la Figura 6.1.

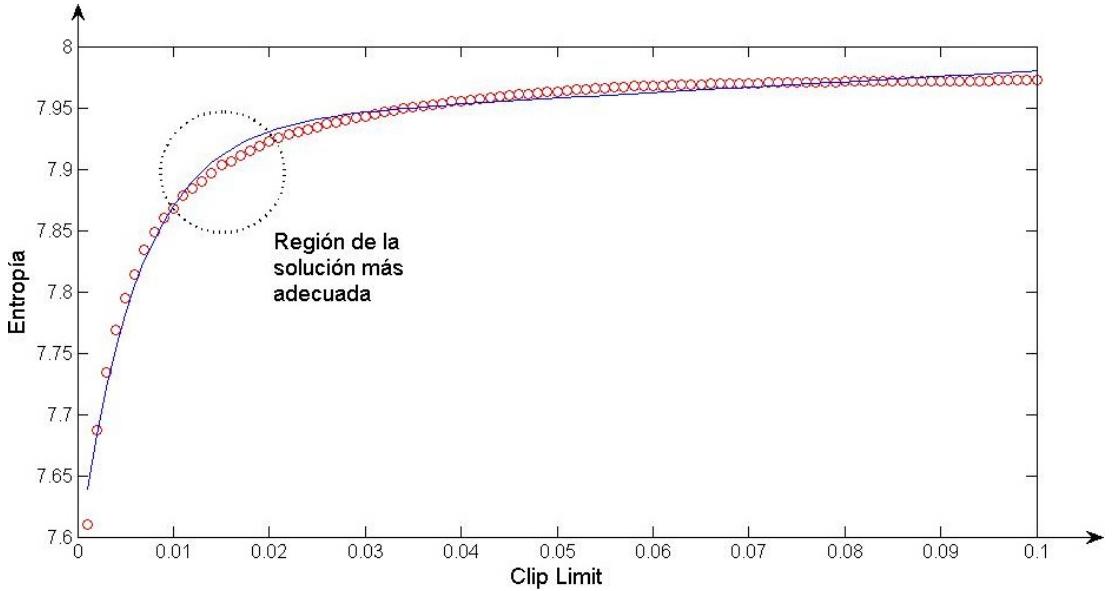


Figura 6.1: Ejemplo de curva ajustada de Entropía con respecto al Clip Limit, según la implementación de Byong. A partir de la misma se debe seleccionar el punto en donde se tiene la máxima curvatura, para tomar como el resultado de Clip Limit del algoritmo CLAHE.

Ésta curva de entropía no es monótona, por lo cual se ajusta de acuerdo a la función (6.1):

$$f(\alpha) = \beta_1 e^{-\lambda_1 \alpha} + \beta_2 e^{-\lambda_2 \alpha} \quad (6.1)$$

En (6.1), β_1 , β_2 , λ_1 y λ_2 son parámetros que deben determinarse para lograr ajustar $f(\alpha)$ a los puntos obtenidos en las curvas de ajuste. Ahora, según Byong, los puntos de máxima curvatura de estas curvas ajustadas, serán los parámetros más adecuados para la ecualización. Teniendo esta premisa en cuenta, y considerando a \mathcal{C} como $\gamma(t)$ y a \mathcal{H} como $\delta(t)$, es decir, funciones con respecto al tiempo, entonces el punto de máxima curvatura se halla como se muestra en las ecuaciones (6.2) y (6.3)

$$\kappa = \frac{\dot{\gamma}\ddot{\delta} - \dot{\delta}\ddot{\gamma}}{\sqrt{(\dot{\gamma}^2 + \dot{\delta}^2)^3}} \quad (6.2)$$

$$\kappa = \max(\kappa(\alpha)) \quad (6.3)$$

6. Resultados y Discusión

donde $\dot{\gamma}$ y $\dot{\delta}$ denotan las primeras derivadas con respecto al tiempo de $\gamma(t)$ e $y(\delta)$; a su vez, $\ddot{\gamma}$ y $\ddot{\delta}$ son las derivadas segundas de $\gamma(t)$ e $\delta(t)$ con respecto al tiempo. Entonces, κ representa la curvatura de la curva [SHE03] en el punto dado. Finalmente, se selecciona el punto donde se obtenga el mayor valor para κ , según (6.3).

Ahora, el mejor \mathcal{C} obtenido mediante la función (6.3) se selecciona como resultado, y se utiliza como valor fijo para la construcción de una nueva curva, en este caso de entropía con respecto al tamaño de región contextual, utilizando como valores de abscisa ($\mathcal{R}_x, \mathcal{R}_y$) de $N \times N$, desde (2, 2) hasta (32, 32) inclusive, la cual se vuelve a ajustar de acuerdo a la función (6.1). Finalmente, se aplica la función (6.3) a la nueva curva ajustada, y así se obtiene el tamaño de región contextual seleccionado para la aplicación de CLAHE.

6.3. Resultados Obtenidos. Comparación con el estado del arte

Se eligieron 23 imágenes para ejecutar las corridas de PSO-CLAHE; de este grupo, las imágenes generales fueron obtenidas de una serie de imágenes de prueba del sitio web del SIPI-USC [usc14], mientras que el grupo de imágenes médicas (tomografías, mamografías, radiografías y otros) fueron seleccionadas del motor de búsqueda OPE-Ni [ope14]; a su vez, las imágenes de prueba correspondientes al grupo de imágenes biométricas se tomó de una base de datos disponible en [sdu14]. Se tomaron en cuenta estos grupos importantes debido a que son los tipos de imágenes más relevantes para pruebas en la literatura correspondiente al estado del arte, además de que poseen características de contraste y detalles muy particulares. Para todas las imágenes, se realizaron 10 ejecuciones de prueba de *PSO – CLAHE*; se configuró la población de individuos con 100 partículas, y 50 iteraciones como criterio de parada. En las Tablas 6.1 - 6.3, se muestran los detalles de resultados para la implementación de *PSO – CLAHE*: en la primera columna se ve el nombre de referencia de la imagen, en la segunda se ve la entropía \mathcal{H} de la imagen sin ecualizar, en la tercera se aprecia la entropía \mathcal{H} de la imagen ecualizada que se obtuvo como el mejor resultado, en la cuarta se ve el *SSIM* de dicha imagen (nótese que no se muestra el *SSIM* de la imagen original, porque es 1 por definición [WBSS04]), en la quinta columna se ve el Fitness f que se utiliza para las evaluaciones en la implementación; finalmente, en las columnas 5 y 6 se muestra el Fitness f obtenido utilizando la implementación de Byong [MLKL13] para la mejora del contraste, y la diferencia entre el Fitness f de *PSO – CLAHE* y el de la implementación de Byong para cada resultado tabulado.

6. Resultados y Discusión

Tabla 6.1: Tabla de resultados de la implementación de PSO-CLAHE, para el grupo de imágenes médicas (tomografías, radiografías, mamografías y otros).

Imagen	Coeficientes Normalizados			Fitness		
	\mathcal{H} Original	\mathcal{H}	SSIM	Mejor f PSO-CLAHE	f Byong	Δf
Tórax	0,8336	0,9544	0,8617	0,8224	0,496	0,3264
Mamografía	0,8217	0,8784	0,9288	0,8158	0,5107	0,3051
Retinopatía	0,7302	0,8026	0,8489	0,6814	0,3762	0,3052
Células	0,7709	0,8558	0,8794	0,7526	0,51	0,335
Rodilla	0,8261	0,9211	0,9084	0,8367	0,6306	0,2061
Aorta	0,8391	0,8808	0,9069	0,7989	0,4729	0,3260

Tabla 6.2: Tabla de resultados de la implementación de PSO-CLAHE, para el grupo de imágenes generales.

Imagen	Coeficientes Normalizados			Fitness		
	\mathcal{H} Original	\mathcal{H}	SSIM	Mejor f PSO-CLAHE	f Byong	Δf
Lenna	0,9306	0,9813	0,9246	0,9073	0,7639	0,1434
Flores	0,8748	0,9201	0,9103	0,8375	0,5519	0,2856
Jirafa	0,6724	0,7838	0,8995	0,7050	0,2131	0,4919
Árbol	0,7675	0,8661	0,9232	0,7997	0,4402	0,3595
Mujer	0,6685	0,9038	0,8321	0,7521	0,3834	0,3687
Caramelos	0,7186	0,831	0,9401	0,7813	0,647	0,1343
Caramelos 2	0,7819	0,9168	0,9232	0,8464	0,4752	0,3712
Aérea	0,8264	0,9543	0,9643	0,9203	0,859	0,0613
Aérea 2	0,7833	0,9007	0,9788	0,8817	0,5783	0,3034
Aeroplano	0,7353	0,8706	0,9265	0,8066	0,3226	0,4840
Pareja	0,8025	0,9420	0,9050	0,8525	0,6542	0,1983
Puente	0,8746	0,9711	0,8697	0,84465	0,804	0,04065
Camión	0,7278	0,9070	0,8386	0,7607	0,469	0,2917
Elaine	0,8416	0,9718	0,9037	0,8783	0,7426	0,1357

Tabla 6.3: Tabla de resultados de la implementación de PSO-CLAHE, para el grupo de imágenes biométricas (escaneo de retina, escaneo de venas de dedos).

Imagen	Coeficientes Normalizados			Fitness		
	\mathcal{H} Original	\mathcal{H}	SSIM	Mejor f PSO-CLAHE	f Byong	Δf
Iris 1	0,8045	0,8252	0,931	0,7683	0,5356	0,2327
Iris 2	0,8449	0,9399	0,8982	0,8442	0,6098	0,2344
Dedo 1	0,6261	0,7759	0,8335	0,6467	0,6043	0,0424

6. Resultados y Discusión

Tabla 6.4: Tabla de resultados de la implementación de Byong [MLKL13], para el grupo de imágenes médicas (tomografías, radiografías, mamografías y otros).

Imagen	Coeficientes Normalizados			Fitness	Parámetros aplicados		
	\mathcal{H} Original	\mathcal{H}	SSIM		\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}
Tórax	0,8336	0,9764	0,5080	0,4960	8	8	0,0580
Mamografía	0,8217	0,9564	0,6215	0,5107	2	2	0,051
Retinopatía	0,7302	0,8861	0,4245	0,3762	2	2	0,0860
Células	0,7709	0,9924	0,5139	0,5100	2	2	0,058
Rodilla	0,8261	0,9791	0,6441	0,6306	2	2	0,033
Aorta	0,8391	0,9552	0,4951	0,4729	2	2	0,028

Tabla 6.5: Tabla de resultados de la implementación de Byong [MLKL13], para el grupo de imágenes generales.

Imagen	Coeficientes normalizados			Fitness	Parámetros aplicados		
	\mathcal{H} Original	\mathcal{H}	SSIM		\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}
Lenna	0,9306	0,9948	0,8208	0,7639	2	2	0,030
Flores	0,8748	0,9906	0,631	0,5519	2	2	0,044
Jirafa	0,6724	0,9754	0,3169	0,2131	2	2	0,056
Árbol	0,7675	0,9842	0,5735	0,4402	2	2	0,063
Mujer	0,6685	0,7936	0,5735	0,3834	32	32	0,042
Caramelos	0,7186	0,9089	0,7119	0,6470	8	8	0,0370
Caramelos 2	0,7819	0,9101	0,5222	0,4752	32	32	0,9101
Aérea	0,8264	0,9905	0,8137	0,859	2	2	0,250
Aérea 2	0,7833	0,9907	0,5838	0,5783	2	2	0,0380
Aeroplano	0,7353	0,9865	0,3271	0,3226	4	4	0,100
Pareja	0,8025	0,9915	0,6599	0,6542	2	2	0,056
Puente	0,8746	0,9945	0,8085	0,8040	2	2	0,0310
Camión	0,7278	0,9856	0,4759	0,4690	2	2	0,680
Elaine	0,8416	0,9939	0,7472	0,7426	2	2	0,0540

Tabla 6.6: Tabla de resultados de la implementación de Byong [MLKL13], para el grupo de imágenes biométricas (escaneo de retina, escaneo de venas de dedos).

Imagen	Coeficientes Normalizados			Fitness	Parámetros aplicados		
	\mathcal{H} Original	\mathcal{H}	SSIM		\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}
Iris 1	0,8045	0,9816	0,5456	0,5356	2	2	0,057
Iris 2	0,8449	0,9807	0,6218	0,6098	2	2	0,093
Dedo 1	0,6261	0,7912	0,7638	0,6043	2	2	0,04

6. Resultados y Discusión



Figura 6.2: (a) Lenna Original. (b) $PSO - CLAHE$.(c) Byong.

Cuando se comparan los resultados listados en las Tablas 6.4, 6.5 y 6.6 contra los de las Tablas 6.1, 6.2 y 6.3 respectivamente, se puede ver que una de las diferencias más importantes es que para las Tablas de resultados de la implementación de Byong, los coeficientes presentados para cada fila de la columna \mathcal{H} , resultan similares a los mismos valores que se presentan en las Tablas de resultados de $PSO - CLAHE$; ésto es así debido a que en la implementación de Byong, solamente se considera el objetivo de maximizar la cantidad de información presente en la imagen, sin tener en cuenta una restricción explícita que pueda prevenir la degradación de la imagen resultante. Por lo tanto, se puede notar también que los valores presentados en la columna $SSIM$ resultan mayores para las filas de las Tablas de resultados de $PSO - CLAHE$, por lo que el fitness general resulta mayor en las filas de dichas tablas, considerando las imágenes de prueba que se utilizaron para la validación.

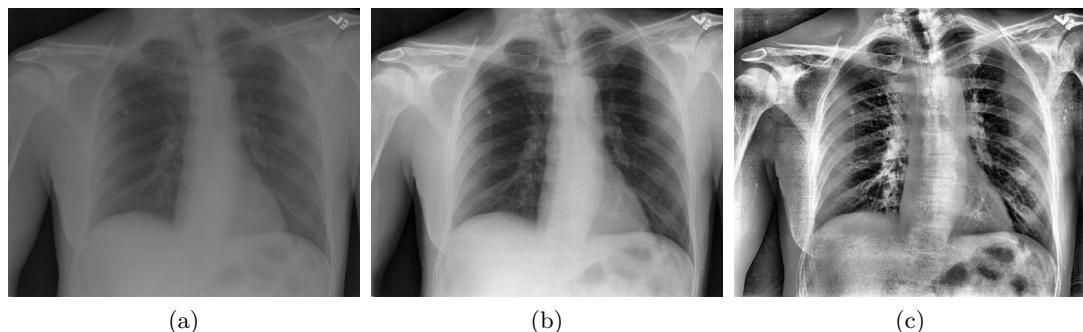


Figura 6.3: (a) Tórax Original. (b) $PSO - CLAHE$.(c) Byong.

En las Figuras 6.2, 6.3, 6.4, y en el Apéndice B, Figuras 12 - 20, se muestran las imágenes originales, el mejor resultado obtenido para cada imagen de prueba utilizando PSO-CLAHE y los resultados obtenidos utilizando la implementación de Byong, de forma a comparar visualmente las soluciones. Para el grupo de imágenes generales, se

6. Resultados y Discusión

puede ver que hay mejora del contraste perceptible en cada imagen, sin que ocurra amplificación del ruido. La mejora del contraste más importante se muestra en las imágenes en donde el contraste es notoriamente pobre (véase Apéndice B Figuras 7, 9, 10, 11, 2) y los detalles de imagen se preservan visibles, por lo que mantienen una apariencia visual natural. Para la implementación de Byong, se puede notar que los resultados arrojados tienen un brillo que no resulta natural, e inclusive se puede apreciar cómo se perdió información como consecuencia de la sobre-ecualización (véase Apéndice B, Figuras 11c, 9c, 14c).

En el caso de las imágenes médicas, es particularmente importante mantener los detalles finos durante el proceso de mejora del contraste. Se puede ver en las Figuras 1 - 5 del Apéndice B que efectivamente se mantienen de forma muy satisfactoria los detalles más minúsculos de las imágenes, lo cual es fundamental para preservar la utilidad de las mismas, al mismo tiempo que se logra una mejora positiva en el contraste. Si se analiza el mismo grupo de imágenes resultantes obtenido por la implementación de Byong (Apéndice B, Figuras 1c - 5c), se puede ver que se perdieron detalles finos como consecuencia de la sobre ecualización y de que no se controló de forma efectiva que la distorsión introducida quede en un umbral tolerable.

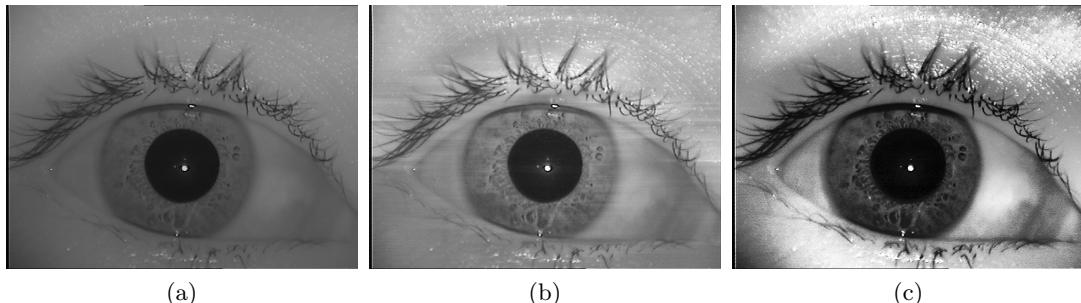


Figura 6.4: (a) Iris 1 Original. (b) *PSO – CLAHE*.(c) Byong.

En el grupo de imágenes biométricas, también es apreciable la necesidad de mantener los detalles finos de las imágenes resultantes. En las Figuras 19 - 20 del Apéndice B se ve que existe mejora del contraste sin perder éstos detalles, y aunque en los resultados de la implementación de Byong (Apéndice B, Figuras 19c - 20c) también se aprecia mejora en el contraste, la función de Fitness para todas las pruebas resultaron mayores en favor de *PSO – CLAHE*, debido a que se controla mejor la distorsión de la imagen.

Entre los parámetros aplicados para la mejora, existen variaciones importantes en cuanto a los tamaños de ventana aplicados para obtener las soluciones; esto significa que cada problema (es decir, cada imagen) necesita de tratamiento distinto para obtener éstos parámetros, además implica de no siempre es conveniente acotar los parámetros de ventana, como ocurrió en la implementación de Byong. Los parámetros de Clip Limit \mathcal{C} aplicados son relativamente bajos, debido a que la evaluación de *SSIM* evita

6. Resultados y Discusión

la distorsión severa, y CLAHE regula la ecualización cuando se aplica este rango de coeficientes. Por ultimo, en todos los casos aumentó la cantidad de información que se representa en la imagen, gracias a la utilización de la métrica de Entropía \mathcal{H} .

Capítulo 7

Conclusiones y Trabajos Futuros

7.1. Consideraciones finales

En los capítulos anteriores se presentaron de forma extensiva los siguientes temas:

- Una reseña de trabajos que anteceden a este material, en lo que se refiere a la Mejora del Contraste utilizando diversas técnicas, en su mayoría basadas en la Ecualización del Histograma, además de obras que realizan ecualización basada en *CLAHE*, pero sin ninguna optimización.
- Los objetivos que se propone este trabajo, buscando lograr la mejora del contraste en imágenes de naturaleza diversa, además de los objetivos que se plantean para la metaheurística *PSO*.
- Conceptos básicos con referencia a cómo se representa una imagen digital, cómo se define la mejora de una imagen, en términos de la calidad visual de la misma, además de cómo se define el contraste y bajo qué circunstancias se puede considerar que el contraste es pobre en la imagen digital.
- Los enfoques generales de ecualización del histograma, con respecto a si se toma la imagen como un todo para la ecualización, o se realiza por sectores.
- El concepto de ecualización del histograma, además de diferentes variantes propuestas a la ecualización del histograma clásica que se ven en las obras del estado del arte.
- Los conceptos fundamentales del algoritmo de *CLAHE*, y del algoritmo de *AHE*, el cual es un predecesor fuertemente relacionado, además de una breve comparación entre los mismos.
- Las métricas de evaluación utilizadas por *PSO* para la evaluación de la calidad de las soluciones encontradas. La definición de la Entropía de la información, y su aplicación en el contexto de la mejora del contraste de la imagen; además

7. Conclusiones y Trabajos Futuros

del *SSIM*, que es una métrica específica para evaluar la calidad de una imagen digital.

- La función de Fitness utilizada, además del funcionamiento del algoritmo de *PSO – CLAHE*, para la resolución del problema de mejora del contraste a nivel local.

Se realizó la implementación utilizando las librerías disponibles en OpenCV [Bra00] para el algoritmo de *CLAHE* y *SSIM* y JMetal [DN11] para la implementación de *PSO* monoobjetivo. Se seleccionaron 23 imágenes de naturaleza diversa para efectuar pruebas, y configurando el algoritmo con 100 partículas. Se realizó la exploración extensiva del espacio de búsqueda completo para cada imagen, ésto es, utilizando todos los tamaños de ventana rectangulares posibles, y todos los Clip Limit disponibles en *CLAHE* para cada imagen de prueba.

Se validaron los resultados implementando el algoritmo más próximo encontrado en la literatura del estado del arte propuesto por Byong [MLKL13]. Para el efecto se ejecutaron las mismas imágenes de prueba con los dos algoritmos, y se muestran los resultados tabulados de *PSO – CLAHE* en el Apéndice A, Tablas 1 - 23, y sus imágenes correspondientes en el Apéndice B, Figuras 1 - 20 junto con las imágenes resultantes de Byong.

A partir de las pruebas realizadas y de los resultados obtenidos, se pueden considerar las siguientes conclusiones:

- Para todos los resultados, la implementación de Byong muestra valores similares de Entropía al comparar con *PSO – CLAHE*, sin embargo, se presentan valores notablemente superiores de *SSIM* en todos los resultados obtenidos con *PSO – CLAHE*; por ende los valores de fitness de los resultados obtenidos con *PSO – CLAHE* son superiores para todos los casos de prueba presentados.
- Los resultados de las imágenes generales para *PSO – CLAHE* muestran una clara mejora en el contraste, manteniendo la apariencia natural de las mismas. Los resultados más notables se dan en las imágenes con problemas de contraste severos, aunque también existen mejoras en las imágenes que tienen contraste aceptable. Para el mismo grupo de imágenes, los resultados obtenidos por la implementación de Byong muestran ecualizaciones que tienden a exceder el contraste natural de las imágenes, debido a que sólo se utiliza la Entropía como métrica de evaluación de los resultados.
- En el grupo de imágenes médicas, *PSO – CLAHE* arrojó como resultados imágenes que mantienen los detalles finos de la imagen original, lo cual es fundamental para presevar la utilidad de los mismos, y también consiguió mostrar detalles finos que se ven opacados por el contraste incorrecto. Los mismos resultados obtenidos por la implementación de Byong, muestran imágenes sobre ecualizadas que perdieron detalles fundamentales, además de sobre ecualización.

7. Conclusiones y Trabajos Futuros

- Asimismo, en el grupo de imágenes biométricas, se ve que *PSO–CLAHE* mejora en todos los casos el Fitness definido al comparar con los resultados obtenidos con la implementación de Byong, y aunque en este grupo se ven imágenes con menos detalles, el contraste de los mismos es muy pobre, y en todos los casos *PSO – CLAHE* logra mejoras significativas.
- Gracias a la metaheurística *PSO*, se logra la sintonización de parámetros de *CLAHE*, debido a que se realiza una búsqueda efectiva dentro del espacio de soluciones.
- *PSO – CLAHE* es un algoritmo válido para la mejora de contraste en imágenes generales, médicas y biométricas, por lo que su aplicabilidad es muy amplia, y los resultados que se obtuvieron en las pruebas de la implementación son prometedores.
- Gracias a la formulación propuesta, se lograron los objetivos principales trazados en este trabajo, tanto en términos de mejorar la cantidad de información, como la minimización de la distorsión producida por la ecualización.

Finalmente, el aporte más importante que arroja este trabajo es la utilización efectiva de un algoritmo de mejora de contraste a nivel local (*CLAHE*) en conjunto con una metaheurística de optimización (*PSO*) y unas métricas de evaluación de resultados (Entropía y SSIM) que permiten la mejora del contraste en imágenes en escala de grises, sin introducir una distorsión apreciable en las mismas. Este algoritmo se muestra aplicable tanto en imágenes generales, médicas o biométricas, mostrando resultados satisfactorios.

7.2. Trabajos Futuros

Se proponen los siguientes trabajos de manera a seguir con esta tesis de grado:

- Utilizar una implementación multi-objetivo de *PSO*, de manera a introducir métricas que se consideren adecuadas para la mejora del contraste.
- Encontrar otros casos prácticos de manera a validar los resultados obtenidos por *PSO – CLAHE*.
- Realizar modificaciones al algoritmo de *CLAHE* de manera a que se tengan en cuenta múltiples ventanas de tamaños variables durante la optimización con *PSO*.
- Realizar una implementación de *PSO – CLAHE*, o una combinación de metaheurística con una técnica de mejora del contraste adaptada para imágenes a color.

Apéndice A

Tablas de resultados.

En este Apéndice se presentan las tablas de resultados de la propuesta *PSO – CLAHE*. En cada tabla se presentan los 10 mejores resultados encontrados por *PSO – CLAHE* para cada imagen de prueba.

Cada tabla presenta los parámetros \mathcal{R} y Clip Limit \mathcal{C} , la entropía \mathcal{H} de la imagen mejorada, el índice de similitud estructural *SSIM* y el valor del fitness f .

Al final de cada tabla se presentan la media y la desviación estándar del valor de *Fitness* para cada imagen.

Tabla 1: Resultados para imagen Tórax.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	<i>SSIM</i>	f
7	8	0,0109	0,9167	0,8515	0,7806
210	2	0,0075	0,9043	0,9007	0,8145
2	96	0,0118	0,9481	0,8141	0,7718
2	129	0,0154	0,9583	0,7727	0,7404
2	2	0,0091	0,9544	0,8617	0,8224
2	2	0,0245	0,9886	0,7399	0,7315
2	257	0,0119	0,9514	0,7989	0,7601
3	3	0,0096	0,9312	0,8695	0,8097
2	16	0,0101	0,9405	0,8478	0,7974
2	2	0,0223	0,9894	0,7449	0,7370
Promedio de f : 0,7808					
Desviación Estándar de f : 0,0256					

Tabla 2: Resultados para imagen Mamografía.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	55	0,0051	0,8839	0,9043	0,7993
2	2	0,0044	0,8784	0,9287	0,8158
2	55	0,0058	0,8952	0,8532	0,7639
3	2	0,0064	0,9105	0,8675	0,7898
5	2	0,0087	0,9364	0,7945	0,7440
5	2	0,0073	0,9253	0,8396	0,7769
7	3	0,0062	0,8732	0,9052	0,7904
6	2	0,0059	0,9115	0,8798	0,8020
5	2	0,0069	0,9208	0,8508	0,7834
2	2	0,0056	0,8936	0,8906	0,7959
Promedio de f : 0,7862					
Desviación Estándar de f : 0,0205					

Tabla 3: Resultados para imagen Retinopatía.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	10	0,0152	0,8783	0,6304	0,5537
196	7	0,00003	0,8144	0,7070	0,5759
2	245	0,0166	0,8738	0,5873	0,5132
99	2	0,0065	0,8218	0,8086	0,6646
2	256	0,0049	0,8026	0,8489	0,6814
37	2	0,0183	0,8940	0,5684	0,5082
2	49	0,0104	0,8522	0,7196	0,6133
2	2	0,0072	0,8424	0,8045	0,6777
11	2	0,0190	0,8982	0,5588	0,5019
2	2	0,0132	0,8636	0,6600	0,5700
Promedio de f : 0,5860					
Desviación Estándar de f : 0,0701					

. Apéndice A

Tabla 4: Resultados para imagen Células.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	256	0,0187	0,9542	0,6580	0,6279
97	2	0,0175	0,9377	0,6371	0,5974
2	256	0,0108	0,9306	0,7625	0,7097
2	140	0,0211	0,9717	0,6034	0,5863
6	129	0,00003	0,8497	0,8848	0,7518
5	256	0,00003	0,8022	0,8358	0,6705
10	129	0,00003	0,7392	0,8762	0,6477
2	256	0,0242	0,9735	0,5840	0,5686
4	256	0,0073	0,8558	0,8794	0,7526
2	256	0,0085	0,9038	0,8321	0,7521
Promedio de f : 0,6757					
Desviación Estándar de f : 0,0882					

Tabla 5: Resultados para imagen Rodilla.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	512	0,0017	0,8981	0,9192	0,8255
2	256	0,0118	0,9492	0,8273	0,7852
2	2	0,0140	0,9597	0,8165	0,7836
2	7	0,0080	0,9211	0,9084	0,8367
2	181	0,0194	0,9652	0,7566	0,7303
2	256	0,0164	0,9601	0,7794	0,7483
3	2	0,0116	0,9511	0,8400	0,7989
103	2	0,0056	0,8723	0,9109	0,7946
2	12	0,0121	0,9444	0,8467	0,7997
2	2	0,0096	0,9370	0,8841	0,8284
Promedio de f : 0,7931					
Desviación Estándar de f : 0,03396					

Tabla 6: Resultados para imagen Aorta.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
13	2	0,01965	0,9718	0,4923	0,4785
18	23	0,000039	0,8808	0,9069	0,7989
2	5	0,0056	0,9299	0,7901	0,7347
2	129	0,0064	0,9368	0,7430	0,6961
2	256	0,000039	0,8949	0,8857	0,7927
5	256	0,000039	0,9138	0,8287	0,7572
2	222	0,0144	0,9728	0,5270	0,5127
2	2	0,0091	0,9487	0,6560	0,6224
2	252	0,0071	0,9444	0,7115	0,6720
2	2	0,0125	0,9536	0,5803	0,5534
Promedio de f : 0,6619					
Desviación Estándar de f : 0,1158					

Tabla 7: Resultados para imagen Lenna.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	65	0,0072	0,9798	0,8987	0,8806
65	3	0,0028	0,9530	0,9437	0,8993
2	3	0,0045	0,9813	0,9246	0,9073
2	2	0,0118	0,9909	0,8629	0,8551
2	5	0,0110	0,9911	0,8561	0,8485
2	5	0,0102	0,9894	0,8658	0,8566
2	2	0,0076	0,9851	0,9073	0,8939
5	4	0,0087	0,9823	0,8818	0,8662
4	2	0,0063	0,9806	0,9226	0,9048
4	2	0,0065	0,9816	0,9195	0,9026
Promedio de f : 0,8815					
Desviación Estándar de f : 0,0230					

. Apéndice A

Tabla 8: Resultados para imagen Flores.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
32	8	0,000039	0,9352	0,8662	0,8101
128	2	0,000039	0,9434	0,8555	0,8071
128	2	0,000039	0,9434	0,8555	0,8071
42	6	0,0021	0,9201	0,9103	0,8375
2	65	0,0090	0,9634	0,7966	0,7674
2	65	0,0110	0,9710	0,7520	0,7302
58	5	0,0040	0,9372	0,8705	0,8159
2	65	0,0116	0,9764	0,7101	0,6933
2	59	0,0106	0,9693	0,7676	0,7440
3	128	0,000039	0,9376	0,8653	0,8113
Promedio de f : 0,7824					
Desviación Estándar de f : 0,0463					

Tabla 9: Resultados para imagen Jirafa.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	128	0,0022	0,7745	0,9002	0,6972
2	2	0,0078	0,8330	0,8086	0,6735
71	2	0,0085	0,8314	0,7910	0,6576
128	2	0,0049	0,7838	0,8995	0,7050
2	128	0,0007	0,7745	0,9002	0,6972
65	3	0,0083	0,8058	0,8636	0,6959
65	2	0,0065	0,8084	0,8430	0,6815
75	5	0,0084	0,8127	0,7984	0,6489
5	2	0,0081	0,8381	0,8000	0,6705
128	3	0,0009	0,7852	0,9022	0,7084
Promedio de f : 0,6835					
Desviación Estándar de f : 0,0204					

. Apéndice A

Tabla 10: Resultados para la imagen Árbol.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
148	2	0,0045	0,8661	0,9232	0,7997
148	2	0,000039	0,8661	0,9232	0,7996
41	2	0,0104	0,9258	0,7839	0,7258
10	2	0,0063	0,8920	0,8715	0,7774
2	2	0,0113	0,9275	0,7513	0,6969
148	2	0,0120	0,8965	0,7912	0,7093
2	5	0,0039	0,8108	0,9396	0,7619
2	2	0,0012	0,7951	0,9926	0,7893
75	2	0,01179	0,9322	0,7496	0,6988
2	128	0,0081	0,8666	0,8168	0,7079
Promedio de f : 0,7467					
Desviación Estándar de f : 0,0430					

Tabla 11: Resultados para imagen Mujer.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	2	0,0081	0,8363	0,8000	0,6691
128	2	0,0057	0,7838	0,8995	0,7050
9	3	0,0074	0,8257	0,8231	0,6797
3	3	0,0055	0,7996	0,8779	0,7019
5	2	0,0315	0,9327	0,7296	0,6804
128	2	0,0106	0,8480	0,7503	0,6363
122	2	0,0067	0,7936	0,8900	0,7063
65	2	0,0056	0,7873	0,8993	0,7080
5	2	0,0077	0,8331	0,8133	0,6776
9	4	0,0045	0,7861	0,9131	0,7177
Promedio de f : 0,6882					
Desviación Estándar de f : 0,0244					

. Apéndice A

Tabla 12: Resultados para imagen Caramelos.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
128	2	0,000039	0,8385	0,9150	0,7672
2	128	0,000039	0,8311	0,9402	0,7813
2	128	0,026422	0,8935	0,8386	0,7493
4	65	0,000039	0,7902	0,9459	0,7475
128	2	0,000039	0,8385	0,9150	0,7672
2	65	0,023957	0,9121	0,8308	0,7578
5	63	0,000039	0,7691	0,9493	0,7301
3	128	0,000039	0,7986	0,9432	0,7533
65	2	0,031423	0,9380	0,7630	0,7157
2	19	0,020645	0,9062	0,8568	0,7764
Promedio de f : 0,7546					
Desviación Estándar de f : 0,0203					

Tabla 13: Resultados para imagen Caramelos 2.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
7	2	0,0187	0,9444	0,8588	0,8111
2	2	0,0146	0,9288	0,8870	0,8238
5	2	0,0115	0,9168	0,9232	0,8464
9	2	0,0224	0,9571	0,8267	0,7913
9	2	0,0248	0,9624	0,8029	0,7727
20	2	0,0127	0,9214	0,9111	0,8395
2	128	0,0261	0,9262	0,8095	0,7497
7	2	0,0243	0,9235	0,8281	0,7648
7	6	0,0112	0,9089	0,9288	0,8441
2	256	0,0068	0,8041	0,9131	0,7298
Promedio de f : 0,7973					
Desviación Estándar de f : 0,0418					

. Apéndice A

Tabla 14: Resultados de la imagen Aérea.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	6	0,0044	0,9338	0,9688	0,9047
2	3	0,0037	0,9143	0,9754	0,8918
6	4	0,0082	0,9689	0,9236	0,8949
4	5	0,0074	0,9636	0,9309	0,8970
2	56	0,0062	0,9543	0,9643	0,9203
5	3	0,0052	0,9397	0,9598	0,9019
98	2	0,0164	0,9699	0,9059	0,8786
5	7	0,0100	0,9765	0,9047	0,8835
16	2	0,0019	0,9036	0,9940	0,8982
2	4	0,0046	0,9340	0,9639	0,9004
Promedio de f : 0,8971					
Desviación Estándar de f : 0,0114					

Tabla 15: Resultados para imagen Aérea 2.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
279	3	0,0026	0,9007	0,8382	0,8817
2	59	0,0122	0,9605	0,8382	0,8051
2	256	0,0094	0,9375	0,9086	0,8518
9	6	0,0134	0,9667	0,8125	0,7855
9	2	0,0134	0,9691	0,8122	0,7871
129	2	0,0127	0,9603	0,8416	0,8082
7	8	0,0086	0,9471	0,8910	0,8439
8	2	0,0083	0,9461	0,8983	0,8498
129	2	0,0108	0,9508	0,8779	0,8347
145	2	0,0082	0,9401	0,9151	0,8603
Promedio de f : 0,8308					
Desviación Estándar de f : 0,0326					

. Apéndice A

Tabla 16: Resultados para imagen Aeroplano.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	2	0,0057	0,8706	0,9265	0,8066
45	2	0,0092	0,8782	0,8736	0,7672
11	2	0,0062	0,8761	0,9137	0,8005
2	5	0,0102	0,8941	0,8232	0,7361
5	4	0,0065	0,8662	0,9039	0,7830
4	2	0,0077	0,8920	0,8836	0,7882
2	2	0,0109	0,8982	0,8203	0,7368
5	2	0,0081	0,8921	0,8744	0,7800
2	101	0,0060	0,8517	0,9277	0,7901
2	2	0,0100	0,8955	0,8370	0,7495
Promedio de f : 0,7738					
Desviación Estándar de f : 0,0254					

Tabla 17: Resultados de la imagen Pareja.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	2	0,0144	0,9767	0,8246	0,8054
2	2	0,0006	0,8465	0,9991	0,8457
7	7	0,000057	0,8157	0,9994	0,8153
2	11	0,00039	0,8265	0,9992	0,8259
3	2	0,0001	0,8051	0,9998	0,8049
2	2	0,0112	0,9675	0,8703	0,8421
2	2	0,0002	0,8153	0,9996	0,8151
2	2	0,0148	0,9785	0,8195	0,8019
2	9	0,0091	0,9588	0,8868	0,8503
2	129	0,0069	0,9420	0,9050	0,8525
Promedio de f : 0,8259					
Desviación Estándar de f : 0,0200					

. Apéndice A

Tabla 18: Resultados de la imagen Puente.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
16	2	0,5000	0,9988	0,7443	0,7434
3	2	0,2500	0,9964	0,7814	0,7786
7	2	0,2500	0,9982	0,7599	0,7586
14	2	0,5000	0,9987	0,7480	0,7470
2	2	0,0226	0,9928	0,8261	0,8202
512	2	0,4407	0,9711	0,8697	0,8446
4	4	0,4965	0,9981	0,7606	0,7592
17	2	0,4589	0,9988	0,7444	0,7435
17	2	0,4589	0,9988	0,7444	0,7435
3	4	0,0000	0,9975	0,7748	0,7728
Promedio de f : 0,7711					
Desviación Estándar de f : 0,0350					

Tabla 19: Resultados para imagen Camión.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
129	2	0,0200	0,9567	0,6718	0,6427
129	2	0,0109	0,9240	0,8009	0,7400
3	2	0,0180	0,9483	0,6994	0,6633
256	2	0,0162	0,9573	0,6978	0,6680
2	2	0,0093	0,9070	0,8386	0,7607
256	2	0,0125	0,9301	0,7819	0,7272
256	4	0,0080	0,9326	0,7314	0,6821
256	7	0,0051	0,9080	0,7948	0,7217
235	2	0,0141	0,9324	0,7535	0,7025
129	2	0,0119	0,9306	0,7805	0,7264
Promedio de f : 0,7035					
Desviación Estándar de f : 0,0380					

Tabla 20: Resultados de la imagen Elaine.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
8	2	0,0128	0,9837	0,8481	0,8343
2	2	0,0125	0,9812	0,8648	0,8486
2	7	0,0095	0,9731	0,8942	0,8702
2	2	0,0108	0,9781	0,8882	0,8688
13	2	0,0197	0,9917	0,7688	0,7625
2	2	0,0189	0,9897	0,7979	0,7897
16	2	0,0103	0,9781	0,8797	0,8604
2	2	0,0237	0,9920	0,7698	0,7637
2	13	0,0141	0,9838	0,8241	0,8108
256	2	0,0092	0,9718	0,9037	0,8783
Promedio de f : 0,8287					
Desviación Estándar de f : 0,0443					

Tabla 21: Resultados de la imagen Iris 1.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
288	8	0,00679	0,8952	0,8478	0,7590
145	2	0,01311	0,9513	0,7692	0,7317
2	38	0,01151	0,9247	0,7897	0,7302
288	2	0,01553	0,9615	0,7228	0,6950
278	2	0,01193	0,9428	0,7868	0,7418
2	10	0,00938	0,9125	0,8379	0,7646
2	10	0,00974	0,9149	0,8305	0,7599
16	2	0,01085	0,9426	0,8112	0,7646
2	2	0,01729	0,9585	0,7182	0,6884
23	80	0,00004	0,8252	0,9310	0,7683
Promedio de f : 0,7403					
Desviación Estándar de f : 0,0291					

. Apéndice A

Tabla 22: Resultados de la imagen Iris 2.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
2	2	0,0110	0,9566	0,8215	0,78586
2	9	0,0045	0,8833	0,9387	0,8292
8	2	0,0091	0,9528	0,8595	0,8190
114	2	0,0093	0,9482	0,8533	0,8091
8	2	0,0095	0,9542	0,8524	0,8134
7	2	0,0072	0,9399	0,8982	0,8442
9	11	0,0040	0,8543	0,9481	0,8101
16	2	0,0114	0,9601	0,8162	0,7837
2	2	0,0088	0,9474	0,8611	0,8158
2	2	0,0075	0,9402	0,8866	0,8337
Promedio de f : 0,8144					
Desviación Estándar de f : 0,0191					

Tabla 23: Resultados de la imagen Dedo 1.

\mathcal{R}_x	\mathcal{R}_y	\mathcal{C}	\mathcal{H}	$SSIM$	f
25	2	0,0434	0,8583	0,6795	0,5832
29	2	0,0254	0,8408	0,7509	0,6314
8	2	0,0318	0,8448	0,7579	0,6403
3	160	0,0000	0,7759	0,8335	0,6467
2	160	0,0142	0,8561	0,6757	0,5785
17	2	0,0563	0,8602	0,6518	0,5606
7	4	0,0194	0,8533	0,7304	0,6232
2	14	0,0203	0,8514	0,7010	0,5968
19	2	0,0551	0,8591	0,6486	0,5573
4	2	0,0005	0,6300	0,9954	0,6271
Promedio de f : 0,6045					
Desviación Estándar de f : 0,0333					

Apéndice B

Imágenes originales y mejoradas.

En este Apéndice se presentan las imágenes mejoradas con los parámetros del *CLAHE* encontrados por nuestra propuesta *PSO – CLAHE* en comparación con las imágenes originales y las imágenes mejoradas por los parámetros encontrados por Byong [MLKL13].

Para nuestra propuesta, se ha escogido el mejor resultado de cada una de las tablas del Apéndice A, donde se presentaron los 10 mejores resultados del *PSO – CLAHE* por cada imagen de prueba.

Para la propuesta de Byong, se ha puesto el único resultado posible debido a que es un método determinístico.

Los resultados se presentan de la siguiente manera:

- En (a) se presenta la imagen original.
- En (b) se presenta la imagen mejorada con los resultados de nuestra propuesta *PSO – CLAHE*.
- En (c) se presenta la imagen mejorada con los resultados de la propuesta de Byong.

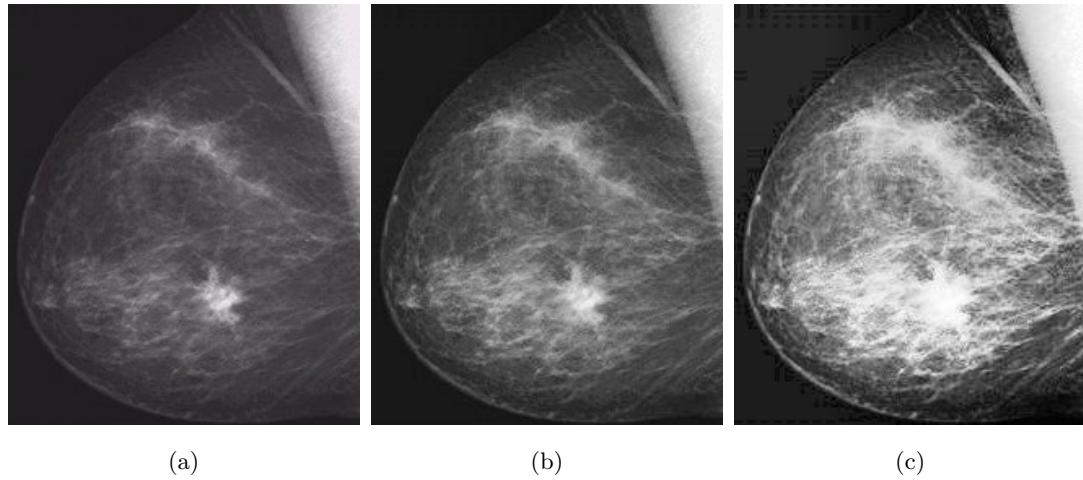


Figura 1: Imagen original y resultados para imagen Mamografía.

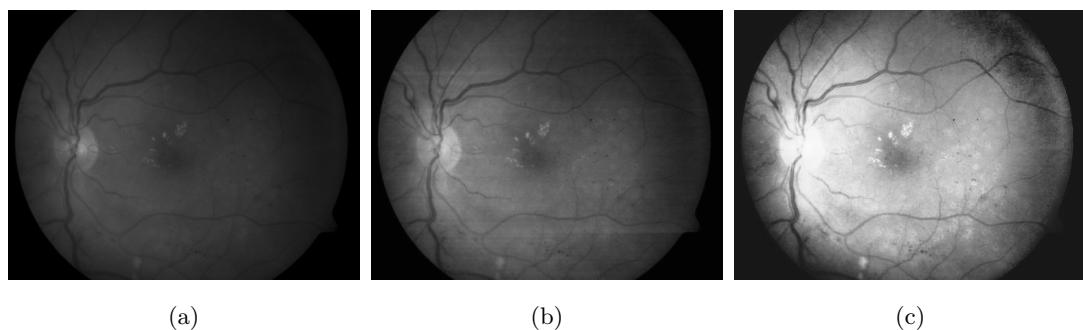


Figura 2: Imagen original y resultados para imagen Retinopatía.

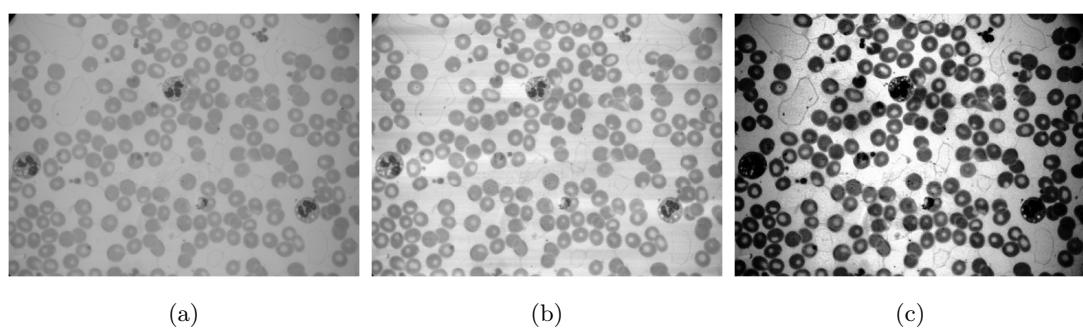


Figura 3: Imagen original y resultados para imagen Células.

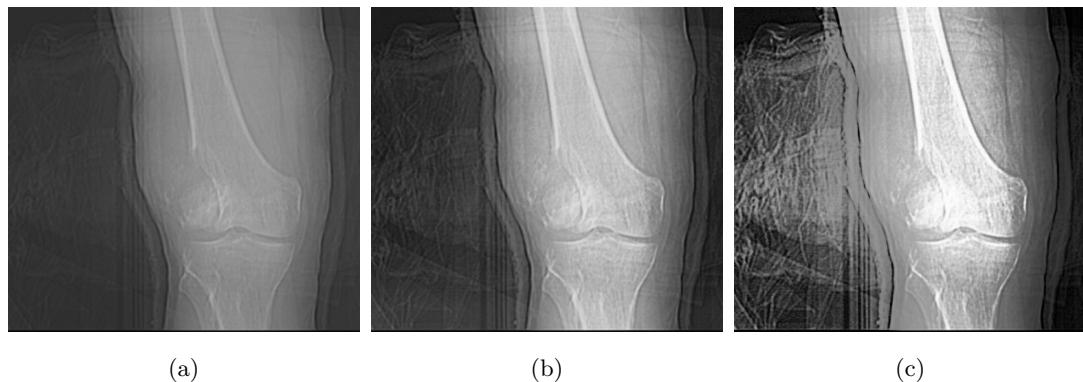


Figura 4: Imagen original y resultados para imagen Rodilla.

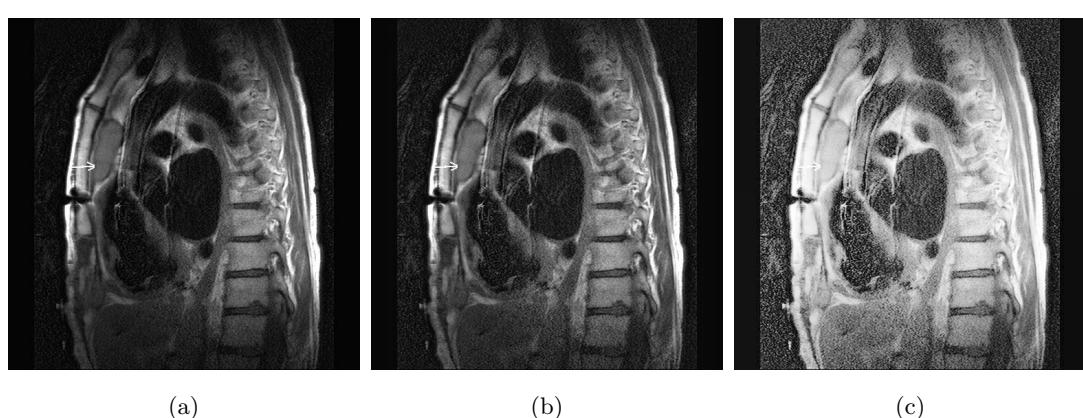


Figura 5: Imagen original y resultados para imagen Aorta.

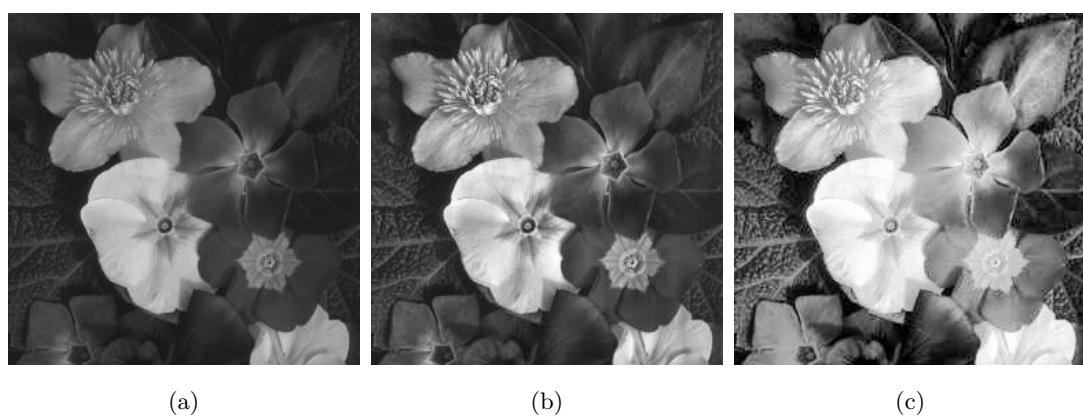
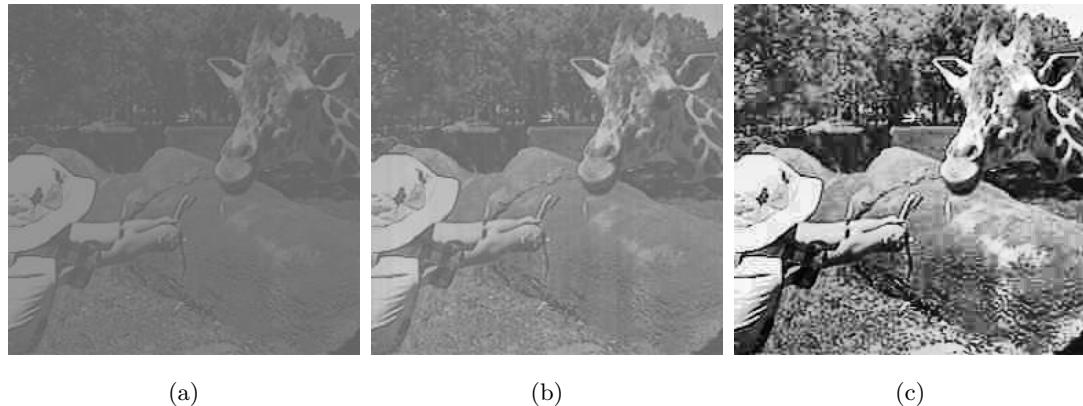


Figura 6: Imagen original y resultados para imagen Flores.

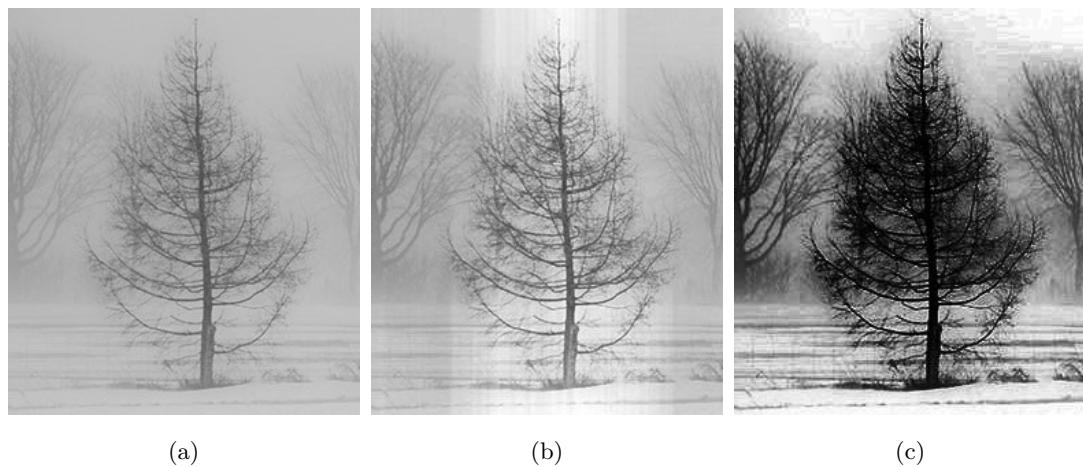


(a)

(b)

(c)

Figura 7: Imagen original y resultados para imagen Jirafa.

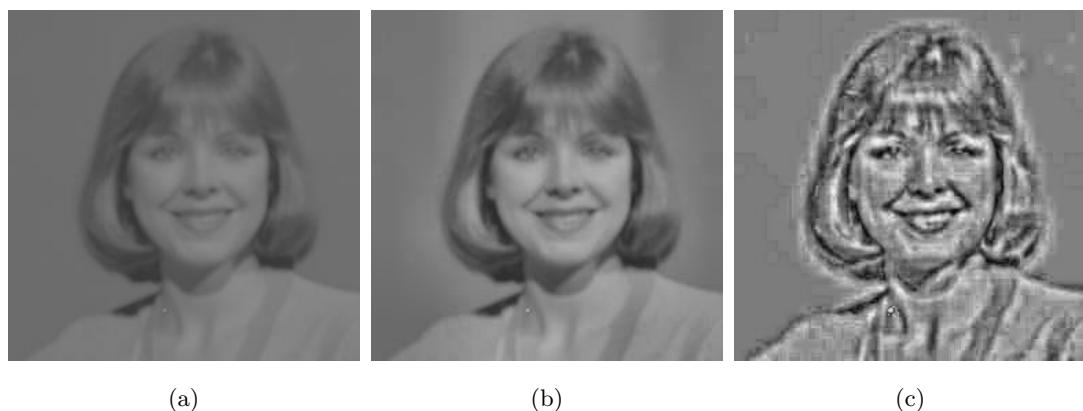


(a)

(b)

(c)

Figura 8: Imagen original y resultados para imagen Árbol.



(a)

(b)

(c)

Figura 9: Imagen original y resultados para imagen Mujer.

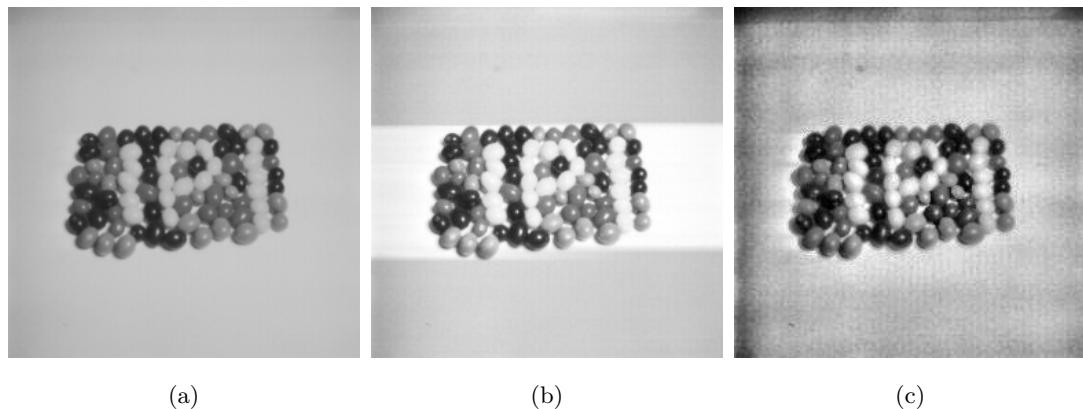


Figura 10: Imagen original y resultados para imagen Caramelos.

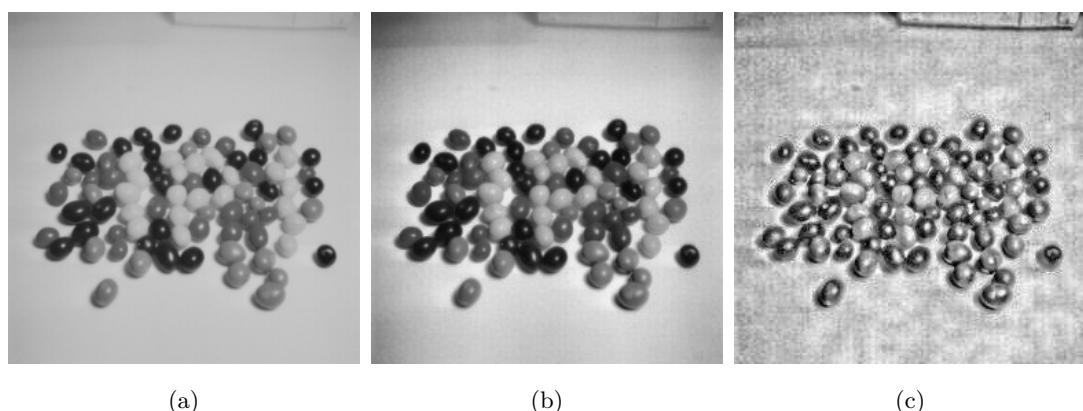
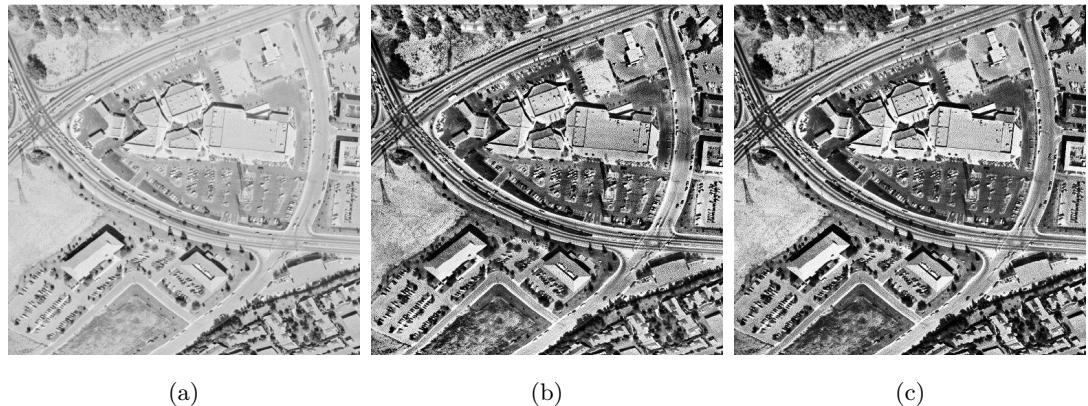


Figura 11: Imagen original y resultados para imagen Caramelos 2.



Figura 12: Imagen original y resultados para imagen Aérea.

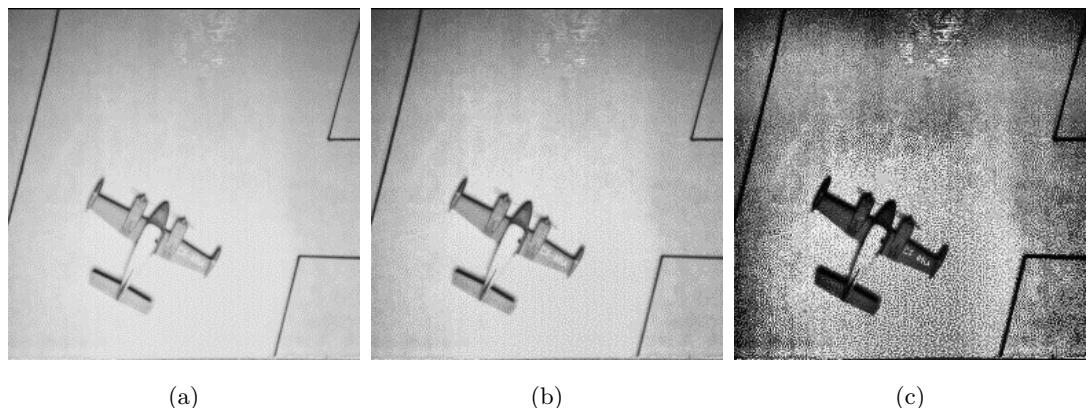


(a)

(b)

(c)

Figura 13: Imagen original y resultados para imagen Aérea 2.

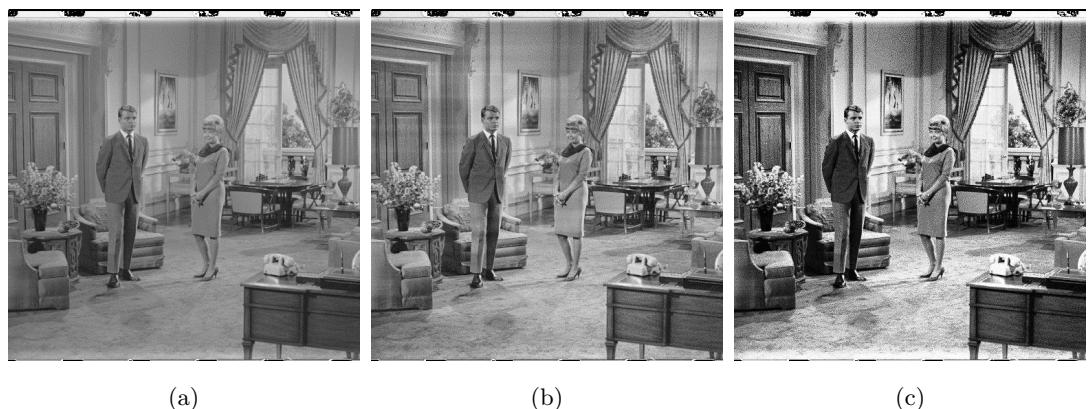


(a)

(b)

(c)

Figura 14: Imagen original y resultados para imagen Avión.

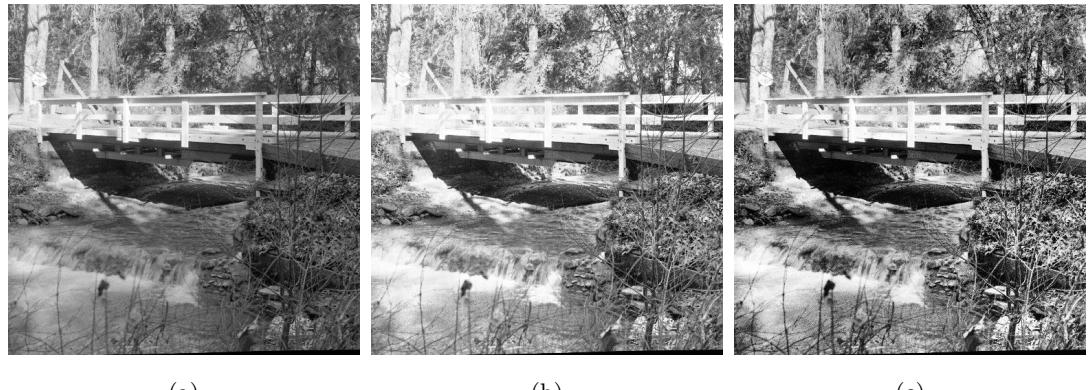


(a)

(b)

(c)

Figura 15: Imagen original y resultados para imagen Pareja.



(a)

(b)

(c)

Figura 16: Imagen original y resultados para imagen Puente.

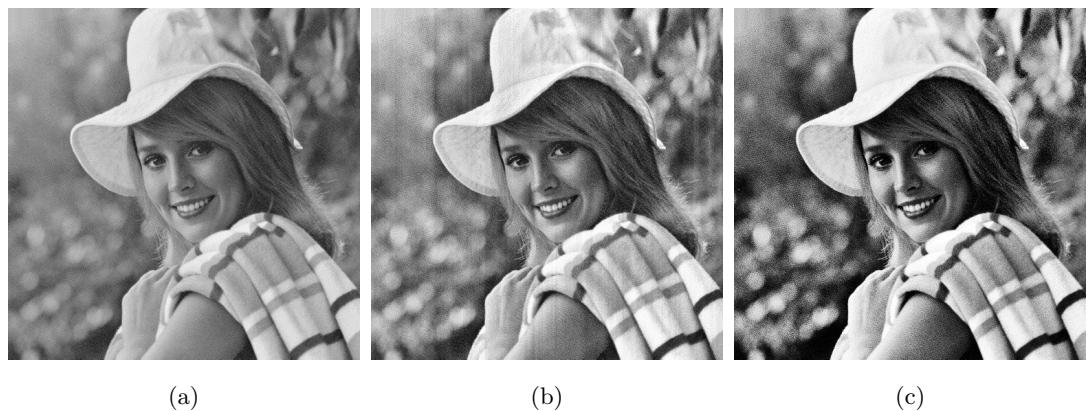


(a)

(b)

(c)

Figura 17: Imagen original y resultados para imagen Camión.



(a)

(b)

(c)

Figura 18: Imagen original y resultados para imagen Elaine.

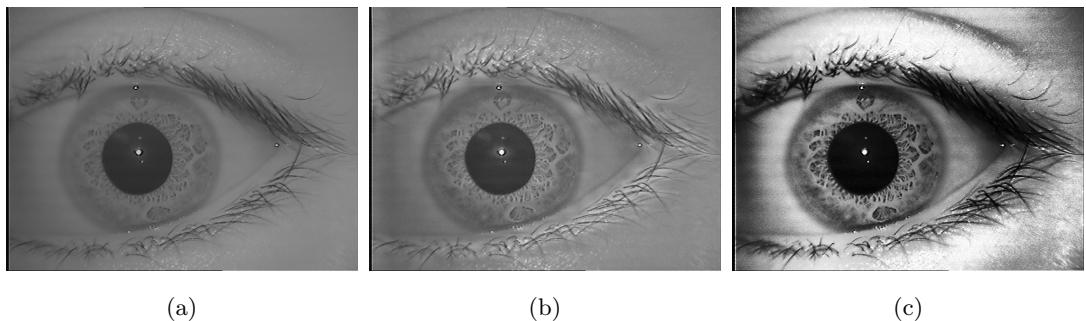


Figura 19: Imagen original y resultados para imagen biométrica de Iris 2.

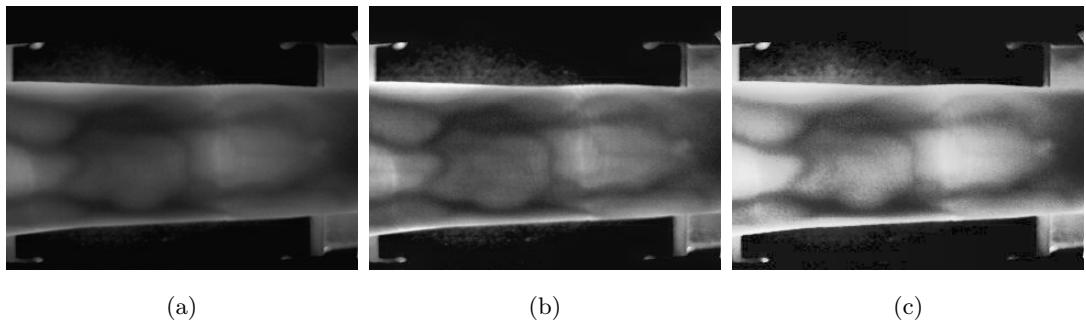


Figura 20: Imagen original y resultados para imagen biométrica Dedo.

Referencias

- [AMFM11] Pablo Arbelaez, Michael Maire, Charless Fowlkes, and Jitendra Malik. Contour detection and hierarchical image segmentation. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 33(5):898–916, 2011. [2](#)
- [Ann07] S Annadurai. *Fundamentals of digital image processing*. Pearson Education India, 2007. [41](#)
- [ASN13] Niloofer Amani, Asadollah Shahbahrami, and Manoochehr Nahvi. A new approach for face image enhancement and recognition. *International Journal of Advanced Science and Technology*, 52:1–10, March 2013. [2](#), [7](#)
- [Bax94] Gregory A Baxes. *Digital image processing: principles and applications*. John Wiley & Sons, Inc., 1994. [1](#), [5](#)
- [Bra00] G. Bradski. Opencv. *Dr. Dobb's Journal of Software Tools*, 2000. [56](#), [65](#)
- [BSA07] Malik Braik, Alaa F Sheta, and Aladdin Ayesh. Image enhancement using particle swarm optimization. In *Proceedings of the World Congress on Engineering*, London, U.K., July 2007. IAENG. [14](#), [33](#), [51](#)
- [Bus10] Stewart C Bushong. In *Manual de radiología para técnicos*, page 685. Elsevier, 2010. [10](#)
- [CA86] Gonzalo Cuevas Agustín. *Teoría de la Información, Codificación y Lenguaje*. Ministerio de Educación y Ciencia, 1986. [43](#)
- [CD01] Anthony Carlisle and Gerry Dozier. An off-the-shelf pso. In *Proceedings of the workshop on particle swarm optimization*, volume 1, pages 1–6. Indianapolis, 2001. [39](#)
- [CDS13] A Cheung, X Ding, and H Shen. Optifel: A convergent heterogeneous particle swarm optimization algorithm for takagi-sugeno fuzzy mo-

REFERENCIAS

- deling. *Fuzzy Systems, IEEE Transactions on*, 22(4):919–933, Aug 2013. 39
- [CJB13] Rajlaxmi Chouhan, Rajib Kumar Jha, and Prabir Kumar Biswas. Enhancement of dark and low-contrast images using dynamic stochastic resonance. *IET Image Processing*, 7:174–184, March 2013. 11
- [CK02] Maurice Clerc and James Kennedy. The particle swarm-explosion, stability, and convergence in a multidimensional complex space. *Evolutionary Computation, IEEE Transactions on*, 6(1):58–73, 2002. 38
- [CPW10] Chi-hau Chen, Louis-François Pau, and Patrick Shen-pei Wang. *Handbook of pattern recognition and computer vision*. World Scientific, 2010. 2
- [CVVL02] Carlos A Coello Coello, David A Van Veldhuizen, and Gary B Lamont. *Evolutionary algorithms for solving multi-objective problems*, volume 242. Springer, 2002. 32
- [DHLB14] A Djerouni, H Hamada, A Loukil, and N Berrached. Dorsal hand vein image contrast enhancement techniques. *International Journal of Computer Science Issues*, 11(1):137–142, January 2014. 7
- [Dic14] Dictionary. Gray. <http://dictionary.reference.com/browse/gray?s=t>, 2014. En línea. Acceso: 14-11-2014. 6
- [dlRAE14] Diccionario de la Real Academia Española. Gris. <http://lema.rae.es/drae/?val=gris>, 2014. En línea. Acceso: 14-11-2014. 6
- [DN11] Juan J Durillo and Antonio J Nebro. jmetal: A java framework for multi-objective optimization. *Advances in Engineering Software*, 42:760–771, 2011. 56, 65
- [EB98] Michael P Eckert and Andrew P Bradley. Perceptual quality metrics applied to still image compression. *Signal processing*, 70(3):177–200, 1998. 41
- [EF95] Ahmet M Eskicioglu and Paul S Fisher. Image quality measures and their performance. *Communications, IEEE Transactions on*, 43(12):2959–2965, Dec 1995. 41
- [Fie00] Roy Thomas Fielding. *Architectural Styles and the Design of Network-based Software Architectures*. PhD thesis, University of California, Irvine, 2000. 56
- [FKB07] Hartwig Fronthaler, Klaus Kollreider, and Josef Bigun. Pyramid-based image enhancement of fingerprints. In *2007 IEEE Workshop on Automatic Identification Advanced Technologies*, number 12452, pages 45–50, Alghero, June 2007. IEEE. 7

REFERENCIAS

- [GF10] Ignacio García Fenoll. Aportaciones a la segmentación y caracterización de imágenes médicas 3d. Tesis de Grado, Universidad de Sevilla, España, Enero 2010. [1](#)
- [Gir93] Bernd Girod. Digital images and human vision. chapter What's Wrong with Mean-squared Error?, pages 207–220. MIT Press, Cambridge, MA, USA, 1993. [41](#)
- [Gis00] Carlos Gispert. *Enciclopedia interactiva de los conocimientos*. OCEANO, Grupo Editorial S.A., Barcelona - España, 2000. [6](#)
- [Han11] Muna F Hanoon. Contrast fingerprint enhancement based on histogram equalization followed by bit reduction of vector quantization. *International Journal of Computer Science and Network Security*, 11(5):116–123, May 2011. [2](#), [7](#)
- [HC14] S Huang and W Chen. A new hardware-efficient algorithm and reconfigurable architecture for image contrast enhancement. *IEEE Transactions on Image Processing*, 23:4426–4437, October 2014. [12](#)
- [HKNM09] Sara Hashemi, Soheila Kiani, Navid Noroozi, and Mohsen Ebrahimi Moghaddam. An image contrast enhancement method based on genetic algorithm. In *2009 International Conference on Digital Image Processing*, pages 167–171, Bangkok, March 2009. IEEE. [14](#), [19](#)
- [JRP04] Anil K Jain, Arun Ross, and Salil Prabhakar. An introduction to biometric recognition. *Circuits and Systems for Video Technology, IEEE Transactions on*, 14(1):4–20, 2004. [1](#), [7](#)
- [KBD91] A Khellaf, A Beghdadi, and H. Dupoisot. Entropic contrast enhancement. *Medical Imaging, IEEE Transactions on*, 10(4):589–592, Dec 1991. [45](#)
- [Ken97] James Kennedy. The particle swarm: social adaptation of knowledge. In *Evolutionary Computation, 1997., IEEE International Conference on*, pages 303–308. IEEE, 1997. [38](#)
- [KHLF06] Ngai Ming Kwok, Quang Phuc Ha, DK Liu, and Gu Fang. Intensity-preserving contrast enhancement for gray-level images using multi-objective particle swarm optimization. In *IEEE International Conference on Automation Science and Engineering*, pages 21–26, Shanghai, China, October 2006. IEEE. [12](#), [43](#)
- [Kim97] Yeong-Taeg Kim. Contrast enhancement using brightness preserving bi-histogram equalization. *IEEE Transactions on Consumer Electronics*, 43:1–8, February 1997. [21](#)

REFERENCIAS

- [KJ91] Charles W Kurak Jr. Adaptive histogram equalization: a parallel implementation. In *CBMS*, pages 192–199. IEEE, 1991. [21](#), [22](#), [23](#)
- [KKH01] Joung-Youn Kim, Lee-Sup Kim, and Seung-Ho Hwang. An advanced contrast enhancement using partially overlapped sub-block histogram equalization. *IEEE Transactions on Circuits and Systems for Video Technology*, 11:475–484, April 2001. [21](#)
- [KL02] Thiemo Krink and Morten Løvbjerg. The lifecycle model: Combining particle swarm optimisation, genetic algorithms and hillclimbers. In *Parallel Problem Solving from Nature — PPSN VII*, volume 2439, pages 621–630. Springer Berlin Heidelberg, 2002. [39](#)
- [KLW76] David J Ketcham, Roger W Lowe, and JW Weber. *Image Enhancement Techniques for Cockpit Displays*. Defense Technical Information Center, 1976. [21](#), [22](#)
- [KWH⁺13] NM Kwok, D Wang, QP Ha, G Fang, and SY Chen. Locally-equalized image contrast enhancement using pso-tuned sectorized equalization. In *Computational Intelligence in Image Processing*, pages 21–36. Springer Berlin Heidelberg, 2013. [2](#), [12](#), [13](#), [14](#), [16](#)
- [KWR⁺00] Raymond J Kim, Edwin Wu, Allen Rafael, Enn-Ling Chen, Michele A Parker, Orlando Simonetti, Francis J Klocke, Robert O Bonow, and Robert M Judd. The use of contrast-enhanced magnetic resonance imaging to identify reversible myocardial dysfunction. *New England Journal of Medicine*, 343(20):1445–1453, 2000. [2](#)
- [Len14] Lenna. Imagen de referencia. <http://sipi.usc.edu/database/database.php?volume=misc&image=12#top>, 2014. Fecha de acceso: 2014-09-06. [28](#)
- [LK02] Morten Løvbjerg and Thiemo Krink. Extending particle swarm optimisers with self-organized criticality. In *Computational Intelligence, Proceedings of the World on Congress on*, volume 2, pages 1588–1593. IEEE, 2002. [39](#)
- [LLK13] Chulwoo Lee, Chul Lee, and Chang-Su Kim. Contrast enhancement based on layered difference representation of 2d histograms. *IEEE Transactions on Image Processing*, 22(12):5372–5384, December 2013. [1](#), [13](#), [14](#), [16](#), [19](#), [20](#), [21](#)
- [LWHJ94] Jian Lu, John B Weaver, and Dennis M Healy Jr. Contrast enhancement of medical images using multiscale edge representation. *Optical engineering*, 33(7):2151–2161, 1994. [2](#)

REFERENCIAS

- [MLKL13] Byong Seok Min, Dong Kyun Lim, Seung Jong Kim, and Joo Heung Lee. A novel method of determining parameters of clahe based on image entropy. *International Journal of Software Engineering and Its Applications*, 7(5):113–120, September 2013. [IV](#), [VI](#), [XV](#), [XV](#), [XV](#), [2](#), [3](#), [14](#), [17](#), [19](#), [24](#), [56](#), [58](#), [60](#), [65](#), [79](#)
- [MM13] Shelda Mohan and TR Mahesh. Particle swarm optimization based contrast limited enhancement for mammogram images. In *2013 7th International Conference on Intelligent Systems and Control (ISCO)*, pages 384–388, Coimbatore, Tamil Nadu, India, January 2013. IEEE. [7](#)
- [MR13] Shelda Mohan and M Ravishankar. Optimized histogram based contrast limited enhancement for mammogram images. *ACEEE Int. J. on Information Technology*, 3(1):66–71, March 2013. [2](#), [3](#), [7](#), [21](#), [24](#)
- [NA10] Taher Niknam and Babak Amiri. An efficient hybrid approach based on pso, aco and i_l - k_l -means for cluster analysis. *Applied Soft Computing*, 10(1):183–197, 2010. [39](#)
- [NBC⁺12] Marco S Nobile, Daniela Besozzi, Paolo Cazzaniga, Giancarlo Mauri, and Dario Pescini. A gpu-based multi-swarm pso method for parameter estimation in stochastic biological systems exploiting discrete-time target series. In *Evolutionary Computation, Machine Learning and Data Mining in Bioinformatics*, volume 7246, pages 74–85. Springer Berlin Heidelberg, 2012. [40](#)
- [NG11] Mojtaba Najafi and Sedigheh Ghofrani. Iris recognition based on using ridgelet and curvelet transform. *International Journal of Signal Processing, Image Processing and Pattern Recognition*, 4(2):7–18, June 2011. [2](#), [7](#)
- [OHBL10] Martin Aastrup Olsen, Daniel Hartung, Christoph Busch, and Rasmus Larsen. Contrast enhancement and metrics for biometric vein pattern recognition. In *Advanced Intelligent Computing Theories and Applications*, volume 93, pages 425–434. Springer Berlin Heidelberg, 2010. [2](#), [7](#)
- [ope14] Banco de datos de imágenes. openi biomedical image search engine. <http://openi.nlm.nih.gov/>, 2014. En línea. Acceso: 02-11-2014. [58](#)
- [PAA⁺87] Stephen M Pizer, E Philip Amburn, John D Austin, Robert Cromartie, Ari Geselowitz, Trey Greer, Bart ter Haar Romeny, John B Zimerman, and Karel Zuiderveld. Adaptive histogram equalization and its variations. *Comput. Vision Graph. Image Process.*, 39(3):355–368, September 1987. [21](#), [22](#), [27](#)

REFERENCIAS

- [Par10] Jim R Parker. *Algorithms for image processing and computer vision*. John Wiley & Sons, 2010. [2](#)
- [PCGSCFYD09] Luzmila Pró Concepción, Juan Carlos González Suárez, Walter Contreras Flores, and Carlos Enrique Yañez Duran. Tecnologías biométricas aplicadas a la seguridad en las organizaciones. *Revista de Ingeniería de Sistemas e Informática*, 6:55–66, Diciembre 2009. [1](#)
- [PKB07] Riccardo Poli, James Kennedy, and Tim Blackwell. Particle swarm optimization. *Swarm Intelligence*, 1(1):33–57, 2007. [32](#), [37](#)
- [Pol08] Riccardo Poli. Analysis of the publications on the applications of particle swarm optimisation. *J. Artif. Evol. App.*, 2008:4:1–4:10, January 2008. [32](#)
- [PTS⁺13] Shashi Poddar, Suman Tewary, Deewakar Sharma, Vinod Karar, Ashish Ghosh, and Sankar K Pal. Non-parametric modified histogram equalisation for contrast enhancement. *IET Image Processing*, 7:641 – 652, October 2013. [8](#), [16](#), [19](#)
- [PZH⁺98] Etta D Pisano, Shuquan Zong, Bradley M Hemminger, Marla DeLuca, R Eugene Johnston, Keith Muller, M Patricia Braeuning, and Stephen M Pizer. Contrast limited adaptive histogram equalization image processing to improve the detection of simulated spiculations in dense mammograms. *Journal of Digital Imaging*, 11(4):193–200, 1998. [31](#)
- [Rus10] John C Russ. *The image processing handbook*. CRC press, Florida - USA, 2010. [1](#), [5](#), [6](#), [8](#), [9](#), [26](#), [27](#)
- [SBS11] P Shanmugavadivu, K Balasubramanian, and K Somasundaram. Modified histogram equalization for image contrast enhancement using particle swarm optimization. *International Journal of Computer Science, Engineering and Information Technology*, 1(5):13–27, December 2011. [1](#), [19](#)
- [sdu14] Sdumla-hmt - machine learning and data mining lab. shandong university, 2014. [58](#)
- [SE98a] Yuhui Shi and Russell C Eberhart. A modified particle swarm optimizer. In *Evolutionary Computation Proceedings, 1998. IEEE World Congress on Computational Intelligence., The 1998 IEEE International Conference on*, pages 69–73. IEEE, May 1998. [37](#)
- [SE98b] Yuhui Shi and Russell C Eberhart. Parameter selection in particle swarm optimization. In *Evolutionary Programming VII*, pages 591–600. Springer, 1998. [38](#)

REFERENCIAS

- [Sha48] Claude Elwood Shannon. A mathematical theory of communication. *Bell System Technical Journal, The*, 27(3):379–423, July 1948. [42](#)
- [SHE03] S.L. Salas, E. Hille, and G.J. Etgen. *Calculus: una y varias variables*. Number v. 2. Reverté, 2003. [58](#)
- [SM15] H Sanpachai and Settapong Malisuwat. A study of image enhancement for iris recognition. *Journal of Industrial and Intelligent Information*, 3(1):61–64, March 2015. [7](#)
- [SMG11] Balvant Singh, Ravi Shankar Mishra, and Puran Gour. Analysis of contrast enhancement techniques for underwater image. *International Journal of Computer Technology and Electronics Engineering*, 1(2):190–194, October 2011. [2](#), [14](#), [15](#), [21](#), [31](#)
- [SRAP11] M Sundaram, K Ramar, N Arumugam, and G Prabin. Histogram based contrast enhancement for mammogram images. In *2011 International Conference on Signal Processing, Communication, Computing and Networking Technologies (ICSCCN)*, pages 842–846, Thuckafay, July 2011. IEEE. [2](#), [7](#)
- [SV11] Saikat Kumar Shome and Siva Ram Krishna Vadali. Enhancement of diabetic retinopathy imagery using contrast limited adaptive histogram equalization. *International Journal of Computer Science and Information Technologies (IJCSIT)*, 2:2694–2699, November–December 2011. [1](#), [2](#), [3](#), [8](#), [19](#)
- [TH94] Patrick C Teo and David J Heeger. Perceptual image distortion. In *Image Processing, 1994. Proceedings. ICIP-94., IEEE International Conference*, volume 2, pages 982–986, Nov 1994. [41](#)
- [TLM08] Du-Yih Tsai, Yongbum Lee, and Eri Matsuyama. Information entropy measure for evaluation of image quality. *Journal of Digital Imaging*, 21(3):338–347, 2008. [42](#)
- [TMM13] Randa BOUKHRIS TRABELSI, Alima DAMAK MASMOUDI, and Dorra SELLAMI MASMOUDI. Hand vein image enhancement with radon like features descriptor. *World Academy of Science, Engineering and Technology*, 7(6):1653–1656, 2013. [7](#)
- [usc14] Banco de datos de imágenes. signal and image processing institute - university of southern california. <http://sipi.usc.edu/database/>, 2014. En línea. Acceso: 28-10-2014. [58](#)
- [VDB06] Frans Van Den Bergh. *An Analysis of Particle Swarm Optimizers*. PhD thesis, Pretoria, South Africa, South Africa, 2006. [33](#)

REFERENCIAS

- [VS11] Komal Vij and Yaduvir Singh. Enhancement of images using histogram processing techniques. *International Journal of Computer Technology and Applications*, 2(2):309–313, January 2011. [1](#), [8](#), [16](#), [24](#)
- [WB02] Zhou Wang and Alan C Bovik. A universal image quality index. *Signal Processing Letters, IEEE*, 9(3):81–84, 2002. [41](#)
- [WBL02] Zhou Wang, Alan C Bovik, and Ligang Lu. Why is image quality assessment so difficult? In *Acoustics, Speech, and Signal Processing (ICASSP), 2002 IEEE International Conference on*, volume 4, pages IV–3313. IEEE, 2002. [41](#)
- [WBSS04] Zhou Wang, Alan C Bovik, Hamid R Sheikh, and Eero P Simoncelli. Image quality assessment: from error visibility to structural similarity. *Image Processing, IEEE Transactions on*, 13(4):600–612, April 2004. [41](#), [45](#), [49](#), [58](#)
- [WCZ99] Yu Wang, Qian Chen, and Baomin Zhang. Image enhancement based on equal area dualistic sub-image histogram equalization method. *IEEE Transactions on Consumer Electronics*, 45:68–75, February 1999. [21](#)
- [web14a] C++ rest sdk (codename casablanca). <https://casablanca.codeplex.com/documentation.html>, 2014. En línea. Acceso: 28-10-2014. [56](#)
- [web14b] Formato de intercambio de mensajes: Json. <http://json.org/>, 2014. En línea. Acceso: 28-10-2014. [56](#)
- [Xin10] Zhao Xinchao. A perturbed particle swarm algorithm for numerical optimization. *Applied Soft Computing*, 10(1):119–124, 2010. [39](#)
- [ZCF⁺89] John B Zimmerman, Steve B Cousins, Mark E Frisse, Karin M Hartzell, and Michael G Kahn. A psychophysical comparison of two methods for adaptive histogram equalization. *Journal of Digital Imaging*, 2(2):82–91, 1989. [21](#), [22](#)
- [Zui94] Karel Zuiderveld. Contrast limited adaptive histogram equalization. pages 474–485, 1994. [2](#), [21](#), [22](#), [23](#), [24](#), [30](#), [31](#)
- [ZZLS11] Zhi-Hui Zhan, Jun Zhang, Yun Li, and Yu-Hui Shi. Orthogonal learning particle swarm optimization. *Evolutionary Computation, IEEE Transactions on*, 15(6):832–847, 2011. [39](#)